Carlos Mario Garcia Alvarez
cc:1036963357

Taller: Regresión Lineal...

① Regresión lineal multivariada desde máxima verosimilitud.

1) Tenemos

$$y^{(i)} = \theta^T x^{(i)} + \epsilon^{(i)}$$

siendo $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$

Luego s. $\epsilon \sim \mathcal{N}(0, \sigma^2)$

$\therefore \mu + \epsilon \sim \mathcal{N}(\mu, \sigma^2)$

donde $\theta^T x^{(i)}$

Por lo tanto

$$y^{(i)} | X = x^{(i)} \sim \mathcal{N}(\theta^T x^{(i)}, \sigma^2)$$

2) como acabamos de ver que $y^{(i)} | X = x^{(i)}$ sigue una distribución normal, así:

$$p(y | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y-\mu)^2}{2\sigma^2} \right]$$

como en nuestro caso $\mu = \theta^T x^{(i)}$ entonces:

$$P(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[\frac{-(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right]$$

3) Si tenemos independencia, entonces:

$$L(\theta) = \prod_{i=1}^{m} P(y^{(i)} | x^{(i)}; \theta)$$

y si sustituimos

$$\therefore L(\theta) = \prod_{i=1}^{m} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[\frac{-(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right]$$

Si sacamos las constantes y consideramos que $\prod_i e^{a_i} = e^{\sum_i a_i}$

obtenemos:

$$L(\theta) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^m \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^{m} (y^{(i)} - \theta^T x^{(i)})^2\right]$$

4) $\ell(\theta) = \text{Log } L(\theta)$

$$\ell(\theta) = \text{Log}\left[\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^m \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^{m} (y^{(i)} - \theta^T x^{(i)})^2\right]\right]$$

como $\log(xy) = \log x + \log y$ ∧ $\log(e^z) = z$

siguiente.

$$\ell(\theta) = \log\left[\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^m\right] - \frac{1}{2\sigma^2}\sum_{i=1}^{m}\left(y^{(i)} - \theta^T x^{(i)}\right)^2$$

$\therefore$

$$\ell(\theta) = -\frac{m}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{m}\left(y^{(i)} - \theta^T x^{(i)}\right)^2$$

5) Solo el término

$$\frac{-1}{2\sigma^2}\sum_{i=1}^{m}\left(y^{(i)} - \theta^T x^{(i)}\right)^2$$

6) Tenemos

$$\ell(\theta) = K - \frac{1}{2\sigma^2}\sum_{i}\left(y^{(i)} - \theta^T x^{(i)}\right)^2$$

K = constante

y como $\frac{1}{2\sigma^2} > 0$, entonces el máximo lo encontramos como

$$\min\left(\sum_{i}\left(y^{(i)} - \theta^T x^{(i)}\right)^2\right)$$

Que es entonces minimizar la suma de residuos cuadrados.

7) como

$$h_\theta(x^{(i)}) = \theta^T x^{(i)}$$

$\therefore$

$$\ell(\theta) = -\frac{m}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{m}\left(y^{(i)} - h_\theta(x^{(i)})\right)^2$$

ahora queremos maximizar $\ell(\theta)$,

Para esto Nos fijamos en maximizar:

$$-\frac{1}{2\sigma^2}\sum_{i=1}^{m}\left(y^{(i)} - h_\theta(x^{(i)})\right)^2$$

por ser Negativo, entonces debemos minimizar:

$$\sum_{i=1}^{m}\left(y^{(i)} - h_\theta(x^{(i)})\right)^2$$

$$= \sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)^2$$

Multiplicamos por $\frac{1}{2m}$

y llegamos a que

$$J(\theta) = \frac{1}{2m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)^2$$

8) Como $m > 0$, entonces multiplicar toda la función por ese número no cambia el punto donde alcanza su mínimo, así $\frac{1}{2}$ ∧ $\frac{1}{m}$ no cambia el minimizador.

(2) Gradiente y descenso por gradiente

Partiendo de

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right)^2$$

1) Como

$$h_\theta(x^{(i)}) = \sum \theta_k x_k^{(i)}$$

$$\therefore \frac{\partial h_\theta(x^{(i)})}{\partial \theta_j} = x_j^{(i)}$$

2) $$\frac{\partial J}{\partial \theta_j} = ?$$

J depende de θ_j a través de $h_\theta(x^{(i)})$

Aplicando la regla de la cadena

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^{m} 2\left(h_\theta(x^{(i)}) - y^{(i)}\right) \cdot \frac{\partial h_\theta(x^{(i)})}{\partial \theta_j}$$

3) si sustituimos lo del Paso 1) en 2)

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right) x_j^{(i)}$$

4) Sustituyendo en $\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$

$$\theta_j := \theta_j - \alpha \cdot \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right) x_j^{(i)}$$

5)

- $j=0$: $\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right) \cdot \underbrace{x_0^{(i)}}_{1}$

⋮

- $j=n$: $\theta_n := \theta_n - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right) x_n^{(i)}$

6) Cada $\frac{\partial J}{\partial \theta_j}$ depende de $h_\theta(x^{(i)})$, y h_θ usa Todos los Parámetros $\theta_0, \ldots, \theta_n$ a la vez. Si actualizo θ_0 primero y luego uso ese θ_0 ya actualizado para calcular el gradiente de θ_1, estaría mezclando los valores Viejos con los nuevos de θ dentro de una misma iteración.

(3) Ecuación normal

Partimos de la forma matricial del costo:

$$J(\theta) = \frac{1}{2m}(X\theta - y)^T(X\theta - y)$$

1) Para expandir tenemos en cuenta que. $(A-B)^T = A^T - B^T$

$$\therefore (X\theta - y)^T(X\theta - y) = (\theta^T X^T - y^T)(X\theta - y)$$

$$= \theta^T X^T X\theta - \theta^T X^T y - y^T X\theta + y^T y$$

$$= \theta^T X^T X\theta - 2\theta^T X^T y + y^T y$$

2) Para calcular $\nabla_\theta J(\theta)$ tenemos en cuenta

- $\nabla_\theta(\theta^T A\theta) = 2A\theta$
- $\nabla_\theta(\theta^T b) = b$

$$\therefore \nabla_\theta(\theta^T X^T X\theta) = 2X^T X\theta$$

$$\nabla_\theta(2\theta^T X^T y) = 2X^T y$$

$$\nabla_\theta(y^T y) = 0 \text{ (No depende de } \theta)$$

Así llegamos a:

$$\nabla_\theta J(\theta) = \frac{1}{2m}(2X^T X\theta - 2X^T y) = \frac{1}{m}(X^T X\theta - X^T y)$$

3) $\nabla_\theta J(\theta) = 0 = \frac{1}{m}(X^T X\theta - X^T y)$

$\Rightarrow X^T X\theta - X^T y = 0$

4) despejando la Anterior

$\Rightarrow X^T X\theta = X^T y$

5) $\theta = (X^T X)^{-1} X^T y$

6)
- El Descenso por gradiente es Iterativo
- La ecuación normal es la Analítica.
- Las Columnas son Linealmente dependientes o hay más parámetros que datos.

4) Regresión logística desde la Familia exponencial

7) como $A = e^{\log A}$

$P(y;\phi) = \exp[\log(\phi^y(1-\phi)^{1-y}]$

$= \exp[y\log\phi + (1-y)\log(1-\phi)]$

organizando terminos..

$= \exp\left[y\log\frac{\phi}{1-\phi} + \log(1-\phi)\right]$

2) Comparando con $\exp[\eta T(y) - a(\eta)]$

$\therefore$ $T(y) = y$, $\eta = \log \frac{\phi}{1-\phi}$ $a(\eta) = -\log(1-\phi)$

$b(y) = 1$

3) Ya que dado del punto anterior cuando se comparó con la expresión del paso 1)

4)

$$e^{\eta} = \frac{\phi}{1-\phi}$$ Luego despejamos "ϕ"

$$\phi = \frac{e^{\eta}}{1+e^{\eta}} = \frac{1}{1+e^{-\eta}} = \phi$$

5) Sustituyendo

$$P_\theta(Y=1 \mid X=x) = \frac{1}{1+e^{-\theta^T x}}$$

6) $$h_\theta(x) = \frac{1}{1+e^{-\theta^T x}} = \sigma(\theta^T x)$$

7) Como Y solo toma dos valores y las probabilidades deben sumar 1:

$$P_\theta(Y=0 \mid X=x) = 1 - P_\theta(Y=1 \mid X=x)$$

$$= 1 - h_\theta(x)$$

(5) Likelihood y Función de coste Logística

1) $p(y^{(i)} | x^{(i)}; \theta) = (h_\theta(x^{(i)}))^{y^{(i)}} \cdot (1 - h_\theta(x^{(i)}))^{1-y^{(i)}}$

Verificando

Si $y^{(i)} = 1$

$\Rightarrow h_\theta(x^{(i)})^1 \cdot (1 - h_\theta(x^{(i)}))^0 = h_\theta(x^{(i)})$

Si: $y^{(i)} = 0$

$\Rightarrow h_\theta(x^{(i)})^0 \cdot (1 - h_\theta(x^{(i)}))^1 = 1 - h_\theta(x^{(i)})$

2) Suponiendo independencia

$$L(\theta) = \prod_{i=1}^{m} (h_\theta(x^{(i)}))^{y^{(i)}} (1 - h_\theta(x^{(i)}))^{1-y^{(i)}}$$

3) $$\ell(\theta) = \log L(\theta) = \sum_{i=1}^{m} [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$$

4)

$$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log h_\theta(x^{(i)}) + (1-y^{(i)})\cdot \log(1-h_\theta(x^{(i)}))\right]$$

5) Sería entonces

$$-\left[y^{(i)}\log h_\theta(x^{(i)}) + (1-y^{(i)})\log(1-h_\theta(x^{(i)}))\right]$$

6)

$$\frac{\partial}{\partial \theta_j}\left[-y^{(i)}\log h_\theta(x^{(i)}) - (1-y^{(i)})\log(1-h_\theta(x^{(i)}))\right]$$

$$= \left(-\frac{y^{(i)}}{h_\theta(x^{(i)})} + \frac{1-y^{(i)}}{1-h_\theta(x^{(i)})}\right)\cdot \frac{\partial h_\theta(x^{(i)})}{\partial \theta_j}$$

$$\Rightarrow \frac{\partial h_\theta(x^{(i)})}{\partial \theta_j} = \sigma(\theta^T x^{(i)})(1-\sigma(\theta^T x^{(i)}))\cdot x_j^{(i)}$$

$$= h_\theta(x^{(i)})(1-h_\theta(x^{(i)}))x_j^{(i)}$$

Sustituyendo y distribuyendo.

$$= [h_\theta(x^{(i)}) - y^{(i)}]\, x_j^{(i)}$$

$\therefore$

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_j^{(i)}}$$

7) $\theta_j := \theta_j - \alpha \cdot \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$

8) Lineal

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad h_\theta(x) = \theta^T x$$

Logistica

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad h_\theta(x) = g(\theta^T x)$$

(6) Regularización

7)

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2 + \frac{1}{2m} \sum_{j=1}^{n} \theta_j^2$$

2) el primer termino fue calculado en el punto 2. Por otro lado.

$$\frac{\partial}{\partial \theta_j} \left(\frac{\lambda}{2m} \sum_{k=1}^{n} \theta_k^2 \right) = \frac{1}{2m} \cdot 2\theta_j = \frac{1}{m} \theta_j$$

sumando ambas contribuciones

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) + \frac{1}{m} \theta_j$$

$j \geq 1$

3) Caso $j=0$.

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_0^{(i)}$$

4) Para $j \geq 1$

$$\theta_j := \theta_j - \alpha\left[\frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_j^{(i)} + \frac{1}{m}\theta_j\right]$$

5) $$\theta_j := \theta_j - \alpha\frac{1}{m}\theta_j - \alpha\frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_j^{(i)}$$

Factorizando θ_j de los 2 primeros términos:

$$\theta_j := \theta_j\left(1 - \frac{\alpha 1}{m}\right) - \alpha\frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_j^{(i)}$$

(Término de datos)

6) El factor $\left(1 - \frac{\alpha 1}{m}\right) < 1$ encoge θ_j hacia cero en cada iteración, antes de aplicar la corrección de los datos.

7) $$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log h_\theta(x^{(i)}) + (1-y^{(i)})\log(1-h_\theta(x^{(i)}))\right] + \frac{\lambda}{2m}\sum_{j=1}^{n}\theta_j^2$$

8) $\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{1}{m} \theta_j$

$j \geq 1$

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

a) θ_0 es el sesgo / Intercepto: No multiplica ninguna Feature, solo Fija el nivel base de Y. Así que No aporta a la complejidad que la regularización busca Controlar.