① a) $L(\theta) = \prod_{i=1}^{n} p(y_i|x_i;\theta) \Rightarrow L(\theta) = \prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}$

donde $p(y_i|x_i;\theta)$ representa la probabilidad de observar exactamente y_i partículas cuando la condición experimental es x_i.

Como las detecciones correspondientes a distintas observaciones son independientes, se puede definir la verosimilitud como la probabilidad conjunta $P(y_1,\dots,y_n|x_1,\dots,x_n;\theta)$.

---

b). Ahora, queremos encontrar $\hat{\theta}_{MV}$ t.q. $\hat{\theta}_{MV} = \underset{\theta^*}{\operatorname{argmax}} L(\theta)$

o lo que es lo mismo $\hat{\theta}_{MV} = \underset{\theta^*}{\operatorname{argmax}} \ell(\theta)$

donde $\ell(\theta) = \log L(\theta)$. Entonces, calculando tenemos

$$\ell(\theta) = \log\left(\prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right) = \sum_{i=1}^{n} \log\left(\frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right)$$

$$= \sum_{i=1}^{n} \log\left(h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}\right) - \sum_{i=1}^{n} \log y_i!$$

$$= \sum_{i=1}^{n} y_i \log h_\theta(x_i) - \sum_{i=1}^{n} h_\theta(x_i) - \sum_{i=1}^{n} \log y_i!$$

$$\Rightarrow \boxed{\ell(\theta) = \sum_{i=1}^{n} \left[y_i \log h_\theta(x_i) - h_\theta(x_i) - \log y_i!\right]}$$

Ahora, el principio de máxima verosimilitud busca maximizar $\ell(\theta)$. Sin embargo, la optimización buscada para el modelo es en términos de minimización. Así, pasamos de maximizar a minimizar, definiendo

$$J(\theta) = -\ell(\theta) \Rightarrow J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \log h_\theta(x_i) + \log y_i! \right]$$

---

c). Ahora, si despreciamos el término independiente de los parámetros θ, tenemos que la función de coste es:

$$\boxed{J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \log h_\theta(x_i) \right]}$$

---

d). Ahora, calculemos $\nabla_\theta J(\theta)$ con $h_\theta(x_i) = \theta_0 + \theta_1 x_i$

$$\Rightarrow \partial_0 J = \frac{\partial}{\partial \theta_0} \left[\sum_{i=1}^{n} (\theta_0 + \theta_1 x_i) - y_i \log(\theta_0 + \theta_1 x_i) \right]$$

$$= \sum_{i=1}^{n} \left(1 - \frac{y_i}{\theta_0 + \theta_1 x_i} \right) \Rightarrow \boxed{\partial_0 J = \sum_{i=1}^{n} \left(1 - \frac{y_i}{h_\theta(x_i)} \right)}$$

$$\Rightarrow \partial_1 J = \frac{\partial}{\partial \theta_1} \left[\sum_{i=1}^{n} (\theta_0 + \theta_1 x_i) - y_i \log(\theta_0 + \theta_1 x_i) \right]$$

$$= \sum_{i=1}^{n} \left(x_i - \frac{x_i y_i}{\theta_0 + \theta_1 x_i} \right) = \sum_{i=1}^{n} x_i \left(1 - \frac{y_i}{\theta_0 + \theta_1 x_i} \right) \Rightarrow \boxed{\partial_1 J = \sum_{i=1}^{n} x_i \left(1 - \frac{y_i}{h_\theta(x_i)} \right)}$$

e). Por último, según el modelo $h_\theta(x_i)$ representa la tasa esperada de detecciones. Puede decirse que es el número esperado de partículas detectadas durante el intervalo de tiempo considerado. Se podría decir que $h_\theta(x) = \mathbb{E}[y|x;\theta]$.

Por su parte θ_0 representa las condiciones del detector cuando no hay presencia de partículas detectadas. Es algo intrínseco del detector, por ejemplo puede ser su sensibilidad. Todo esto se basa en el hecho de que $h_\theta(x_i=0) = \theta_0$.

Por último, si hacemos $\frac{\partial h_\theta(x_i)}{\partial x_i} = \theta_1$. Así, θ_1 representa el cambio de la tasa esperada bajo el cambio de las condiciones experimentales. Es decir, θ_1 nos da cuenta de cómo cambia el flujo de partículas detectadas, cuando se cambian las condiciones experimentales detectadas.

2 a). Tenemos una red de una capa oculta con entrada escalar de salida positiva:

$$h_\theta(x_i) = e^{f_\theta(x_i)}$$

con $z_{i1}^{[1]} = \theta_{11}^{[1]} x_i + b_1^{[1]}$, $A_{i1}^{[1]} = \sigma(z_{i1}^{[1]})$

$$z_{i1}^{[2]} = \theta_{11}^{[2]} A_{i1}^{[1]} + b_1^{[2]}, \quad h_\theta(x_i) = e^{z_{i1}^{[2]}}$$

donde σ es función de activación diferenciable.

Para un dato (x_i, y_i) la función de costo de Poisson

$$J_i(\theta) = e^{z_{i1}^{[2]}} - y_i z_{i1}^{[2]}$$

Entonces, el error en la capa de salida es:

$$\delta_{i1}^{[2]} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} = e^{z_{i1}^{[2]}} - y_i = h_\theta(x_i) - y_i \Rightarrow \boxed{\delta_{i1}^{[2]} = h_\theta(x_i) - y_i}$$

---

b). Los gradientes respecto a los parámetros de la capa de salida son:

$$\frac{\partial J_i}{\partial \theta_{11}^{[2]}} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} \frac{\partial z_{i1}^{[2]}}{\partial \theta_{11}^{[2]}} = \delta_{i1}^{[2]} \frac{\partial z_{i1}^{[2]}}{\partial \theta_{11}^{[2]}}, \text{ pero } \frac{\partial z_{i1}^{[2]}}{\partial \theta_{11}^{[2]}} = A_{i1}^{[1]}$$

$$\Rightarrow \frac{\partial J_i}{\partial \theta_{11}^{[2]}} = \delta_{i1}^{[2]} A_{i1}^{[1]}$$

$$\Rightarrow \frac{\partial J_i}{\partial \theta_{11}^{[2]}} = \delta_{i1}^{[2]} A_{i1}^{[1]} = (h_\theta(x_i) - y_i)\, \sigma(z_{i1}^{[1]}) \Rightarrow \boxed{\frac{\partial J_i}{\partial \theta_{11}^{[2]}} = (h_\theta(x_i) - y_i)\, \sigma(z_{i1}^{[1]})}$$

Así mismo, $\frac{\partial J_i}{\partial b_1^{[2]}} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} \underbrace{\frac{\partial z_{i1}^{[2]}}{\partial b_1^{[2]}}}_{=1} = \delta_{i1}^{[2]} = h_\theta(x_i) - y_i$

$$\Rightarrow \boxed{\frac{\partial J_i}{\partial b_1^{[2]}} = h_\theta(x_i) - y_i}$$

---

c). Ahora, el error que se propaga hacia la capa oculta es:

$$\delta_{i1}^{[1]} = \frac{\partial J_i}{\partial z_{i1}^{[1]}} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} \frac{\partial z_{i1}^{[2]}}{\partial A_{i1}^{[1]}} \frac{\partial A_{i1}^{[1]}}{\partial z_{i1}^{[1]}} = \delta_{i1}^{[2]} \frac{\partial z_{i1}^{[2]}}{\partial A_{i1}^{[1]}} \frac{\partial A_{i1}^{[1]}}{\partial z_{i1}^{[1]}} = \delta_{i1}^{[2]} \theta_{11}^{[2]} \frac{\partial A_{i1}^{[1]}}{\partial z_{i1}^{[1]}}$$

$$= = \delta_{i1}^{[2]} \theta_{11}^{[2]} \sigma'(z_{i1}^{[1]}) \Rightarrow \boxed{\delta_{i1}^{[1]} = (h_\theta(x_i) - y_i)\, \theta_{11}^{[2]} \sigma'(z_{i1}^{[1]})}$$

Ahora, por último, tenemos que los gradientes respecto a los parámetros de la primera capa:

$$\frac{\partial J_i}{\partial \theta_{11}^{[1]}} = \frac{\partial J_i}{\partial z_{i1}^{[1]}} \frac{\partial z_{i1}^{[1]}}{\partial \theta_{11}^{[1]}} = \delta_{i1}^{[1]} \frac{\partial z_{i1}^{[1]}}{\partial \theta_{11}^{[1]}} = \delta_{i1}^{[1]} x_i \Rightarrow$$

$$\Rightarrow \boxed{\frac{\partial J_i}{\partial \theta_{11}^{[1]}} = x_i (h_\theta(x_i) - y_i)\, \theta_{11}^{[2]} \sigma'(z_{i1}^{[1]})}$$

Por su parte, el gradiente respecto a $b_1^{[1]}$ es:

$$\frac{\partial J_i}{\partial b_1^{[1]}} = \frac{\partial J_i}{\partial z_{11}^{[1]}} \frac{\partial z_{i1}^{[1]}}{\partial b_1^{[1]}} = \delta_{i1}^{[1]} \Rightarrow \boxed{\frac{\partial J_i}{\partial b_1^{[1]}} = (h_\theta(x_i) - y_i)\theta_{11}^{[2]} \sigma'(z_{i1}^{[1]})}$$