Examen CCA — Soluciones

Universidad de Antioquia — Instituto de Física

30 de octubre

Índice

Punto 1 **1**

Punto 2 **4**

Soluciones analíticas de los puntos 3 y 4 **6**
Punto 3. Membrana vibrante y PINN 6
Punto 4. Memoria asociativa con energía log-sum-exp 9

Punto 1

a)

$$L(\theta) = \prod_{i=1}^{n} p(y_i \mid x_i; \theta) \Rightarrow L(\theta) = \prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}$$

donde $p(y_i \mid x_i; \theta)$ representa la probabilidad de observar exactamente y_i partículas cuando la condición experimental es x_i.

Como las detecciones correspondientes a distintas observaciones son independientes, se puede definir la verosimilitud como la probabilidad conjunta $P(y_1, \ldots, y_n \mid x_1, \ldots, x_n; \theta)$.

---

b) Ahora, queremos encontrar $\hat{\theta}_{MV}$ t.q.

$$\hat{\theta}_{MV} = \arg\max_{\theta^*} L(\theta)$$

o lo que es lo mismo

$$\hat{\theta}_{MV} = \arg\max_{\theta^*} \ell(\theta)$$

donde $\ell(\theta) = \log L(\theta)$. Entonces, calculando tenemos

$$\begin{aligned}\ell(\theta) &= \log\left(\prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right) = \sum_{i=1}^{n} \log\left(\frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right) \\ &= \sum_{i=1}^{n} \log\left(h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}\right) - \sum_{i=1}^{n} \log y_i! \\ &= \sum_{i=1}^{n} y_i \log h_\theta(x_i) - \sum_{i=1}^{n} h_\theta(x_i) - \sum_{i=1}^{n} \log y_i!\end{aligned}$$

$$\Rightarrow \boxed{\ell(\theta) = \sum_{i=1}^{n} \left[y_i \log h_\theta(x_i) - h_\theta(x_i) - \log y_i!\right]}$$

Ahora, el principio de máxima verosimilitud busca maximizar $\ell(\theta)$. Sin embargo, la optimización buscada para el modelo es en términos de minimización. Así, pasamos de maximizar a minimizar, definiendo

$$J(\theta) = -\ell(\theta) \Rightarrow J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \log h_\theta(x_i) + \log y_i!\right]$$

---

c) Ahora, si despreciamos el término independiente de los parámetros θ, tenemos que la función de coste es:

$$\boxed{J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \log h_\theta(x_i)\right]}$$

---

d) Ahora, calculemos $\nabla_\theta J(\theta)$ con $h_\theta(x_i) = \theta_0 + \theta_1 x_i$

$$\begin{aligned}\Rightarrow\ \partial_0 J &= \frac{\partial}{\partial \theta_0}\left[\sum_{i=1}^{n} (\theta_0 + \theta_1 x_i) - y_i \log(\theta_0 + \theta_1 x_i)\right] \\ &= \sum_{i=1}^{n}\left(1 - \frac{y_i}{\theta_0 + \theta_1 x_i}\right) \Rightarrow \boxed{\partial_0 J = \sum_{i=1}^{n}\left(1 - \frac{y_i}{h_\theta(x_i)}\right)}\end{aligned}$$

$$\begin{aligned}\Rightarrow\ \partial_1 J &= \frac{\partial}{\partial \theta_1}\left[\sum_{i=1}^{n} (\theta_0 + \theta_1 x_i) - y_i \log(\theta_0 + \theta_1 x_i)\right] \\ &= \sum_{i=1}^{n}\left(x_i - \frac{x_i y_i}{\theta_0 + \theta_1 x_i}\right) = \sum_{i=1}^{n} x_i\left(1 - \frac{y_i}{\theta_0 + \theta_1 x_i}\right) \Rightarrow \boxed{\partial_1 J = \sum_{i=1}^{n} x_i\left(1 - \frac{y_i}{h_\theta(x_i)}\right)}\end{aligned}$$

---

e) Por último, según el modelo $h_\theta(x_i)$ representa la tasa esperada de detecciones. Puede decirse que es el número esperado de partículas detectadas durante el intervalo de tiempo considerado. Se podría decir que $h_\theta(x) = \mathbb{E}[y \mid x; \theta]$.

Por su parte θ_0 representa las condiciones del detector cuando no hay presencia de partículas detectadas. Es algo intrínseco del detector, por ejemplo puede ser su sensibilidad. Todo esto se basa en el hecho de que $h_\theta(x_i = 0) = \theta_0$.

Por último, si hacemos $\dfrac{\partial h_\theta(x_i)}{\partial x_i} = \theta_1$. Así, θ_1 representa el cambio de la tasa esperada bajo el cambio de las condiciones experimentales. Es decir, θ_1 nos da cuenta de cómo cambia el flujo de partículas detectadas, cuando se cambian las condiciones experimentales detectadas.

Punto 2

a) Tenemos una red de una capa oculta con entrada escalar de salida positiva:

$$h_\theta(x_i) = e^{f_\theta(x_i)}$$

con

$$z_{i1}^{[1]} = \theta_{11}^{[1]} x_i + b_1^{[1]}, \qquad A_{i1}^{[1]} = \sigma\big(z_{i1}^{[1]}\big),$$
$$z_{i1}^{[2]} = \theta_{11}^{[2]} A_{i1}^{[1]} + b_1^{[2]}, \quad h_\theta(x_i) = e^{z_{i1}^{[2]}}$$

donde σ es función de activación diferenciable.

Para un dato (x_i, y_i) la función de coste de Poisson

$$J_i(\theta) = e^{z_{i1}^{[2]}} - y_i z_{i1}^{[2]}$$

Entonces, el error en la capa de salida es:

$$\delta_{i1}^{[2]} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} = e^{z_{i1}^{[2]}} - y_i = h_\theta(x_i) - y_i \Rightarrow \boxed{\delta_{i1}^{[2]} = h_\theta(x_i) - y_i}$$

---

b) Los gradientes respecto a los parámetros de la capa de salida son:

$$\frac{\partial J_i}{\partial \theta_{11}^{[2]}} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} \frac{\partial z_{i1}^{[2]}}{\partial \theta_{11}^{[2]}} = \delta_{i1}^{[2]} \frac{\partial z_{i1}^{[2]}}{\partial \theta_{11}^{[2]}}, \qquad \text{pero} \qquad \frac{\partial z_{i1}^{[2]}}{\partial \theta_{11}^{[2]}} = A_{i1}^{[1]}$$

$$\Rightarrow \quad \frac{\partial J_i}{\partial \theta_{11}^{[2]}} = \delta_{i1}^{[2]} A_{i1}^{[1]}$$

$$\Rightarrow \quad \frac{\partial J_i}{\partial \theta_{11}^{[2]}} = \delta_{i1}^{[2]} A_{i1}^{[1]} = \big(h_\theta(x_i) - y_i\big)\sigma\big(z_{i1}^{[1]}\big) \Rightarrow \boxed{\frac{\partial J_i}{\partial \theta_{11}^{[2]}} = \big(h_\theta(x_i) - y_i\big)\sigma\big(z_{i1}^{[1]}\big)}$$

Así mismo,

$$\frac{\partial J_i}{\partial b_1^{[2]}} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} \underbrace{\frac{\partial z_{i1}^{[2]}}{\partial b_1^{[2]}}}_{=1} = \delta_{i1}^{[2]} = h_\theta(x_i) - y_i$$

$$\Rightarrow \quad \boxed{\frac{\partial J_i}{\partial b_1^{[2]}} = h_\theta(x_i) - y_i}$$

---

c) Ahora, el error que se propaga hacia la capa oculta es:

$$\delta_{i1}^{[1]} = \frac{\partial J_i}{\partial z_{i1}^{[1]}} = \frac{\partial J_i}{\partial z_{i1}^{[2]}} \frac{\partial z_{i1}^{[2]}}{\partial A_{i1}^{[1]}} \frac{\partial A_{i1}^{[1]}}{\partial z_{i1}^{[1]}} = \delta_{i1}^{[2]} \frac{\partial z_{i1}^{[2]}}{\partial A_{i1}^{[1]}} \frac{\partial A_{i1}^{[1]}}{\partial z_{i1}^{[1]}} = \delta_{i1}^{[2]} \theta_{11}^{[2]} \frac{\partial A_{i1}^{[1]}}{\partial z_{i1}^{[1]}}$$
$$= \delta_{i1}^{[2]} \theta_{11}^{[2]} \sigma'\big(z_{i1}^{[1]}\big) \Rightarrow \boxed{\delta_{i1}^{[1]} = \big(h_\theta(x_i) - y_i\big)\theta_{11}^{[2]} \sigma'\big(z_{i1}^{[1]}\big)}$$

Ahora, por último, tenemos que los gradientes respecto a los parámetros de la primera capa:

$$\frac{\partial J_i}{\partial \theta_{11}^{[1]}} = \frac{\partial J_i}{\partial z_{i1}^{[1]}} \frac{\partial z_{i1}^{[1]}}{\partial \theta_{11}^{[1]}} = \delta_{i1}^{[1]} \frac{\partial z_{i1}^{[1]}}{\partial \theta_{11}^{[1]}} = \delta_{i1}^{[1]} x_i$$

$$\Rightarrow \boxed{\frac{\partial J_i}{\partial \theta_{11}^{[1]}} = x_i \big(h_\theta(x_i) - y_i\big) \theta_{11}^{[2]} \sigma'\big(z_{i1}^{[1]}\big)}$$

Por su parte, el gradiente respecto a $b_1^{[1]}$ es:

$$\frac{\partial J_i}{\partial b_1^{[1]}} = \frac{\partial J_i}{\partial z_{i1}^{[1]}} \frac{\partial z_{i1}^{[1]}}{\partial b_1^{[1]}} = \delta_{i1}^{[1]} \Rightarrow \boxed{\frac{\partial J_i}{\partial b_1^{[1]}} = \big(h_\theta(x_i) - y_i\big) \theta_{11}^{[2]} \sigma'\big(z_{i1}^{[1]}\big)}$$

Soluciones analíticas de los puntos 3 y 4

La parte computacional de estos puntos está en los notebooks `ejercicio_3_pinn_membrana.ipynb` y `ejercicio_4_memoria_asociativa.ipynb`.

Punto 3. Membrana vibrante y PINN

a) Tenemos una PINN de la forma

$$U_\theta(x, y, t) = \phi(x, y)\, a_\theta(t), \qquad \phi(x, y) = \sin(\pi x)\sin(\pi y),$$

donde ϕ se anula en $x = 0, 1$ y en $y = 0, 1$. Así, la condición de borde $U = 0$ se cumple para cualquier valor de θ, en ambos modelos.

Ahora, calculando las derivadas de U_θ tenemos

$$\frac{\partial^2 U_\theta}{\partial t^2} = \phi\, a''_\theta(t), \qquad \frac{\partial^2 U_\theta}{\partial x^2} = -\pi^2 \phi\, a_\theta(t), \qquad \frac{\partial^2 U_\theta}{\partial y^2} = -\pi^2 \phi\, a_\theta(t).$$

Entonces, sustituyendo en la ecuación de ondas

$$\phi\, a''_\theta = -2\pi^2 \phi\, a_\theta \Rightarrow \phi(x, y)\left[a''_\theta(t) + 2\pi^2 a_\theta(t)\right] = 0$$

y como $\phi \neq 0$ en el interior de la membrana,

$$\Rightarrow \boxed{a''(t) + \kappa^2 a(t) = 0, \qquad \kappa^2 = 2\pi^2}$$

Por su parte, las condiciones iniciales quedan

$$U(x, y, 0) = \phi\, a(0) = \phi \Rightarrow a(0) = 1, \qquad U_t(x, y, 0) = \phi\, a'(0) = \sqrt{2\pi}\,\phi \Rightarrow a'(0) = \sqrt{2\pi} \equiv v_0.$$

Así, la ecuación de ondas se reduce al problema de valor inicial

$$\boxed{a'' + \kappa^2 a = 0, \qquad a(0) = 1, \qquad a'(0) = v_0}$$

cuya solución analítica es $a(t) = \cos(\omega t) + \dfrac{v_0}{\omega}\sin(\omega t)$, con $\omega = \kappa = \sqrt{2}\,\pi$. Con esta solución se comparan los dos modelos en la parte computacional.

---

b) Ahora, calculemos las derivadas de las neuronas.

Para el Modelo A, con $\theta = (A_1, \omega_1, b_1, A_2, \omega_2, b_2)$, cada neurona es $\sin(\omega_j t + b_j)$, de modo que

$$\frac{d}{dt}\sin(\omega_j t + b_j) = \omega_j \cos(\omega_j t + b_j), \qquad \frac{d^2}{dt^2}\sin(\omega_j t + b_j) = -\omega_j^2 \sin(\omega_j t + b_j)$$

$$\Rightarrow \boxed{a'_\theta(t) = \sum_{j=1}^{2} A_j \omega_j \cos(\omega_j t + b_j), \qquad a''_\theta(t) = -\sum_{j=1}^{2} A_j \omega_j^2 \sin(\omega_j t + b_j)}$$

Para el Modelo B, con $\theta = (\omega_1, b_1, \omega_2, b_2, A)$, la neurona de la primera capa es $h_1(t) = \sin(\omega_1 t + b_1)$

$$\Rightarrow\ h_1'(t) = \omega_1 \cos(\omega_1 t + b_1), \qquad h_1''(t) = -\omega_1^2 \sin(\omega_1 t + b_1) = -\omega_1^2 h_1(t).$$

Ahora, la neurona de salida es $a_\theta = A \sin z$, con $z(t) = \omega_2 h_1(t) + b_2$, de modo que $z' = \omega_2 h_1'$ y $z'' = \omega_2 h_1''$. Entonces, por la regla de la cadena,

$$a_\theta' = A \cos z\ z' = A\,\omega_2\,h_1' \cos z \Rightarrow \boxed{a_\theta'(t) = A\,\omega_1\omega_2 \cos(\omega_1 t + b_1)\cos z}$$

$$a_\theta'' = A\left[z'' \cos z - (z')^2 \sin z\right] = A\left[\omega_2 h_1'' \cos z - \omega_2^2 (h_1')^2 \sin z\right]$$
$$\Rightarrow \boxed{a_\theta''(t) = -A\,\omega_1^2\omega_2\left[\sin(\omega_1 t + b_1)\cos z + \omega_2 \cos^2(\omega_1 t + b_1)\sin z\right]}$$

---

c) Ahora, el residuo de la PINN en la ecuación de ondas es

$$\mathcal{R}_\theta(x, y, t) = \frac{\partial^2 U_\theta}{\partial t^2} - \frac{\partial^2 U_\theta}{\partial x^2} - \frac{\partial^2 U_\theta}{\partial y^2} = \phi(x, y)\left[a_\theta''(t) + \kappa^2 a_\theta(t)\right].$$

Como ϕ está fija, el residuo físico se define sobre la amplitud:

$$\boxed{r_\theta(t) = a_\theta''(t) + \kappa^2 a_\theta(t)}$$

el cual se anula si y sólo si U_θ cumple la ecuación de ondas. De la misma forma, $U_\theta(x, y, 0) - U(x, y, 0) = \phi\,[a_\theta(0) - 1]$ y $\partial_t U_\theta(x, y, 0) - U_t(x, y, 0) = \phi\,[a_\theta'(0) - v_0]$, así que las condiciones iniciales también se imponen sobre a_θ.

Entonces, con N_c puntos de colocación $\{t_k\}_{k=1}^{N_c} \subset [0, T]$ y pesos $\lambda_0, \lambda_1 > 0$, la función de pérdida es

$$\boxed{\mathcal{L}(\theta) = \frac{1}{N_c}\sum_{k=1}^{N_c} r_\theta(t_k)^2 + \lambda_0\left[a_\theta(0) - 1\right]^2 + \lambda_1\left[a_\theta'(0) - v_0\right]^2}$$

donde el primer término penaliza que no se cumpla la ecuación y los otros dos que no se cumplan las condiciones iniciales. Sin estos dos últimos, $a_\theta \equiv 0$ haría $\mathcal{L} = 0$.

Para el Modelo A, sustituyendo a_θ y a_θ'',

$$r_A(t) = -\sum_{j=1}^{2} A_j \omega_j^2 \sin(\omega_j t + b_j) + \kappa^2 \sum_{j=1}^{2} A_j \sin(\omega_j t + b_j) \Rightarrow \boxed{r_A(t) = \sum_{j=1}^{2} A_j\left(\kappa^2 - \omega_j^2\right)\sin(\omega_j t + b_j)}$$

y en $t = 0$, $a_\theta(0) = \sum_j A_j \sin b_j$ y $a_\theta'(0) = \sum_j A_j \omega_j \cos b_j$

$$\Rightarrow \boxed{\begin{aligned}\mathcal{L}_A(\theta) = \frac{1}{N_c}\sum_{k=1}^{N_c}&\left[\sum_{j=1}^{2} A_j\left(\kappa^2 - \omega_j^2\right)\sin(\omega_j t_k + b_j)\right]^2 \\ &+ \lambda_0\left[\sum_{j=1}^{2} A_j \sin b_j - 1\right]^2 + \lambda_1\left[\sum_{j=1}^{2} A_j \omega_j \cos b_j - v_0\right]^2\end{aligned}}$$

Así mismo, para el Modelo B, sustituyendo a_θ y a''_θ,

$$\boxed{r_B(t) = A\left[\left(\kappa^2 - \omega_1^2\omega_2^2\cos^2(\omega_1 t + b_1)\right)\sin z - \omega_1^2\omega_2\sin(\omega_1 t + b_1)\cos z\right]}$$

con $z = \omega_2\sin(\omega_1 t + b_1) + b_2$, y en $t = 0$, con $z_0 = \omega_2\sin b_1 + b_2$, $a_\theta(0) = A\sin z_0$ y $a'_\theta(0) = A\,\omega_1\omega_2\cos b_1\cos z_0$

$$\Rightarrow \quad \boxed{\mathcal{L}_B(\theta) = \frac{1}{N_c}\sum_{k=1}^{N_c} r_B(t_k)^2 + \lambda_0\left[A\sin z_0 - 1\right]^2 + \lambda_1\left[A\,\omega_1\omega_2\cos b_1\cos z_0 - v_0\right]^2}$$

Punto 4. Memoria asociativa con energía log-sum-exp

a) Ahora, definamos el solapamiento del estado q con el patrón μ y la función de partición

$$m_\mu(q) = \sum_{j=1}^{N} x_{\mu j} q_j = (Xq)_\mu, \qquad Z(q) = \sum_{\mu=1}^{P} e^{\beta m_\mu(q)},$$

de modo que $E(q) = \dfrac{1}{2}\sum_{j=1}^{N} q_j^2 - \dfrac{1}{\beta}\ln Z(q)$.

Entonces, calculando la derivada respecto a q_i de cada término tenemos

$$\frac{\partial}{\partial q_i}\left(\frac{1}{2}\sum_{j=1}^{N} q_j^2\right) = q_i, \qquad \frac{\partial m_\mu}{\partial q_i} = x_{\mu i},$$

y, por la regla de la cadena,

$$\begin{aligned}\frac{\partial}{\partial q_i}\left(\frac{1}{\beta}\ln Z\right) &= \frac{1}{\beta Z}\sum_{\mu=1}^{P}\frac{\partial}{\partial q_i}e^{\beta m_\mu} = \frac{1}{\beta Z}\sum_{\mu=1}^{P}\beta\, x_{\mu i}\, e^{\beta m_\mu} \\ &= \sum_{\mu=1}^{P} x_{\mu i}\frac{e^{\beta m_\mu}}{\sum_{\nu=1}^{P} e^{\beta m_\nu}}.\end{aligned}$$

Ahora, si definimos los pesos

$$p_\mu(q) = \frac{e^{\beta m_\mu(q)}}{\sum_{\nu=1}^{P} e^{\beta m_\nu(q)}} = \operatorname{softmax}\big(\beta X q\big)_\mu, \qquad p_\mu > 0, \quad \sum_{\mu=1}^{P} p_\mu = 1,$$

tenemos que

$$\Rightarrow \boxed{\frac{\partial E}{\partial q_i} = q_i - \sum_{\mu=1}^{P} x_{\mu i}\, p_\mu(q)}$$

Por tanto, el gradiente es

$$\boxed{\nabla_q E(q) = q - X^\top \operatorname{softmax}\big(\beta X q\big)}$$

Es decir, el gradiente compara el estado q con el promedio $\sum_\mu p_\mu x_\mu$ de los patrones almacenados, ponderado por la similitud de cada uno con q.

---

b) Ahora, sustituyendo el gradiente en la regla del descenso de gradiente,

$$q_i^{(t+1)} = q_i^{(t)} - \alpha\left.\frac{\partial E}{\partial q_i}\right|_{q=q^{(t)}} = q_i^{(t)} - \alpha\left[q_i^{(t)} - \sum_{\mu=1}^{P} x_{\mu i}\, p_\mu\big(q^{(t)}\big)\right]$$

$$\Rightarrow \boxed{q_i^{(t+1)} = (1-\alpha)\, q_i^{(t)} + \alpha\sum_{\mu=1}^{P} x_{\mu i}\frac{\exp\left[\beta\sum_j x_{\mu j} q_j^{(t)}\right]}{\sum_{\nu=1}^{P}\exp\left[\beta\sum_j x_{\nu j} q_j^{(t)}\right]}}$$

o, en forma vectorial, $q^{(t+1)} = (1-\alpha)\, q^{(t)} + \alpha X^\top \operatorname{softmax}\left(\beta X q^{(t)}\right)$.

---

c) Si consideramos $\alpha = 1$, el término $(1-\alpha)q^{(t)}$ se anula y tenemos

$$\boxed{q_i^{(t+1)} = \sum_{\mu=1}^{P} x_{\mu i}\, p_\mu\big(q^{(t)}\big), \qquad q^{(t+1)} = X^\top \operatorname{softmax}\left(\beta X q^{(t)}\right)}$$

Es decir, el nuevo estado es un promedio ponderado de los patrones almacenados, con pesos $p_\mu(q^{(t)})$ que suman uno y que dependen del solapamiento $m_\mu(q^{(t)})$ de cada patrón con el estado actual. La contribución relativa de dos patrones es

$$\frac{p_\mu}{p_\nu} = \exp\left[\beta\,(m_\mu - m_\nu)\right],$$

de modo que β multiplica las diferencias de solapamiento y controla la selectividad de la recuperación.

Ahora, si β es pequeño ($\beta|m_\mu - m_\nu| \ll 1$), desarrollando la exponencial a primer orden en β, con $\bar{m} = \frac{1}{P}\sum_\nu m_\nu$, tenemos

$$p_\mu = \frac{1 + \beta m_\mu + O(\beta^2)}{P + \beta \sum_\nu m_\nu + O(\beta^2)} \approx \frac{1}{P}\left[1 + \beta\,(m_\mu - \bar{m})\right]$$

$$\Rightarrow\ q^{(t+1)} \approx \bar{x} + \frac{\beta}{P}\sum_{\mu=1}^{P}(m_\mu - \bar{m})\, x_\mu, \qquad \bar{x} = \frac{1}{P}\sum_{\mu=1}^{P} x_\mu.$$

Así, todos los patrones contribuyen casi por igual ($p_\mu \to 1/P$ cuando $\beta \to 0$) y el estado actual sólo influye con peso β. Por tanto, la red devuelve una mezcla de las memorias, el promedio $\bar{x}$, en lugar de recuperar un patrón individual.

Por su parte, si β es grande, sea $\mu^* = \arg\max_\mu m_\mu(q^{(t)})$, que suponemos único, y $\Delta_\nu = m_{\mu^*} - m_\nu > 0$ para $\nu \neq \mu^*$. Dividiendo numerador y denominador por $e^{\beta m_{\mu^*}}$ tenemos

$$p_\nu = \frac{e^{-\beta\Delta_\nu}}{1 + \sum_{\nu' \neq \mu^*} e^{-\beta\Delta_{\nu'}}} \leq e^{-\beta\Delta_\nu} \xrightarrow[\beta\to\infty]{} 0, \qquad p_{\mu^*} \xrightarrow[\beta\to\infty]{} 1$$

$$\Rightarrow\ q^{(t+1)} = x_{\mu^*} + \sum_{\nu\neq\mu^*} p_\nu\,(x_\nu - x_{\mu^*}) \xrightarrow[\beta\to\infty]{} x_{\mu^*}.$$

Es decir, el softmax tiende a un vector *one-hot*: sólo contribuye el patrón con mayor solapamiento con el estado actual, y la red lo recupera en un solo paso, con correcciones exponencialmente pequeñas en β. Como para un estado binario $m_\mu = (N - d_H) - d_H = N - 2d_H(x_\mu, q)$, donde d_H es la distancia de Hamming, ese patrón es el más cercano a q. Si varios patrones empatan en el solapamiento máximo, se reparten el peso por igual.

Por último, β controla el paso de una recuperación que promedia todas las memorias (β pequeño) a una recuperación selectiva del patrón más parecido al estado (β grande).