UNIVERSIDAD DE ANTIOQUIA
1803

Universidad de Antioquia
Facultad de Ciencias Exactas y Naturales
Instituto de Física
Examen, 30 Octubre, CCA

Nombre: Eduardo Henao Restrepo Cédula: 1039453805

1. (20%)Considere un detector que registra el número de partículas que llegan a su superficie durante intervalos de tiempo fijos. Se asume que las detecciones ocurren de manera independiente y que la tasa esperada de llegada depende de una condición experimental x_i, por ejemplo la intensidad de la fuente, la distancia al detector o el tiempo de exposición.

   Bajo estas hipótesis, el número de eventos observados y_i se modela como una variable aleatoria de Poisson:

$$p(y_i \mid x_i; \theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}, \qquad y_i = 0, 1, 2, \ldots \tag{1}$$

   donde $h_\theta(x_i)$ representa la tasa esperada de detecciones. En este primer modelo, suponga que la tasa depende linealmente de x_i:

$$h_\theta(x_i) = \theta_0 + \theta_1 x_i. \tag{2}$$

   Como $h_\theta(x_i)$ representa una tasa física, se debe cumplir que

$$h_\theta(x_i) > 0 \tag{3}$$

   para todos los datos observados.

   (a) Construya la función de verosimilitud $L(\theta)$ para un conjunto de datos independientes $\{(x_i, y_i)\}_{i=1}^n$.

   (b) Determine la log-verosimilitud $\ell(\theta)$ y obtenga la función de coste asociada al principio de máxima verosimilitud.

   (c) Muestre que, salvo constantes independientes de θ, la función de coste puede escribirse como

$$J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \log h_\theta(x_i) \right]. \tag{4}$$

   (d) Usando $h_\theta(x_i) = \theta_0 + \theta_1 x_i$, calcule el gradiente de $J(\theta)$ respecto a θ_0 y θ_1.

   (e) Interprete físicamente $h_\theta(x)$, θ_0 y θ_1 en el contexto del detector.

2. (20%) Backward pass. Considere una red neuronal de una capa oculta que recibe una entrada escalar x_i y produce una tasa esperada de conteos mediante una salida positiva:

$$h_\theta(x_i) = \exp(f_\theta(x_i)). \tag{5}$$

La red está definida por:

$$Z_{i,1}^{[1]} = \theta_{1,1}^{[1]} x_i + b_1^{[1]}, \tag{6}$$

$$A_{i,1}^{[1]} = \sigma\left(Z_{i,1}^{[1]}\right), \tag{7}$$

$$Z_{i,1}^{[2]} = \theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}, \tag{8}$$

$$h_\theta(x_i) = \exp\left(Z_{i,1}^{[2]}\right). \tag{9}$$

donde σ es una función de activación diferenciable. Para un dato (x_i, y_i), la función de coste de Poisson, salvo constantes independientes de θ, es

$$J_i(\theta) = h_\theta(x_i) - y_i \log h_\theta(x_i). \tag{10}$$

Como $h_\theta(x_i) = \exp\left(Z_{i,1}^{[2]}\right)$, esta función puede escribirse como

$$J_i(\theta) = \exp\left(Z_{i,1}^{[2]}\right) - y_i Z_{i,1}^{[2]}. \tag{11}$$

(a) Calcule el error en la capa de salida:

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}}. \tag{12}$$

(b) Calcule los gradientes respecto a los parámetros de la capa de salida:

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}}, \qquad \frac{\partial J_i}{\partial b_1^{[2]}}. \tag{13}$$

(c) Calcule el error que se propaga hacia la capa oculta:

$$\delta_{i,1}^{[1]} = \frac{\partial J_i}{\partial Z_{i,1}^{[1]}} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}} \frac{\partial Z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} \frac{\partial A_{i,1}^{[1]}}{\partial Z_{i,1}^{[1]}}. \tag{14}$$

(d) Calcule los gradientes respecto a los parámetros de la primera capa:

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}}, \qquad \frac{\partial J_i}{\partial b_1^{[1]}}. \tag{15}$$

3. (30%) Considere una membrana cuadrada de lado unitario, con bordes fijos, cuyos desplazamientos transversales (U(x,y,t)), respecto a su posición de equilibrio, están descritos, en el régimen de pequeñas oscilaciones, por la ecuación de ondas adimensional:

$$\frac{\partial^2 U}{\partial t^2} = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2}$$

con $U = 0$ en los bordes y condiciones iniciales

$$U(x, y, 0) = \sin(\pi x)\sin(\pi y),$$

$$U_t(x, y, 0) = \sqrt{2}\pi \sin(\pi x)\sin(\pi y).$$

Aproxime el desplazamiento $U(x, y, t)$ mediante una PINN de la forma

$$U_\theta(x, y, t) = \sin(\pi x)\sin(\pi y)a_\theta(t).$$

donde $a_\theta(t)$ se representa mediante las siguientes arquitecturas:

Modelo A. Una capa con dos neuronas de activación sinusoidal:

$$a_\theta(t) = \sum_{j=1}^{2} A_j \sin(w_j t + b_j).$$

Modelo B. Dos capas consecutivas, con una neurona por capa:

$$h_1(t) = \sin(w_1 t + b_1),$$

$$a_\theta(t) = A \sin(w_2 h_1(t) + b_2).$$

Parte analítica. Para ambas arquitecturas, reducir la ecuación de ondas a una ecuación diferencial ordinaria, calcular analíticamente las derivadas de las neuronas y construir el residuo físico y la función de pérdida, incorporando las condiciones iniciales.

Parte computacional. Implementar en Python ambas arquitecturas y minimizar sus funciones de pérdida mediante un método de optimización. Comparar gráficamente las soluciones obtenidas con la solución analítica, cuantificar los errores de aproximación y analizar la conservación de la energía mecánica de la membrana. Analice todos los resultados.

Ayuda: La energía mecánica total se conserva:

$$E(t) = \frac{1}{2}\int_0^1 \int_0^1 \left[\left(\frac{\partial U}{\partial t}\right)^2 + \left(\frac{\partial U}{\partial x}\right)^2 + \left(\frac{\partial U}{\partial y}\right)^2\right] dx\, dy.$$

$$\frac{dE}{dt} = 0.$$

4. (30%) Considere una red de memoria asociativa formada por N neuronas que almacena P patrones binarios. Cada patrón se representa mediante un vector de N componentes, cuyos valores son $+1$ o -1. Los patrones almacenados se organizan en una matriz X de tamaño $P \times N$, cuyos elementos son

$$x_{\mu i} \in \{-1, +1\},$$

donde $\mu = 1, \ldots, P$ identifica el patrón almacenado e $i = 1, \ldots, N$ identifica la neurona.

El estado de la red se describe mediante un vector $\mathbf{q} = (q_1, \ldots, q_N)$, donde $q_i \in \mathbb{R}$ representa el estado de la neurona i. Inicialmente, la red recibe un patrón binario $\mathbf{q}^{(0)}$, que puede contener errores respecto a uno de los patrones almacenados.

La recuperación de la memoria se realiza mediante la minimización de la función de energía

$$E(\mathbf{q}) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln \left(\sum_{\mu=1}^{P} \exp \left[\beta \sum_{i=1}^{N} x_{\mu i} q_i \right] \right)$$

donde $\beta > 0$ es un parámetro que controla la selectividad de la recuperación. Durante la evolución de la red, los valores q_i pueden ser continuos, aunque los patrones almacenados sean binarios.

Parte analítica

- Calcular las derivadas parciales de la energía respecto a cada componente q_i y obtener la expresión del gradiente.
- A partir del descenso de gradiente, deducir la regla de actualización:

$$q_i^{(t+1)} = q_i^{(t)} - \alpha \left. \frac{\partial E}{\partial q_i} \right|_{\mathbf{q}=\mathbf{q}^{(t)}},$$

  donde $\alpha > 0$ es el tamaño del paso de actualización y $t = 0, 1, 2, \ldots$ representa el número de iteración.
- Considerar el caso $\alpha = 1$ y simplificar la regla de actualización. Analizar cómo influye el parámetro β en la contribución de los diferentes patrones almacenados, considerando valores pequeños y grandes.

Parte computacional

- Implementar en Python una red de memoria asociativa que almacene dos patrones binarios correspondientes a las letras J y H, representados mediante imágenes de 8×8 píxeles. Cada patrón contiene $N = 64$ componentes, donde $+1$ representa un píxel activo y -1 uno inactivo. Organizar los patrones en una matriz X de tamaño 2×64.
- Seleccionar uno de los patrones almacenados y generar un estado inicial perturbado mediante la inversión aleatoria de un porcentaje de sus píxeles. Implementar iterativamente la regla de actualización obtenida en la parte analítica, utilizando $\alpha = 1$, hasta alcanzar la convergencia o un número máximo de iteraciones.
- Desarrollar experimentos computacionales que permitan:
  (a) Visualizar el patrón original, el patrón perturbado y el estado final de la red, tanto en su representación continua como binaria.
  (b) Estudiar cómo cambia la recuperación al modificar el porcentaje de píxeles perturbados. Realizar varias perturbaciones aleatorias para cada porcentaje y evaluar la calidad de la recuperación.
  (c) Analizar cómo influye el parámetro β en la evolución de la energía y en los estados finales de la red. Interpretar los resultados obtenidos.

Ayuda: Para evaluar la recuperación, convertir el estado final en un patrón binario según el signo de cada componente y calcular el porcentaje de píxeles que coinciden con el patrón original.

Eduardo Henao R
1039453805

1.

Supongamos que las observaciones $\{(X_i, Y_i)\}_{i=1}^{n}$ son estadisticamente independientes siguiendo una distribucion poisoniana la verosimilitud es solo el producto de las probalilidades

$$L(\theta) = \prod_{i=1}^{n} p(Y_i | X_i, \theta) = \prod_{i=1}^{n} \frac{h_\theta(X_i)^{Y_i} e^{-h_\theta(X_i)}}{Y_i!}$$

dado la asunsión Naive Bayes y $h_\theta(X_i) = \theta_0 + \theta_1 X_i > 0$

Luego la log-verosimilitud me convierte la productoria en sumatoria

$$\ell(\theta) = Ln\left[L(\theta)\right] = Ln\left[\prod_{i=1}^{n} \frac{h_\theta(X_i)^{Y_i} e^{-h_\theta(X_i)}}{Y_i!}\right]$$

$$= \sum_{i=1}^{n}\left[Y_i Ln\, h_\theta(X_i) - h_\theta(X_i) - Ln(Y_i!)\right]$$

De acuerdo con (EMV / MLE), maximizar $\ell(\theta)$ equivale a minimizar $-\ell(\theta)$ y se ignoran terminos independientes

$$\hat{\Theta}_{MLE} = \arg\max_{\theta\in\Theta}\left[\ell(\theta)\right] \Longleftrightarrow \arg\min_{\theta\in\Theta}\left[-\ell(\theta)\right], \quad \frac{\partial[Ln(Y_i!)]}{\partial\theta} = 0$$

Se define $J(\theta) := \sum_{i=1}^{n}\left[h_\theta(X_i) - Y_i Ln\, h_\theta(X_i)\right]$

Su gradiente es

$$\frac{\partial J}{\partial\theta_K} = \sum_{i=1}^{n}\frac{\partial}{\partial\theta_K}\left[h_\theta(X_i) - Y_i Ln\, h_\theta(X_i)\right] = \sum_{i=1}^{n}\left[1 - \frac{Y_i}{h_\theta(X_i)}\right]\frac{\partial h_\theta(X_i)}{\partial\theta_K}$$

$$\frac{\partial h_\theta(X_i)}{\partial\theta_K} = \frac{\partial}{\partial\theta_K}\left[\theta_0 + \theta_1 X_i\right] \Rightarrow \begin{cases} \dfrac{\partial h_\theta(X_i)}{\partial\theta_0} = 1 \\ \dfrac{\partial h_\theta(X_i)}{\partial\theta_1} = X_i \end{cases}$$

$h_\theta(0) = \theta_0$

h_θ representa la tasa de cuentas esperada segun el modelo

Si la condicion experimental X es nula, sin una tasa de fondo θ_0, el modelo no seria bueno ya que

también sería nulo: $\theta_0 = 0 \Rightarrow h_\theta(x_i = 0) = 0$

En cuanto a θ_1, representa una constante de proporcionalidad de primer orden de comportamiento lineal de la condición experimental x_i. Definir $h_\theta(x_i) = \theta_0 + \theta_1 x_i$ describe un hiperplano de la forma más general

$$\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n} \left[\left(\frac{\theta_0 + \theta_1 x_i}{\theta_0 + \theta_1 x_i} \right) - \left(\frac{y_i}{\theta_0 + \theta_1 x_i} \right) \right] = \sum_{i=1}^{n} \left[\frac{\theta_0 + \theta_1 x_i - y_i}{\theta_0 + \theta_1 x_i} \right]$$

$$\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} x_i \left[\frac{\theta_0 + \theta_1 x_i - y_i}{\theta_0 + \theta_1 x_i} \right]$$

2.

$$P(Y = y_i | x_i) = \left[h_\theta(x_i)^{y_i} \exp(-h_\theta(x_i)) \right] / y_i!$$

$$-\ln P(Y = y_i | x_i) = -y_i \ln h_\theta(x_i) + h_\theta(x_i) + \underbrace{\ln(y_i!)}_{\to \nabla \cdot = 0}$$

Definimos J_i

$$J_i(\theta) = \underbrace{h_\theta(x_i)}_{\exp[z_{i,1}^{[2]}]} - y_i \underbrace{\ln h_\theta(x_i)}_{[z_{i,1}^{[2]}]} = \exp\left[z_{i,1}^{[2]} \right] - y_i z_{i,1}^{[2]}$$

$$\eta_{i,1} = z_{i,1}^{[2]} = \ln h_\theta(x_i) = \ln\left(\frac{p_i}{1 - p_i} \right)$$

Se conoce como un Log-momio

$p \equiv P(y = 1 | x_i)$

Error de salida

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial \eta_{i,1}} = \frac{\partial}{\partial \eta_{i,1}} \left[e^{\eta_{i,1}} - y_i \eta_{i,1} \right] = e^{\eta_{i,1}} - y_i$$

$$= h_\theta(x_i) - y_i$$

Eduardo Heras R

Eduardo Henao R
1039453805

- Gradiente capa de salida

$$Z_{i,1}^{[2]} = \Theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}, \quad Z_{i,1}^{[1]} = \Theta_{1,1}^{[1]} X_1 + b_1^{[1]}$$

$$\frac{\partial J_i}{\partial \Theta_{1,1}^{[2]}} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}} \cdot \frac{\partial Z_{i,1}^{[2]}}{\partial \Theta_{1,1}^{[2]}} = \delta_{i,1}^{[2]} A_{i,1}^{[1]} = \left[h_\theta(x_i) - y_i \right] \sigma(\eta_{i,1})$$

$$\frac{\partial J_{1,1}^{[2]}}{\partial b_1^{[2]}} = \frac{\partial J_1}{\partial Z_{i,1}^{[2]}} \cdot \underbrace{\frac{\partial Z_{i,1}^{[2]}}{\partial b_1^{[2]}}}_{=1} = \delta_{i,1}^{[2]} = h_\theta(x_i) - y_i$$

- backward pass, Error propagado hacia la capa oculta

$$\delta_{i,1}^{[1]} = \frac{\partial J_i}{\partial Z_{i,1}^{[1]}} = \underbrace{\left[\frac{\partial J_i}{\partial Z_{i,1}} \right]}_{\delta_{i,1}^{[2]}} \underbrace{\left[\frac{\partial Z_{i,1}^{[2]}}{\partial A_{i,1}} \right]}_{\Theta_{1,1}^{[2]}} \underbrace{\left[\frac{\partial A^{[1]}_{i,1}}{\partial Z_{i,1}^{[1]}} \right]}_{\sigma'(\eta_{i,1})}$$ regla de la cadena

$$\delta_{i,1}^{[1]} = \delta_{i,1}^{[2]} \Theta_{i,1}^{[2]} \sigma'(\eta_{1,1}) = \left[h_\theta(x_i) - y_i \right] \Theta_{1,1}^{[2]} \sigma'\left(Z_{i,1}^{[1]} \right)$$

- Gradiente capa de entrada

$$Z_{i,1}^{[1]} = \Theta_{1,1}^{[1]} X_i + b_1^{[1]}$$

$$\frac{\partial J_i}{\partial \Theta_{1,1}^{[1]}} = \left[\frac{\partial J_i}{\partial Z_{i,1}^{[1]}} \right] \left[\frac{\partial Z_{i,1}^{[1]}}{\partial \Theta_{1,1}} \right] = \delta_{i,1}^{[1]} X_i = \left[h_\theta(x_i) - y_i \right] \Theta_{1,1}^{[2]} \sigma'\left(Z_{i,1}^{[1]} \right) X_i$$

$$\frac{\partial J_i}{\partial b_1^{[1]}} = \left[\frac{\partial J_i}{\partial b_1^{[1]}} \right] \underbrace{\left[\frac{\partial Z_{i,1}^{[1]}}{\partial b_1^{[1]}} \right]}_{=1} = \delta_{i,1}^{[1]} = \left[h_\theta(x_i) - y_i \right] \Theta_{1,1}^{[2]} \sigma'\left(Z_{i,1}^{[1]} \right)$$

3.

$$\frac{\partial^2 U(x,y,t)}{\partial t^2} = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2}$$

$$\begin{cases} U = 0 \text{ nulo en los bordes} \\ U(x,y,0) = \sin(\pi x)\sin(\pi y) \\ U_t = \sqrt{2}\pi U(x,y,0) \\ U_\theta(x,y,t) = U(x,y,0)\, a_\theta(t) \end{cases}$$

Membrana Cuadrada (Matiz)

Asumimos condicion de frontera para la funcion de perdida

Frontera $[U_\theta = 0,\ J = 0]\ \forall x, y \in \{0,1\}$

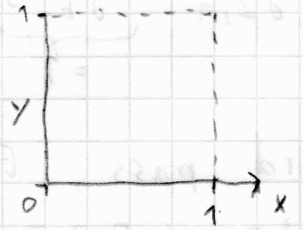

$$a_\theta(t) = \begin{cases} \bullet = \sum_{j=1}^{2} A_j \sin(w_j t + b_j) & \text{dos neuronas} \\ \bullet = A\sin[w_2 h_1(t) + b_2], \quad h_1(t) = \sin[w_1 t + b_1] \end{cases}$$

dos capas con una neurona por capa

$$\frac{\partial U_\theta}{\partial t} = \sin(\pi x)\sin(\pi y)\,\dot{a}_\theta(t), \qquad \frac{\partial^2 U_\theta}{\partial t^2} = \sin(\pi x)\sin(\pi y)\,\ddot{a}_\theta(t)$$

$$\frac{\partial U_\theta}{\partial x} = \pi\cos(\pi x)\sin(\pi y)\,a_\theta(t), \qquad \frac{\partial^2 U_\theta}{\partial x^2} = -\pi^2\sin(\pi x)\sin(\pi y)\,a_\theta(t)$$

$$\frac{\partial U_\theta}{\partial y} = \pi\sin(\pi x)\cos(\pi y)\,a_\theta(t), \qquad \frac{\partial^2 U_\theta}{\partial y^2} = -\pi^2\sin(\pi x)\sin(\pi y)\,a_\theta(t)$$

Luego:

$$\sin(\pi x)\sin(\pi y)\,\ddot{a}_\theta(t) = -2\pi^2\sin(\pi x)\sin(\pi y)\,a_\theta(t)$$

Entonces

$$[\sin(\pi x)\sin(\pi y)]\,[\ddot{a}_\theta(t) + 2\pi^2 a_\theta(t)] = 0$$

Para un oscilador armonico simple se cumple

$$\ddot{a}_\theta(t) + w_o^2\, a_\theta(t) = 0 \Rightarrow w_o^2 \equiv 2\pi^2 \rightarrow w_o = \sqrt{2}\pi$$

Condiciones iniciales

$$U_\theta(x,y,0) = \sin(\pi x)\sin(\pi y)\,a_\theta(0) = \overbrace{\sin(\pi x)\sin(\pi y)}^{U(x,y,0)} \Rightarrow a_\theta(0) = 1$$

$$\frac{\partial U_\theta}{\partial t}(x,y,0) = \sin(\pi x)\sin(\pi y)\,\dot{a}_\theta(0) = \underbrace{\sqrt{2}\pi\sin(\pi x)\sin(\pi y)}_{U_t = \sqrt{2}\pi U(x,y,0)} \Rightarrow \dot{a}_\theta(0) = \sqrt{2}\pi$$

Eduardo Henao R

Eduardo Hendo R
7039453805

La energía mecánica se conserva $\frac{dE(t)}{dt} = 0$

$$\int_0^1 \sin^2(\pi z)\,dz = \frac{1}{2}$$

$$\int_0^1 \cos^2(\pi z)\,dz = \frac{1}{2}$$

ortonormalidad en $[0,1]$

$$E_\theta(t) = \frac{1}{2}\int_0^1\int_0^1 \left[\left(\frac{\partial U}{\partial x}\right)^2 + \left(\frac{\partial U}{\partial y}\right)^2 + \left(\frac{\partial U}{\partial t}\right)^2\right] dx\,dy$$

$$\int_0^1\int_0^1 \left(\frac{\partial U_\theta}{\partial t}\right)^2 dx\,dy = \int_0^1\int_0^1 \left(\sin(\pi x)\sin(\pi y)\,\dot{a}_\theta(t)\right)^2 dx\,dy = \frac{1}{2}\cdot\frac{1}{2}\cdot \dot{a}_\theta^2(t)$$

$$\int_0^1\int_0^1 \left(\frac{\partial U_\theta}{\partial z}\right)^2 dx\,dz = \int_0^1\int_0^1 \left(-\pi^2 \sin(\pi x)\sin(\pi y)\,a_\theta(t)\right)^2 dx\,dy = \frac{1}{2}\cdot\frac{1}{2}\cdot \pi^2 a_\theta(t)$$

para $z = x, y$

Entonces $E_\theta(t) = \frac{1}{2}\cdot\frac{1}{4}\left[\underbrace{\dot{a}_\theta(t)}_{t} + \underbrace{\pi^2 a_\theta^2(t)}_{x} + \underbrace{\pi^2 a_\theta^2(t)}_{y}\right] = \frac{1}{8}\left[\dot{a}_\theta^2(t) + 2\pi^2 a_\theta^2(t)\right]$

$$\frac{dE_\theta}{dt} = \frac{1}{8}\frac{d}{dt}\left[\dot{a}^2(t) + 2\pi^2 a_\theta^2(t)\right] = \frac{2}{8}\,\dot{a}_\theta(t)\left[\ddot{a}_\theta(t) + 2\pi^2 a_\theta(t)\right] = 0$$

$$\frac{\dot{a}_\theta(t)}{4}\left[\ddot{a}_\theta(t) + 2\pi^2 a_\theta(t)\right] = 0$$

Condiciones iniciales $t=0 \Rightarrow a(0) = 1,\ \dot{a}(0) = \sqrt{2}\pi,\ \omega_\theta^2 = 2\pi^2$

$$E_\theta = \frac{1}{8}\left[2\pi^2 + 2\pi^2\right] = \frac{\pi^2}{2} = \frac{\omega_\theta^2}{4}$$

PINN

residuo $r_\theta = \mathcal{N}U_\theta - f = \ddot{a}_\theta(t) + 2\pi^2 a_\theta(t)$

residuo espaciotemporal $R_\theta(x,y,t) = \sin(\pi x)\sin(\pi y)\,r_\theta$

Modelo A

$\Theta_A = \{A_1, A_2, w_1, w_2, b_1, b_2\}$

$$a_\theta(t) = \sum_{j=1}^{2} A_j \sin(w_j t + b_j)$$

$$\dot{a}_\theta(t) = \sum_{j=1}^{2} A_j w_j \cos(w_j t + b_j)$$

$$\ddot{a}_\theta(t) = -\sum_{j=1}^{2} A_j w_j^2 \sin(w_j t + b_j)$$

$$a_\theta(0) = \sum_{j=1}^{2} A_j \sin(b_j), \qquad \dot{a}_\theta(t) = \sum_{j=1}^{2} A_j w_j \cos(b_j)$$

$$r_\theta^{(A)}(t) = \ddot{a}_\theta + 2\pi^2 a_\theta = \sum_{j=1}^{2} A_j (2\pi^2 - w_j^2) \sin(w_j t + b_j)$$

Si $w_k = \sqrt{2\pi} \quad \forall k = \{1, 2\}$, el modelo contiene exactamente la solucion analitica para todo t anulando el residuo bajo esas condiciones

Modelo B.
Una neurona por dos capas

$$\theta_B = \{A, w_1, b_1, w_2, b_2\} \quad \Big| \quad h_1 = \sin(w_1 t + b_1), \quad a_\theta(t) = A \sin(w_2 h_1(t) + b_2)$$

- Neurona oculta $h_1(t)$

$$\dot{h}_1(t) = w_1 \cos(w_1 t + b_1), \qquad \ddot{h}_1(t) = -w_1^2 \sin(w_1 t + b_1) = -w_1^2 h_1(t)$$

- Neurona de salida $a_\theta(t)$

$$\dot{a}_\theta(t) = A w_2 \dot{h}_1(t) \cos(w_2 h_1(t) + b_2)$$

$$= A w_1 w_2 \cos[w_1 t + b_1) \cos(w_2 \sin(w_1 t + b_1) + b_2]$$

$$\ddot{a}_\theta = A w_2 \left[\ddot{h}_1(t) \cos(w_2 h_1(t) + b_2) - w_2 \dot{h}_1^2(t) \sin(w_2 h_1(t) + b_2) \right]$$

$$= -A w_1^2 w_2 \Big[\sin(w_1 t + b_1) \cos[w_2 \sin(w_1 t + b_1) + b_2] + w_2 \cos^2(w_1 t + b_1) \sin[w_2 \sin(w_1 t + b_1) + b_2] \Big]$$

Condiciones iniciales

$$a_\theta(t=0) = A \sin[w_2 \sin(b_1) + b_2]$$

$$\dot{a}_\theta(t=0) = A w_1 w_2 \cos(b_1) \cos[w_2 \sin(b_1) + b_2]$$

residuo

$$r_\theta^{(B)}(t) = A[2\pi^2 - w_1^2 w_2^2 \cos^2(w_1 t + b_1)] \sin[w_2 \sin(w_1 t + b_1) + b_2] - A w_1^2 w_2 \sin(w_1 t + b_1) \cos[w_2 \sin(w_1 t + b_1) + b_2]$$

Eduardo Henon R

Eduardo Henao R
1039453805

Función de coste PINN

$$J(\theta) = w_{ec} J_{ec}(\theta) + w_{ini} J_{ini}(\theta)$$

N_{ec} puntos muestrados en el intervalo $[0, T]$

$$J_{ec}(\theta) = \frac{1}{N_{ec}} \sum_{i=1}^{N_{ec}} |r_\theta(t_i)|^2 = \frac{1}{N_{ec}} \sum_{i=1}^{N_{ec}} |\ddot{a}_\theta(t_i) + 2\pi a_\theta(t_i)|^2$$

$$J_{ini}(\theta) = |a_\theta(0) - 1|^2 + |\dot{a}_\theta(0) - \sqrt{2}\pi|^2$$

Termino adicional recomendado por G. Argon

Regularización física para forzar invarianza energética

$$J_E(\theta) = \frac{1}{N_{ec}} \sum_{i=1}^{N_{ec}} \left| \frac{1}{8}\left(\dot{a}_\theta^2(t_i) + 2\pi^2 a_\theta^2(t_i)\right) - \frac{\pi^2}{2} \right|^2$$

Para Modelo A

$$J(\theta_A) = \frac{w_{ec}}{N_{ec}} \sum_{i=1}^{N_{ec}} \left[\sum_{j=1}^{2} A_j (2\pi^2 - w_j^2) \sin(w_j t + b_j) \right]^2$$

$$+ w_{ini} \left[\left(\sum_{j=1}^{2} A_j \sin(b_j) - 1 \right)^2 + \left(\sum_{j=1}^{2} A_j w_j \cos(b_j) - \sqrt{2}\pi \right)^2 \right]$$

Para Modelo B

$$J(\theta_B) = \frac{w_{ec}}{N_{ec}} \sum_{i=1}^{2} \left[r_\theta^{(B)}(t_i) \right]^2$$

$$+ w_{ini} \left[\left(A \sin[w_2 \sin(b_1) + b_2] - 1 \right)^2 \right.$$

$$\left. + \left(A w_1 w_2 \cos(b_1) \cos[w_2 \sin(b_1) + b_2] - \sqrt{2}\pi \right)^2 \right]$$

4. $\beta > 0$

$$E(q) = \frac{1}{2}\sum_{j=1}^{N} q_j^2 - \frac{1}{\beta} Ln\left[\sum_{\mu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j\right)\right], \quad X_{\mu j} \in \{F, T\}$$

F: -1
T: +1

$\mathbf{q} = (q_1, \dots q_N)$

$$\frac{\partial}{\partial q_i}\left(\frac{1}{2}\sum_{j=1}^{N} q_j^2\right) = q_i$$

Regla de la cadena en Log

$$\frac{\partial}{\partial q_i}\left[-\frac{1}{\beta} Ln\left[\sum_{\mu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j\right)\right]\right] =$$

$$= -\frac{1}{\beta} \frac{\sum_{\mu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j\right) \cdot \frac{\partial}{\partial q_i}\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j\right)}{\sum_{\nu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\nu j} q_j\right)}$$

$\frac{\partial}{\partial q_i}\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j\right) = \beta X_{\mu i}$, Entonces:

$$\frac{\partial E}{\partial q_i} = q_i - \frac{\sum_{\mu=1}^{P} X_{\mu i} \exp\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j\right)}{\sum_{\nu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\nu j} q_j\right)} \equiv q_i - \sum_{\mu=1}^{P} w_\mu(\mathbf{q}) X_{\mu x}$$

Donde

$$w_\mu(\mathbf{q}) := \frac{\exp\left(\beta \sum_{j=1}^{N} X_{\mu j} q\right)}{\sum_{\nu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\nu j} q_j\right)} = softmax(\beta X \mathbf{q})_\mu$$

Son los pesos normalizados ~ distribucion Boltzmaniano

Definimos el vector columna $X_\mu := (X_{\mu 1}, \dots X_{\mu N})^T$

Entonces

$$\nabla_q E(\mathbf{q}) = \mathbf{q} - X^T softmax(\beta X \mathbf{q})$$

Descenso de gradiente $q_i^{(t+1)} = q_i^{(t)} - \alpha \nabla_q E(\mathbf{q})$

Eduardo Henao R

8/10

Eduardo Henao R
1039453805

$$q_i^{(t+1)} = (1-\alpha)\, q_i^{(t)} + \alpha \frac{\sum_{\mu=1}^{P} X_{\mu i} \exp\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j^{(t)}\right)}{\sum_{\nu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\nu j} q_j^{(t)}\right)}$$

$$\mathbf{q}^{(t+1)} = (1-\alpha)\, \mathbf{q}^{(t)} + \alpha\, X^T \mathrm{softmax}(\beta X \mathbf{q}^{(t)})$$

Para $\alpha = 1$

$$\mathbf{q}^{(t+1)} = X^T \mathrm{softmax}(\beta X \mathbf{q}^{(t)}) = \sum_{\mu=1}^{P} W_\mu(\mathbf{q}^{(t)})\, X_{\mu i}$$

$$q_i^{(t+1)} = \frac{\sum_{\mu=1}^{P} X_{\mu i} \exp\left(\beta \sum_{j=1}^{N} X_{\mu j} q_j^{(t)}\right)}{\sum_{\nu=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{\nu j} q_j^{(t)}\right)} = \frac{\sum_{\mu=1}^{P} X_{\mu i} \exp\left(\beta S_\mu^{(t)}\right)}{\sum_{\nu=1}^{P} \exp\left(\beta S_\nu^{(t)}\right)}$$

El término $S_\mu^{(t)} = \sum_{j=1}^{N} X_{\mu j} q_j^{(t)} = X_\mu \mathbf{q}^{(t)}$ mide la similitud entre el estado actual de la red y el patron almacenado μ

β es una frialdad informacional del sistema, analogo al caso de la temperatura inversa en Fisica estadistica $(k_B T)^{-1}$ en una funcion de particion con una distribucion Boltzmaniana

- Frialdades bajas $(\beta \to 0,\ T \to \infty)$

$$\exp\left[\beta S_\mu^{(t)}\right] \approx 1 + \beta S_\mu^{(t)} \approx 1 \Rightarrow W_\mu \approx \frac{1}{P},\quad q^{(t+1)} \approx \frac{1}{P} \sum_{\mu=1}^{P} X_{\mu i}$$

es decir, un campo lieal de una red de Hopfield con pesos de Hebb, la actualizacion converge a un promedio aritmetico, las contribuciones interfieren entre si dificultando una unica contribucion.

- Frialdades altas $(\beta \to \infty,\ T \to 0)$

$$W_\mu(\mathbf{q}^{(t)}) = \frac{\exp\left[\beta\left(S_\mu^{(t)} - S_{\mu^*}^{(t)}\right)\right]}{1 + \sum_{\nu \neq \mu} \exp\left[\beta\left(S_\nu^{(t)} - S_{\mu^*}^{(t)}\right)\right]} \xrightarrow{\beta \to \infty} \begin{cases} 1, & \mu = \mu^* \\ 0, & \mu \neq \mu^* \end{cases}$$

En el zero absoluto informacional softmax se comporta como un argmax, asignando todo el peso al patron $X_{\mu *}$ mas cercano

- las frialdades negativas ($\beta < 0$) estan prohibidas, en mecanica cuantica corresponde a inversiones de poblacion donde la energia esta acotada ente un maximo y un minimo de energia, llega un punto en que a mayor energia, disminuye la multiplicidad

Criterio de recuperación

$$\hat{q}_i = \mathrm{Sgn}\left[q_i^{(T)}\right] = \begin{cases} +1, & q_i^{(T)} \geq 0 \\ -1, & q_i^{(T)} < 0 \end{cases}$$

T es en este caso la iteración final
(no confundir con temperatura)

Como $X_{\mu * i} \in \{-1, +1\} \Rightarrow \hat{q}_i X_{\mu * i}$ es:

+1: los pixeles coinciden
-1: los pixeles difieren

$$\text{Porcentaje de coincidencia} = \frac{100}{N} \sum_{i=1}^{N} \left[\frac{1 + \hat{q}_i X_{\mu * i}}{2} \right]$$

10/10

Eduardo Honda R.