Parcial #1: Computación científica avanzada.

Punto 1

Para la detección de eventos independientes y cuya tasa esperada de llegada depende de una condición experimental x_i, el número de eventos observados y_i se modela como una variable aleatoria de poisson

$$P(y_i|x_i;\theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!} \qquad y_i = 0, 1, 2, \ldots$$

Siendo $h_\theta(x_i)$ representa la tasa esperada de detecciones. En este primer modelo, suponga que la tasa depende linealmente de x_i

$$h_\theta(x_i) = \theta_0 + \theta_1 x_i \qquad h_\theta(x_i) > 0$$

a) Construya la función verosimilitud $L(\theta)$ para un conjunto de datos independientes $\{(x_i, y_i)\}_{i=1}^n$

Siendo $L(\theta)$ la probabilidad conjunta dada por:

$$L(\theta) = P(y_1, y_2, \ldots, y_n | X; \theta)$$

pero suponiendo que son independientes

$$L(\theta) = \prod_{i=1}^{n} P(y_i|x_i;\theta)$$

$$= \prod_{i=1}^{n} \frac{(\theta_0+\theta_1 x_i)^{y_i} e^{-(\theta_0+\theta_1 x_i)}}{y_i!}$$

b) Determine $\ell(\theta) = \log L(\theta)$ la cual es:

$$\ell(\theta) = \log L(\theta)$$

$$= \log \prod_{i=1}^{n} \frac{(\theta_0+\theta_1 x_i)^{y_i} e^{-(\theta_0+\theta_1 x_i)}}{y_i!}$$

$$= \sum_{i=1}^{n} \log \left[\frac{\theta_0+\theta_1 x_i)^{y_i} e^{-(\theta_0+\theta_1 x_i)}}{y_i!} \right]$$

$$= \sum_{i=1}^{n} \log \left[(\theta_0+\theta_1 x_i)^{y_i} e^{-(\theta_0+\theta_1 x_i)} \right] - \log y_i!$$

$$= \sum_{i=1}^{n} y_i \log(\theta_0+\theta_1 x_i) - [(\theta_0+\theta_1 x_i) - \log(y_i!)]$$

Ahora para la función de coste queda como:

$$J(\theta) = -\frac{1}{n} \ell(\theta) = \frac{1}{n} \sum_{i=1}^{n} [(\theta_0+\theta_1 x_i) - y_i \log(\theta_0+\theta_1 x_i) - \log y_i!]$$

c) Considerando solo los términos dependientes de θ queda entonces

$$J(\theta) = \sum_{i=1}^{n} (\theta_0+\theta_1 x_i) - y_i \log(\theta_0+\theta_1 x_i)$$

d) Para calcular el gradiente de $J(\theta)$ respecto a θ_0 y θ_1

$$\rightarrow \frac{\partial J}{\partial \theta_0} = \frac{\partial}{\partial \theta_0} \sum_{i=1}^{n} (\theta_0+\theta_1 x_i) - y_i \log(\theta_0+\theta_1 x_i)$$

$$\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n} \frac{\partial}{\partial \theta_0}(\theta_0 + \theta_1 x_i) - \frac{\partial}{\partial \theta_0} y_i \log(\theta_0 + \theta_1 x_i)$$

$$\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n} 1 - \frac{y_i}{\theta_0 + \theta_1 x_i}$$

$$\rightarrow \frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} \frac{\partial}{\partial \theta_1}(\theta_0 + \theta_1 x_i) - \frac{\partial}{\partial \theta_1} y_i \log(\theta_0 + \theta_1 x_i)$$

$$\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} x_i - \frac{y_i x_i}{\theta_0 + \theta_1 x_i}$$

$$\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} \left(1 - \frac{y_i}{\theta_0 + \theta_1 x_i}\right) x_i$$

e) Para el caso del detector $h_\theta(x_i)$ corresponde al número de eventos que "deberían" ser detectados bajo la condición experimental x_i

Ahora por otro lado θ_0, sería el "ruido de fondo", es decir, es lo que mide el detector incluso cuando no aplica ninguna condición física $(x=0)$

Por otro lado θ_1, sería el factor de peso que determina la sensibilidad del detector respecto a la variable x.

Punto ② Considere una red neuronal de una capa oculta que recibe una entrada escalar x_i y produce una tasa esperada de conteos mediante una salida positiva:

$$h_\theta(x_i) = e^{f_\theta(x_i)}$$

La red definida como

$$Z_{i,1}^{[1]} = \theta_{1,1}^{[1]} x_i + b_1^{[1]}$$

$$A_{i,1}^{[1]} = \sigma\left(Z_{i,1}^{[1]}\right)$$

σ es una función de activación diferenciable

$$Z_{i,1}^{[2]} = \theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}$$

$$h_\theta(x_i) = e^{Z_{i,1}^{[2]}}$$

Para un dato (x_i, y_i), la función de coste de Poisson, salvo constantes independientes de θ es:

$$J_i(\theta) = e^{Z_{i,1}^{[2]}} - y_i Z_{i,1}^{[2]}$$

a) Para calcular el error en la capa de salida

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}} = e^{Z_{i,1}^{[2]}} - y_i$$

$$\delta_{i,1}^{[2]} = h_\theta(x_i) - y_i$$

b) Calcule los gradientes respecto a los parámetros de la capa de salida

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}} = \frac{\partial}{\partial \theta_{1,1}^{[2]}} \left[e^{\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}} - y_i \theta_{1,1}^{[2]} A_{i,1}^{[1]} - y_i b_1^{[2]} \right]$$

$$= \left[A_{i,1}^{[1]} \, e^{\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}} - A_{i,1}^{[1]} y_i\right]$$

$$= A_{i,1}^{[2]} \left[e^{\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}} - y_i\right]$$

$$= A_{i,1}^{[2]} \left[h_\theta(x_i) - y_i\right]$$

$$\rightarrow \frac{\partial J_i}{\partial b_1^{[2]}} = e^{\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}} - y_i = h_\theta(x_i) - y_i$$

c) Para calcular el error que se propaga hacia la capa oculta

$$\delta_{i,1}^{[1]} = \frac{\partial J_i}{\partial z_{i,1}^{[1]}} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}} \frac{\partial z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} \frac{\partial A_{i,1}^{[1]}}{\partial z_{i,1}^{[1]}}$$

$$\frac{\partial z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} = \theta_{1,1}^{[2]} \qquad \frac{\partial J_i}{\partial z_{i,1}^{[2]}} = e^{z_{i,1}^{[2]}} - y_i = h_\theta(x_i) - y_i$$

$$\frac{\partial A_{i,1}^{[1]}}{\partial z_{i,1}^{[1]}} = \sigma'(z_{i,1}^{[1]})$$

$$\delta_{i,1}^{[1]} = \theta_{1,1}^{[2]} \sigma'(z_{i,1}^{[1]}) (h_\theta(x_i) - y_i)$$

d) Calule los gradientes respecto a los parámetros de la primera capa

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = \underbrace{\frac{\partial J_i}{\partial z_{i,1}^{[2]}} \frac{\partial z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} \frac{\partial A_{i,1}^{[1]}}{\partial z_{i,1}^{[1]}}}_{\text{ya se sabe del ejercicio anterior}} \frac{\partial z_{i,1}^{[1]}}{\partial \theta_{1,1}^{[1]}}$$

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = \theta_{1,1}^{[2]} \sigma'(z_{i,1}^{[1]})(h_\theta(x_i) - y_i)\, x_i$$

De forma analoga se obtiene que:

$$\frac{\partial J_i}{\partial b_1^{[1]}} = \theta_{1,1}^{[2]} \sigma'(z_{i,1}^{[1]})(h_\theta(x_i - y_i))$$

Punto ③ Considere una membrana cuadrada unitaria, con bordes fijos, cuyos desplazamientos transversales $U(x,y,t)$, respecto a su posicion de equilibrio, estan descritos en el regimen de pequeñas osilaciones, por la ecuacion de onda adimensional

$$\frac{\partial^2 U}{\partial t^2} = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2}$$

Condiciones de frontera e iniciales

$$U(x,y,0) = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)$$

$$U_t(x,y,0) = \sqrt{2}\pi \operatorname{Sen}(x\pi)\operatorname{Sen}(\pi y)$$

Aproximando $U(x,y,t)$ por medio de una PINN de la forma

$$U_\theta(x,y,t) = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\alpha_\theta(t)$$

Se tienen 2 modelos

Modelo A

Una capa con 2 neuronas de activacion:

$$\alpha_\theta(t) = \sum_{j=1}^{2} A_j \operatorname{Sen}(\omega_j t + b_j)$$

Modelo B

Dos capas con una neurona

$$h_1(t) = \operatorname{Sen}(\omega_1 t + b_1)$$

$$\alpha_\theta(t) = A\operatorname{Sen}(\omega_2 t + b_2)$$

Primero se reduce la ecuacion de onda a una ecuación diferencial ordinaria. Para ello se propone

$$U(x,y,t) = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a(t)$$

$$\frac{\partial^2 U}{\partial t^2} = \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\frac{\partial^2 a(t)}{\partial t^2}$$

$$\frac{\partial U}{\partial x} = \pi\cos(\pi x)\operatorname{Sen}(\pi y)\, a(t) \qquad \frac{\partial^2 U}{\partial x^2} = -\pi^2 \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a(t)$$

$$\frac{\partial U}{\partial y} = \pi \operatorname{Sen}(\pi x)\cos(\pi y)\, a(t) \qquad \frac{\partial^2 U}{\partial y^2} = -\pi^2 \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a(t)$$

$$\operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\frac{\partial^2 a(t)}{\partial t^2} = -\pi^2 \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a(t) - \pi^2 \operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\, a(t)$$

$$\operatorname{Sen}(\pi x)\operatorname{Sen}(\pi y)\left[\frac{\partial^2 a(t)}{\partial t^2} + 2\pi^2 a(t)\right] = 0 \qquad \text{Para } \operatorname{sen}(\pi x)\operatorname{sen}(\pi y) \neq 0$$

$$\frac{d^2 a(t)}{dt^2} + 2\pi^2 a(t) = 0$$

Ahora calculando las derivadas de las neuronas se tiene:

Modelo A

$$a_0(t) = \sum_{j=1}^{2} A_j \operatorname{Sen}(\omega_j t + b_j) \qquad a_0^1(t) = \sum_{j=1}^{2} A_j \omega_j \cos(\omega_j t + b_j)$$

$$a_0''(t) = -\sum_{j=1}^{2} A_j \omega_j^2 \operatorname{sen}(\omega t + b_j)$$

Modelo B.

Primera capa

$$h_1(t) = \operatorname{Sen}(\omega_1 t + b_1) \qquad h_1'(t) = \omega_1 \cos(\omega_1 t + b_2)$$

$$h_1''(t) = -\omega_1^2 \operatorname{Sen}(\omega_1 t + b_2)$$

Segunda capa

$$a(t) = A \operatorname{Sen}(\omega_2 h_1(t) + b_2)$$

$$a'(t) = A\omega_2 h_1'(t) \cos(\omega_2 h_1(t) + b_2)$$
$$= A\omega_2 \omega_1 h_1(t) \cos(\omega_1 t + b_2) \cos(\omega_2 h_1(t) + b_2)$$

$$a''(t) = -A\omega_1^2 \omega_2^2 \operatorname{sen}(\omega_2 h_1(t) + b_2) - A\omega_1^2 \omega_2 \cos(\omega_2 h_1(t) + b_2) \operatorname{sen}(\omega_1 t + b_2)$$

Por otro lado, para las PINN se tiene la definición de los residuos como: $r_\theta = \mathcal{N}U - f(\vec{x}, t)$ donde $\mathcal{N}$ es operador diferencial

Aplicado a nuestro caso el residuo queda como

$$r_\theta = \frac{\partial^2 U_\theta}{\partial t^2} - \frac{\partial^2 U_\theta}{\partial x^2} - \frac{\partial^2 U_\theta}{\partial y^2}$$

$$r_\theta = a''(t) + 2\pi^2 a(t)$$

Aplicado el modelo A

$$r_\theta = -\sum_{j=1}^{2} A_j \omega_j^2 \operatorname{sen}(\omega_j t + b_j) + 2\pi^2 \sum_{j=1}^{2} A_j \operatorname{Sen}(\omega_j t + b_j)$$

$$= \sum_{j=1}^{2} (2\pi^2 - A_j \omega_j^2) \operatorname{Sen}(\omega_j t + b_j)$$

Para el modelo B

$$r_\theta(t) = -A\omega_1^2\omega_2^2 \operatorname{Sen}(\omega_2 h_1(t) + b_2) - A\omega_1^2\omega_2 \cos(\omega_2 h_1(t) + b_2) \operatorname{Sen}(\omega_1 t + b_2) + 2\pi^2 A \operatorname{Sen}(\omega_2 h_1(t) + b_2)$$

Por último para la función de pérdida, se eleva al cuadrado el residuo y se promedia sobre los N puntos e incorporamos las condiciones iniciales.

Las condiciones iniciales quedan como:

$$U(x,y,0) = \operatorname{Sen}(\pi x) \operatorname{Sen}(\pi y)\, a(0) = \operatorname{Sen}(\pi x) \operatorname{Sen}(\pi y)$$

por ende $a(0) = 1$

$$U_\theta(x,y,0) = \sqrt{2}\pi \operatorname{Sen}(\pi x) \operatorname{Sen}(\pi y) = \operatorname{Sen}(\pi x) \operatorname{Sen}(\pi y)\, a'(0)$$

así $a'(0) = \sqrt{2}\pi$

$$J(\theta) = \frac{1}{N} \sum_{i=1} r_\theta(t_i)^2 + \omega_0 [a_\theta(0) - 1]^2 + \omega_1 [a'_\theta(0) - \sqrt{2}\pi]^2$$

Punto 4 Considere una red de memoria asociativa formada por N neuronas que almacena P patrones binarios. Cada patrón se representa mediante un vector de N componentes, cuyos valores son $+1$ o -1, organizados en una matriz X de $P \times N$

$$x_{\mu i} \in \{-1, +1\}$$

El estado de la red se describe mediante un vector $\vec{q} = (q_1, \dots, q_N)$ donde $q_i \in \mathbb{R}$ representa el estado de la neurona i. Inicialmente, la red recibe un patrón binario $\vec{q}(0)$ que puede contener errores.

La recuperación de la memoria se realiza mediante la minimización de energía:

$$E(\vec{q}) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln\left(\sum_{\mu=1}^{P} e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i} \right) \qquad \beta > 0$$

Para calcular las derivadas parciales de la energía respecto a cada componente q_i y obtener la expresión del gradiente

$$\frac{\partial}{\partial q_i} E(\vec{q}) = \frac{\partial}{\partial q_i} \left[\frac{1}{2} \sum q_i^2 - \frac{1}{\beta} \ln\left(\sum_{\mu=1}^{P} e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i} \right) \right]$$

$$= \frac{1}{2} \frac{\partial}{\partial q_i} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \frac{\partial}{\partial q_i} \left[\ln \sum_{\mu=1}^{P} e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i} \right]$$

$$= q_i - \frac{1}{\beta} \frac{\sum_{\mu=1}^{P} \beta x_{\mu i} e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}{\sum_{i=1} e^{\beta \sum_{i=1} x_{\mu i} q_i}}$$

$$= q_i - \frac{\sum_{\mu=1}^{P} x_{\mu i} e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}{e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}$$

Reemplazando lo obtenido en el gradiente

$$q_i^{(t+1)} = q_i^{(t)} - \alpha \frac{\partial E}{\partial q_i}$$

Se tiene entonces

$$q^{(t+1)} = q^{(t)} - \alpha \left(q_i^{(t)} - \sum_{\mu=1}^{P} \frac{x_{\mu i}\, e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}{e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}} \right)$$

$$q^{(t+1)} = (1-\alpha)\, q_i^{(t)} - \sum_{\mu=1}^{P} \frac{x_{\mu i}\, e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}{e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}$$

Ahora para el caso $\alpha = 1$ nos queda que la regla de actualización es:

$$q^{(t+1)} = \sum_{\mu=1}^{P} \frac{x_{\mu i}\, e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}{e^{\beta \sum_{i=1}^{N} x_{\mu i} q_i}}$$

Para un $\beta \to 0$ $\qquad q^{(t+1)} \longrightarrow \sum_{\mu=1}^{P} x_{\mu i}$

Eso implica que la red promedia sin importar el estado inicial, así no distingue los patrones

Para $\beta \to \infty$ $\qquad q^{(t+1)} \longrightarrow x_{\mu i}$

En este caso la red recupera ese patron exactamente, en una sola iteración.