DD MM AA

Examen Computación Científica Avanzada

Juan Pablo Ortiz Gil C.C: 1010128030

1)

Para un conjunto de datos independientes, donde el número de eventos observados y_i se modela como

$$P(y_i | x_i; \theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}, \quad y_i = 0, 1, 2, \ldots$$

$$\{(x_i, y_i)\}_{i=1}^{n}$$

La función de verosimilitud está definida por

$$L(\theta) = \prod_{i=1}^{n} P(y_i | x_i; \theta)$$

$$= \prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}$$

A partir de esto se puede obtener la log-verosimilitud, definida como

$$\ell(\theta) = \log L(\theta)$$

$$= \log \prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!} = \sum_{i=1}^{n} \log \left(\frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!} \right)$$

$\therefore$

$$\ell(\theta) = \sum_{i=1}^{n} [y_i \log h_\theta(x_i) - h_\theta(x_i) - \log y_i!]$$

Y ahora, si consideramos el principio de máxima verosimilitud, podemos definir nuestra función de coste como

$$J(\theta) = -\ell(\theta) = \sum_{i=1}^{n} [\log y_i! + h_\theta(x_i) - y_i \log h_\theta(x_i)]$$

que, omitiendo las constantes independientes de θ nos deja una función de la forma

$$J(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \log h_\theta(x_i)]$$

Norma

Scanned with CamScanner

Ahora, considerando que $h_\theta(x_i) = \theta_0 + \theta_1 x_i$, podemos calcular el gradiente de la función de coste respecto a los parámetros del modelo

$$\frac{\partial J(\theta)}{\partial \theta_0} = \sum_{i=1}^{n} \left[1 - \frac{y_1}{\theta_0 + \theta_1 x_i} \right] = \sum_{i=1}^{n} \left[1 - \frac{y_i}{h_\theta(x_i)} \right]$$

$$\frac{\partial J(\theta)}{\partial \theta_1} = \sum_{i=1}^{n} \left[x_i - \frac{x_i}{\theta_0 + \theta_1 x_i} y_i \right] = \sum_{i=1}^{n} \left[x_i - \frac{x_i y_i}{h_\theta(x_i)} \right]$$

finalmente, vale la pena dar interpretación a la función paramétrica $h_\theta(x_i)$. Esta representa la tasa esperada de detección de partículas por unidad de tiempo para la condición experimental x. Su fórmula paramétrica nos describe cómo cambia la tasa promedio de detección en función de las condiciones experimentales, tal que:

θ_0 se puede interpretar como el nivel de referencia del detector, la tasa esperada a $x_i = 0$.

y θ_1 es la sensibilidad del detector frente a cambios en la condición experimental.

2)

Para la red definida en el problema, el error de la capa de salida es

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}} = \frac{\partial}{\partial z_{i,1}^{[2]}} \left[\exp\left(z_{i,1}^{[2]} \right) - y_i \, z_{i,1}^{[2]} \right]$$

$$= \exp\left(z_{i,1}^{[2]} \right) - y_i$$

Los gradientes de la función de coste respecto a los parámetros de salida $\theta_{1,1}^{[2]}$ y $b_1^{[2]}$ son:

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}} = \frac{\partial}{\partial \theta_{1,1}^{[2]}} \left[\exp\left(\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]} \right) - y_i \left(\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]} \right) \right]$$

Norma

Scanned with CamScanner

DD MM AA

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}} = \exp\left(\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}\right) A_{i,1}^{[1]} - y_i A_{i,1}^{[1]}$$

$$= \exp\left(z_{i,1}^{[2]}\right) A_{i,1}^{[1]} - y_i A_{i,1}^{[1]}$$

y

$$\frac{\partial J_i}{\partial b_1^{[2]}} = \exp\left(\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}\right) - y_i = \exp\left(z_{i,1}^{[2]}\right) - y_i$$

Luego, podemos obtener el error que se propaga hacia la capa oculta

$$\delta_{i,1}^{[1]} = \frac{\partial J_i}{\partial z_{i,1}^{[1]}} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}} \frac{\partial z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} \frac{\partial A_{i,1}^{[1]}}{\partial z_{i,1}^{[1]}}$$

- $\dfrac{\partial J_i}{\partial z_{i,1}^{[2]}} = \exp\left(z_{i,1}^{[2]}\right) - y_i$

- $\dfrac{\partial z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} = \dfrac{\partial}{\partial A_{i,1}^{[1]}}\left[\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}\right] = \theta_{1,1}^{[2]}$

- $\dfrac{\partial A_{i,1}^{[1]}}{\partial z_{i,1}^{[1]}} = \dfrac{\partial}{\partial z_{i,1}^{[1]}}\left[\sigma\left(z_{i,1}^{[1]}\right)\right] = \sigma'\left(z_{i,1}^{[1]}\right)$ → al ser una función de activación general diferenciable

$$\delta_{i,1}^{[1]} = \left[\exp\left(z_{i,1}^{[2]}\right) - y_i\right] \sigma'\left(z_{i,1}^{[1]}\right) \theta_{1,1}^{[2]}$$

$$\delta_{i,1}^{[1]} = \delta_{i,1}^{[2]} \theta_{1,1}^{[2]} \sigma'\left(z_{i,1}^{[2]}\right)$$

Norma

Scanned with CamScanner

DD MM AA

Finalmente, calculamos los gradientes respecto a los parámetros $\theta_{1,1}^{[1]}$ y $b_1^{[1]}$ de la primera capa

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = \frac{\partial J_i}{\partial z_{i,1}^{[1]}} \frac{\partial z_{i,1}^{[1]}}{\partial \theta_{1,1}^{[1]}}$$

la primera expresión la acabamos de calcular

$$\frac{\partial z_{i,1}^{[1]}}{\partial \theta_{1,1}^{[1]}} = \frac{\partial}{\partial \theta_{1,1}^{[1]}} \left[\theta_{1,1}^{[1]} x_i + b_1^{[1]} \right] = x_i$$

$$\therefore \quad \frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = \delta_{i,1}^{[2]} \theta_{1,1}^{[2]} x_i \sigma'(z_{i,1}^{[1]}) = \delta_{i,1}^{[1]} x_i$$

$$\frac{\partial J_i}{\partial b_1^{[1]}} = \frac{\partial J_i}{\partial z_{i,1}^{[1]}} \frac{\partial z_{i,1}^{[1]}}{\partial b_1^{[1]}}$$

$$\frac{\partial z_{i,1}^{[1]}}{\partial b_1^{[1]}} = 1$$

$$\therefore \quad \frac{\partial J_i}{\partial b_1^{[1]}} = \delta_{i,1}^{[2]} \theta_{1,1}^{[2]} \sigma'(z_{i,1}^{[1]}) = \delta_{i,1}^{[1]}$$

3) para el problema de la ecuación de onda bidimensional adimensional

$$\frac{\partial^2 U}{\partial t^2} = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2}$$

para la que aproximamos el desplazamiento $U(x, y, t)$ mediante una PINN

$$V_\theta(x, y, t) = \sin(\pi x) \sin(\pi y) q_\theta(t)$$

Norma

Scanned with CamScanner

tenemos que

$$\frac{\partial U_\theta}{\partial x} = \pi \cos(\pi x)\sin(\pi y)\, a_\theta(t)$$

$$\therefore \frac{\partial^2 U_\theta}{\partial x^2} = -\pi^2 \sin(\pi x)\sin(\pi y)\, a_\theta(t)$$

y de manera análoga

$$\frac{\partial U_\theta}{\partial y} = \pi \sin(\pi x)\cos(\pi y)\, a_\theta(t)$$

$$\therefore \frac{\partial^2 U_\theta}{\partial y^2} = -\pi^2 \sin(\pi x)\sin(\pi y)\, a_\theta(t)$$

Sumando ambas derivadas obtenemos

$$\nabla^2 U_\theta = -2\pi^2 \sin(\pi x)\sin(\pi y)\, a_\theta(t)$$

Adicionalmente, con $\frac{\partial U_\theta}{\partial t} = \sin(\pi x)\sin(\pi y)\, a'_\theta(t)$ y por tanto $\frac{\partial^2 U_\theta}{\partial t^2} = \sin(\pi x)\sin(\pi y)\, a''_\theta(t)$. Sustituyendo en la ecuación de onda se obtiene que

$$\sin(\pi x)\sin(\pi y)\, a''_\theta(t) = -2\pi^2 \sin(\pi x)\sin(\pi y)\, a_\theta(t)$$

Sabemos que el factor espacial al interior de la membrana es no nulo y por tanto cancelamos y obtenemos

$$a''_\theta(t) + 2\pi^2 a_\theta(t) = 0$$

La solución general a esta ecuación es $a_\theta(t) = C_1\cos(w_0 t) + C_2 \sin(w_0 t)$ con $w_0 = \sqrt{2}\pi$. Con condiciones iniciales a partir de hacer coincidir U y U_θ siendo

$$a(0) = 1 \quad \text{y} \quad a'(0) = \sqrt{2}\pi$$

$$\therefore a(0) = C_1 = 1$$

y $a'(t) = -c_1 \omega_0 \sin(\omega_0 t) + c_2 \omega_0 \cos(\omega_0 t)$

$a'(0) = c_2 \omega_0 = \sqrt{2}\pi \rightarrow c_2 = 1$

Se obtiene entonces que la solución exacta es

$$a(t) = \cos(\sqrt{2}\pi t) + \sin(\sqrt{2}\pi t)$$

Y la solución completa de la membrana es

$$V(x,y,t) = \sin(\pi x)\sin(\pi y)\left[\cos(\sqrt{2}\pi t) + \sin(\sqrt{2}\pi t)\right]$$

Esto de forma general, ahora:

Modelo A:

$$a_\theta(t) = \sum_{j=1}^{2} A_j \sin(\omega_j t + b_j)$$

cuya derivada es $a'_\theta(t) = \sum_{j=1}^{2} A_j \omega_j \cos(\omega_j t + b_j)$ y por tanto

$$a''_\theta(t) = -\sum_{j=1}^{2} A_j \omega_j^2 \sin(\omega_j t + b_j)$$

Definimos el residuo físico como $r_A(t) = a''_\theta(t) + 2\pi^2 a_\theta(t)$, por la ecuación que debe satisfacer la red, en este caso es

$$r_A(t) = -\sum_{j=1}^{2} A_j \omega_j^2 \sin(\omega_j t + b_j) + 2\pi^2 \sum_{j=1}^{2} A_j \sin(\omega_j t + b_j)$$

$$= \sum_{j=1}^{2} A_j (2\pi^2 - \omega_j^2) \sin(\omega_j t + b_j)$$

El objetivo del entrenamiento es hacer este residuo lo más cercano a cero posible. Si incorporamos las condiciones iniciales

Norma

Scanned with CamScanner

DD MM AA

en $t=0$ la salida de la red es $a_0(0) = A_1 \sin b_1 + A_2 \sin b_2 = 1$

y $a_0'(0) = A_1 w_1 \cos b_1 + A_2 w_2 \cos b_2 = \sqrt{2}\,\pi$

Estas dos igualdades son las restricciones iniciales de la red

Modelo B:

$$a_0(t) = A \sin(w_2 h_1(t) + b_2) \quad ; \quad h_1(t) = \sin(w_1 t + b_1)$$

por simplificación definamos $z(t) = w_2 h_1(t) + b_2$

- Así, las derivadas de la neurona oculta son $h_1'(t) = w_1 \cos(w_1 t + b_1)$

y $h_1''(t) = -w_1^2 \sin(w_1 t + b_1) = -w_1^2 h_1(t)$

- Y las derivadas de la salida son $a_0'(t) = A \cos z(t)\, z'(t)$

con $z'(t) = w_2 h_1'(t)$

$\therefore$ $a_0'(t) = A w_1 w_2 \cos(w_1 t + b_1) \cos z(t)$

y la segunda $a_0''(t) = A\left[-\sin z(t)\,(z'(t))^2 + \cos z(t)\, z''(t)\right]$

o lo que es lo mismo $a_0''(t) = -A w_1^2 w_2^2 \cos^2(w_1 t + b_1) \sin z(t)$

$$- A w_1^2 w_2 \sin(w_1 t + b_1) \cos z(t)$$

definimos el residuo físico de manera análoga al caso anterior

$$r_B(t) = a_0''(t) + 2\pi^2 a_0(t)$$

$$r_B(t) = -A w_1^2 w_2^2 \cos^2 q(t) \sin z(t) - A w_1^2 w_2 \sin q(t) \cos z(t) + \cdots$$
$$\cdots + 2\pi^2 A \sin z(t)$$

Ahora, si incorporamos las condiciones iniciales, en $t=0$

$q(0) = b_1$, $h_1(0) = \sin b_1$

$\therefore$ $a_0(0) = A \sin(w_2 \sin b_1 + b_2) = 1$

y $a_0'(0) = A w_1 w_2 \cos b_1 \cos(w_2 \sin b_1 + b_2) = \sqrt{2}\,\pi$

Norma

Scanned with CamScanner

La PINN aprenderá los parámetros de la red al minimizar una función de pérdida incorporando las ecuaciones y las condiciones iniciales.

Si tomamos N puntos temporales $t_i \in [0, T]$ $i = 1, \cdots, N$. Para el modelo A definimos

$$J_{fis}^{A} = \frac{1}{N} \sum_{i=1}^{N} [r_A(t_i)]^2$$

y para el modelo B

$$J_{fis}^{B} = \frac{1}{N} \sum_{i=1}^{N} [r_B(t_i)]^2$$

minimizando estas funciones, buscamos que la solución satisfaga la ecuación en todo el dominio temporal.

Podemos incorporar las condiciones iniciales mediante

$$J_{ci} = [a_\theta(0) - 1]^2 + [a_\theta'(0) - \sqrt{2}\,\pi]^2$$

penalizando errores en el desplazamiento y velocidad iniciales.

Así, el entrenamiento consiste en minimizar, para cada arquitectura, la función

$$J(\theta) = w_{ec} J_{fis}^{\alpha} + w_{ini} J_{ci} \qquad \alpha = A, B$$

Las expresiones a reemplazar en cada término se han dejado explícitas a lo largo de la solución del ejercicio

4) En esta red de memoria asociativa donde el estado actual es un vector

$$\vec{q} = (q_1, q_2, \cdots, N)$$

la función de energía a minimizar es

$$E(\vec{q}) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln \left(\sum_{\mu=1}^{P} \exp \left[\beta \sum_{i=1}^{N} x_{\mu i}\, q_i \right] \right)$$

DD MM AA

vamos a definir el acople entre el estado de la red y cada patron almacenado

$$S_\mu = \sum_{i=1}^{N} \chi_{\mu i}\, q_i$$

$$\therefore \quad E(\vec{q}) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln\left(\sum_{\mu=1}^{P} e^{\beta S_\mu} \right)$$

vamos a considerar por separado los dos términos para calcular $\frac{\partial E}{\partial q_i}$ para cada neurona i.

$$* \quad E_1(\vec{q}) = \frac{1}{2} \sum_{j=1}^{N} q_j^2 \quad \rightarrow \quad \frac{\partial E_1(\vec{q})}{\partial q_i} = \frac{1}{2} \sum_{j=1}^{N} \frac{\partial}{\partial q_i}(q_j^2)$$

$$= \frac{1}{2} \sum_{j=1}^{N} 2\, q_j\, \delta_{ij}$$

$$\rightarrow \quad \frac{\partial E_1(\vec{q})}{\partial q_i} = q_i$$

$$* \quad E_2(\vec{q}) = -\frac{1}{\beta} \ln\left(\sum_{\mu=1}^{P} e^{\beta S_\mu} \right) = -\frac{1}{\beta} \ln Z(\vec{q})$$

$$\therefore \quad \frac{\partial E_2}{\partial q_i} = \frac{\partial E_2}{\partial Z} \frac{\partial Z}{\partial q_i} = -\frac{1}{\beta} \frac{1}{Z} \frac{\partial Z}{\partial q_i} \qquad \text{y} \quad \frac{\partial Z}{\partial q_i} = \sum_{\mu=1}^{P} \frac{\partial}{\partial q_i}\left(e^{\beta S_\mu}\right)$$

considerando que $\frac{\partial S_\mu}{\partial q_i} = \chi_{\mu i} \rightarrow \frac{\partial}{\partial q_i} e^{\beta S_\mu} = \beta\, \chi_{\mu i}\, e^{\beta S_\mu}$

$$\therefore \quad \frac{\partial Z}{\partial q_i} = \beta \sum_{\mu=1}^{P} \chi_{\mu i}\, e^{\beta S_\mu} \qquad \text{y} \quad \frac{\partial E_2}{\partial q_i} = -\frac{1}{\beta} \frac{1}{Z} \left(\beta \sum_{\mu=1}^{P} \chi_{\mu i}\, e^{\beta S_\mu} \right)$$

finalmente $$\frac{\partial E_2}{\partial q_i} = -\frac{\sum_{\mu=1}^{P} \chi_{\mu i}\, e^{\beta S_\mu}}{\sum_{\mu=1}^{P} e^{\beta S_\mu}}$$

Norma

Scanned with CamScanner

así $$\frac{\partial E}{\partial q_i} = q_i - \frac{\sum_{\mu=1}^{p} x_{\mu i} e^{\beta S_\mu}}{\sum_{\mu=1}^{p} e^{\beta S_\mu}} = q_i - \frac{\sum_{\mu=1}^{p} x_{\mu i} \exp\left(\beta \sum_{j=1}^{N} x_{\mu j} q_j\right)}{\sum_{\mu=1}^{p} \exp\left(\beta \sum_{j=1}^{N} x_{\mu j} q_j\right)}$$

Con esto, podemos deducir la regla de actualización

$$q_i^{(t+1)} = q_i^{(t)} - \alpha \left.\frac{\partial E}{\partial q_i}\right|_{\vec{q}=\vec{q}(t)}$$

$$= q_i^{(t)} - \alpha \left[q_i^{(t)} - \frac{\sum_{\mu=1}^{p} x_{\mu i} e^{\beta S_\mu(t)}}{\sum_{\mu=1}^{p} e^{\beta S_\mu(t)}} \right]$$

$$= q_i^{(t)} - \alpha q_i^{(t)} + \alpha \frac{\sum_{\mu=1}^{p} x_{\mu i} e^{\beta S_\mu(t)}}{\sum_{\mu=1}^{p} e^{\beta S_\mu(t)}}$$

$$q_i^{(t+1)} = (1-\alpha)\, q_i^{(t)} + \alpha \frac{\sum_{\mu=1}^{p} x_{\mu i} e^{\beta S_\mu(t)}}{\sum_{\mu=1}^{p} e^{\beta S_\mu(t)}}$$

La cual es la regla de actualización para esta red, en particular para el caso $\alpha = 1$

$$q_i^{(t+1)} = \frac{\sum_{\mu=1}^{p} x_{\mu i} e^{\beta S_\mu(t)}}{\sum_{\mu=1}^{p} e^{\beta S_\mu(t)}}$$

Para simplificar, podemos definir el peso asociado a un patrón como

$$P_\mu(\vec{q}) = \frac{e^{\beta S_\mu}}{\sum_{\nu=1}^{p} e^{\beta S_\nu}}$$

Norma

Scanned with CamScanner

DD MM AA

Y la regla de actualización queda como

$$q_i^{(t+1)} = \sum_{\mu=1}^{P} p_\mu(\vec{q}^{(t)})\, x_{\mu i}$$

Con esta definición de peso asociado a un patrón, β - cómo es la distribución de la concentración de los pesos.

para $\beta \to 0$ podemos aproximar $e^{\beta S_\mu} \to 1 + \beta S_\mu$, por lo que en el límite, todos los patrones tienen el mismo peso

$$\lim_{\beta \to 0} q_i^{(t+1)} = \frac{1}{P} \sum_{\mu=1}^{P} x_{\mu i} \quad ; P \text{ el peso al que tiende}$$

Por otro lado, cuando $\beta \to \infty$, la exponencial del patrón con mayor acoplamiento domina la suma, si esto sucede para un único patrón $\hat{\mu}$, entonces

$$\lim_{\beta \to \infty} p_{\hat{\mu}} = 1$$

y los pesos de los demás tienden a cero, por tanto

$$\lim_{\beta \to \infty} q_i^{(t+1)} = x_{\hat{\mu} i}$$

Norma

Scanned with CamScanner