1. Regresión lineal multivariada desde máxima verosimilitud

En regresión lineal se busca modelar una variable continua Y a partir de variables de entrada X. Una forma de hacerlo es suponer que la salida observada está formada por una parte determinista $\theta^T x$, mas una parte aleatoria

Considerar el conjunto de datos dados por los pares (entrada, salida)

$$D = \{ x^{(i)}, y^{(i)} \}_{i=1}^{m} \quad ; \quad x^{(i)} = \begin{bmatrix} 1 \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix} \quad ; \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$$

Bajo la suposición, los datos de salida se podrán escribir entonces como:

$$y^{(i)} = \underbrace{\theta^T x^{(i)}}_{\text{parte determinista}} + \underbrace{\varepsilon^{(i)}}_{\text{Parte Aleatoria}} \quad ; \text{ con } \varepsilon^{(i)} \sim N(0, \sigma^2) \qquad (1)$$

$$\boxed{h(x) = \theta^T x}$$

Es decir, la salida real (valor que quiero predecir) es posiblemente una línea/plano... más un error aleatorio ε que se distribuye como una campana de Gauss centrada en 0. En promedio la predicción $\theta^T x$ es correcta, pero cada observación individual se desvía un poco por ruido.

Esta hipótesis permite construir una distribución para Y y a partir de ella, una función de verosimilitud para los datos observados.

1.1 Determine la distribución de

$$Y^{(i)} \mid X = x^{(i)}$$

R11 La esperanza es la media, valor esperado si se repite el exp.

De (1):

$$y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)} \quad \text{donde} \quad \varepsilon^{(i)} \sim N(0, \sigma^2) \rightarrow E[\varepsilon^{(i)}] = 0$$

$$N(0, \sigma^2) \rightarrow E[\varepsilon^{(i)}] = 0$$

$$\text{Varianza}(\varepsilon^{(i)}) = \sigma^2$$

Queremos la distrib. condicional de $Y^{(i)}$ dado que conocemos $X = x^{(i)}$, es decir $Y^{(i)} \mid X = x^{(i)}$

Sacando la media a ambos lados:

$$E[Y^{(i)} \mid X = x^{(i)}]$$
$$= E[\theta^T x^{(i)} + \varepsilon^{(i)} \mid X = x^{(i)}]$$
$$= E[\theta^T x^{(i)} \mid X = x^{(i)}] + E[\varepsilon^{(i)} \mid X = x^{(i)}]$$

Entonces:

- $E[\theta^T x^{(i)} \mid X = x^{(i)}] = \theta^T x^{(i)}$ porque es una constante. La media de una cte es la cte

- $E[\varepsilon^{(i)} \mid X = x^{(i)}] = E[\varepsilon^{(i)}] = E[N(0, \sigma^2)] = 0$ (media) $\varepsilon^{(i)}$ no depende de $x^{(i)}$

Por tanto: $\boxed{E[Y^{(i)} \mid X = x^{(i)}] = \theta^T x^{(i)}}$

Por otro lado, recordando la propiedad de la varianza:

$$Var(a+b) = Var(a) + Var(b) + 2\,Cov(a,b)$$

Si a y b son independientes : $Cov(a,b) = 0$.

Tomando la varianza a ambos lados:

$$Var(Y^{(i)} \mid X = x^{(i)}) = Var(\theta^T x^{(i)} + \varepsilon^{(i)} \mid X = x^{(i)})$$

$$= Var(\theta^T x^{(i)} \mid X = x^{(i)}) + Var(\varepsilon^{(i)} \mid X = x^{(i)}) + 2\,Cov(\theta^T x^{(i)}, \varepsilon^{(i)} \mid X = x^{(i)})$$

- $Var(\theta^T x^{(i)} \mid X = x^{(i)}) = 0$ ($\theta^T x^{(i)}$ → cte)
- $Var(\varepsilon^{(i)} \mid X = x^{(i)}) = Var(\varepsilon^{(i)}) = \sigma^2$ por hipótesis de distribución
- $2\,Cov(\theta^T x^{(i)}, \varepsilon^{(i)} \mid X = x^{(i)}) = 0$ Covarianza entre una cte y una función es 0.

Por tanto:

$$\boxed{Var(Y^{(i)} \mid X = x^{(i)}) = \sigma^2}$$

¿Cuál es la forma de la distribución?

Prop: Si $Z \sim N(\mu, \sigma^2)$ entonces $a + Z \sim N(a+\mu, \sigma^2)$ $\forall$ a constante.

Por tanto:

$$y^{(i)} = \theta^T \cancel{x^{(i)}}^{\text{cte}} + \varepsilon^{(i)} = \theta^T x^{(i)} + N(0,\sigma^2)$$
$$= N(\theta^T x^{(i)} + 0, \sigma^2)$$
$$= N(\underbrace{\theta^T x^{(i)}}_{\text{media}}, \underbrace{\sigma^2}_{\text{varianza}})$$

Así se sigue que:

$$Y^{(i)} \mid X = x^{(i)}; \theta \sim N(\theta^T x^{(i)}, \sigma^2) \quad (3)$$

1.2 Se sabe que la densidad de $\varepsilon^{(i)} \sim N(0,\sigma^2)$ está dada por:

$$p(\varepsilon) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{\varepsilon}{2\sigma^2}} \quad (4)$$

Por otro lado, de (1): $\varepsilon^{(i)} = y^{(i)} - \theta^T x$

Sustituyendo esto en (4):

$$p(y^{(i)} \mid x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x)^2}{2\sigma^2}} \quad (5)$$

→ Densidad de probabilidad de la variable aleatoria Y, evaluada en el valo $y^{(i)}$, dado que X toma el valor $x^{(i)}$ usando el parámetro θ ($x^{(i)}$ y θ conocidos)

1.3 Suponiendo independencia entre observaciones construir $L(\theta)$

p11

Dados los $x^{(i)}$ y θ, se puede construir la verosimilitud, la cual es la misma función de densidad conjunta de todos los datos observados.

Sin embargo, puede también verse como una función de θ. En este caso, se usa La función de likelihood dada por:

$$L(\theta) = L(\theta; X, \vec{y}) = p(\vec{y} \mid X; \theta)$$
$$L(\theta) = p(y^{(1)}, y^{(2)}, \dots y^{(m)} \mid x^{(1)}, \dots, x^{(m)}; \theta)$$

Asumiendo ahora que las observaciones son independientes, entonces la probabilidad conjunta es el producto de las probabilidades individuales, asi:

$$L(\theta) = \prod_{i=1}^{m} p(y^{(i)} \mid x^{(i)}; \theta) \qquad (6)$$

Es decir, cada ejemplo de entrenamiento $(x^{(i)}, y^{(i)})$ se genera de forma independiente. Esto a su vez significa que el ruido $\varepsilon^{(i)}$ de una observación no depende del ruido de la otra

Sustituyendo (5) en (6):

$$L(\theta) = \prod_{i=1}^{m} p(y^{(i)} \mid x^{(i)}; \theta) = \prod_{i=1}^{m} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x)^2}{2\sigma^2}}$$

1.4 obtener $\ell(\theta) = \ln(L(\theta))$

$$\ell(\theta) = \ln(L(\theta)) = \ln \prod_{i=1}^{m} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}}$$

$$\ell(\theta) = \sum_{i=1}^{m} \ln \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}} \right\}$$

$$\ell(\theta) = \sum_{i=1}^{m} \left\{ \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) + \ln\left(e^{-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}} \right) \right\}$$

$$\ell(\theta) = \sum_{i=1}^{m} \left\{ \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2} \right\}$$

$$\ell(\theta) = \sum_{i=1}^{m} \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \sum_{i=1}^{m} \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}$$

(7)

$$\ell(\theta) = m \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{1}{2\sigma^2} \sum_{i=1}^{m} (y^{(i)} - \theta^T x^{(i)})^2$$

Función de Verosimilitud

1.5 $m \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)$ ⟶ No depende de θ

$\frac{1}{2\sigma^2} \sum_{i=1}^{m} (y^{(i)} - \theta^T x^{(i)})^2$ ⟶ Depende de θ

1.6 Muestre que maximizar $\ell(\theta)$ equivale a minimizar la suma de residuos cuadrados.

R11. De (7):

$$\ell(\theta) = C - \frac{1}{2\sigma^2} \underbrace{\sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)}\right)^2}_{S(\theta)} \qquad (8)$$

Para maximizar $\ell(\theta)$:

$$\max \ell(\theta) = \max \left\{ C - \frac{1}{2\sigma^2} \sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)}\right)^2 \right\}$$

$$= \max \left\{ - \frac{1}{2\sigma^2} \sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)}\right)^2 \right\}$$

Maximizar $-\chi$ equivale a minimizar χ.

$$= \max \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)} \right)^2 \right\} = \min \left\{ \frac{1}{2\sigma^2} \sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)} \right)^2 \right\}$$

$$= \min \underbrace{\left\{ \sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)} \right)^2 \right\}}$$

Suma de los residuos cuadrados

Por tanto:

$$\max l(\theta) = \min \left\{ \sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)} \right)^2 \right\}$$

1.7 obtenga una función de coste de la forma

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$$

R11 Definiendo $h_\theta(x^{(i)})$ como:

$$h_\theta(x^{(i)}) = \theta^T x^{(i)}$$

$S(\theta)$ en (8) se escribe como:

$$S(\theta) = \sum_{i=1}^{m} \left(y^{(i)} - \theta^T x^{(i)} \right)^2 = \sum_{i=1}^{m} \left(y^{(i)} - h_\theta(x^{(i)}) \right)^2 = \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$$

$$\frac{S(\theta)}{2m} = \frac{1}{2m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)^2 = J(\theta)$$

Función de Coste

(9)

1.8 Siendo $S(\theta)$ la suma de residuos cuadrados, ya sabemos que minimizarla equivale a maximizar la verosimilitud.

Dado que de $S(\theta)$ se puede obtener $J(\theta)$ multiplicando por $\frac{1}{2m}$ una pregunta válida es: ¿sigue siendo válido decir que minimizar $J(\theta)$ es lo mismo que minimizar $S(\theta)$?

Para esto se debe demostrar que si $c>0$ es una constante! (no depende de θ) entonces:

$$\min[f(\theta)] = \min[c \cdot f(\theta)]$$

Dm//: Sea θ^* $\min f(\theta)$, es decir que

$$f(\theta^*) \leq f(\theta) \quad \forall\, \theta.$$

$$c\,f(\theta^*) \leq c\,f(\theta) \rightarrow \therefore\ \theta^* \text{ también es el punto donde } c\,f(\theta) \text{ alcanza su valor mínimo}$$

De esta manera: $\theta^* = \min f(\theta) = \min\ c \cdot f(\theta)$

Esto aplicado a $S(\theta)$ y $J(\theta)$ es:

$$\min[S(\theta)] = \min[J(\theta)]\ ;\ \text{con } m>0$$

2. Gradiente y Descenso por Gradiente

Una vez construida $J(\theta)$ el aprendizaje puede volverse como un problema de optimización. El gradiente indica como cambia el coste cuando cambia cada parámetro y permite construir una regla iterativa para encontrar valores de θ que reduzcan el error

2.1 Calcular $\frac{\partial h_\theta(x^{(i)})}{\partial \theta_j}$

R11:

Recordando que : $h_\theta(x^{(i)}) = \theta^T x^{(i)} = \sum_{k=0}^{n} \theta_k x_k^{(i)}$

$$\frac{\partial}{\partial \theta_j} h_\theta(x^{(i)}) = \frac{\partial}{\partial \theta_j} \sum_{k=0}^{n} \theta_k x_k^{(i)}$$

es $0 \ \forall j \neq k$

$$\frac{\partial h_\theta(x^{(i)})}{\partial \theta_j} = \frac{\partial}{\partial \theta_j} \theta_j x_j^{(i)} = \frac{\partial \theta_j}{\partial \theta_j} x_j^{(i)} + \theta_j \frac{\partial x^{(i)}}{\partial \theta_j}^{0} = x_j^{(i)}$$

$$\boxed{\frac{\partial h_\theta(x^{(i)})}{\partial \theta_j} = x_j^{(i)}} \qquad (10)$$

2.2 Hallar $\frac{\partial J}{\partial \theta_j}$

R11: De (9) : $J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \frac{\partial}{\partial \theta_j} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2 = \frac{1}{2m} \frac{\partial}{\partial \theta_j} \sum_{i=1}^{m} v_i(\theta)^2$$

con $v_i(\theta) = h_\theta(x^{(i)}) - y^{(i)}$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{2m} \sum_{i=1}^{m} \frac{\partial}{\partial \theta_j} \left(v_i(\theta) \right)^2 = \frac{1}{m} \sum_{i=1}^{m} v_i(\theta) \frac{\partial}{\partial \theta_j} v_i(\theta)$$

Usando (10): $\frac{\partial}{\partial \theta_j} v_i(\theta) = \frac{\partial}{\partial \theta_j} \left(h_\theta(x^{(i)}) - y^{(i)} \right) = \frac{\partial}{\partial \theta_j} h_\theta(x^{(i)}) = x_j^{(i)}$

Así:

$$\frac{\partial}{\partial \theta_j} J = \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)} \qquad (11)$$

2.4 Construir: $\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$; ":=" Actualizar el valor

R11 Usando (11)

$$\theta_j := \theta_j - \alpha \left\{ \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)} \right\}$$

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)} \qquad (12)$$

En cada iteración, a θ_j se le resta el promedio de que tan mal se predijo multiplicando por cuanto pesaba la característica j en cada dato.

2.5 Escriba la actualización para $j = 0, 1, 2, \ldots n$

Sabiendo que $x_0^{(i)} = 1$, entonces:

$$j=0 \quad \theta_0 := \theta_0 - \frac{\alpha}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})\cdot 1$$

$$j=1 \quad \theta_1 := \theta_1 - \frac{\alpha}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})\cdot x_1^{(i)}$$

$$j=2 \quad \theta_2 := \theta_2 - \frac{\alpha}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})\cdot x_2^{(i)}$$

$$\vdots$$

$$j=n \quad \theta_n := \theta_n - \frac{\alpha}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})\cdot x_n^{(i)}$$

2.6 Explicar por qué los parámetros deben actualizarse simultáneamente.

R//:

Recordando que: $\nabla J(\theta) = \left(\frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1} \cdots \frac{\partial J}{\partial \theta_n}\right)$ se define evaluado en un único punto $\theta = (\theta_0, \theta_1, \cdots \theta_n)$ fijo

Por otro lado, $h_\theta(x^{(i)})$ depende de todas las componentes de θ:

$$h_\theta(x^{(i)}) = \theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} + \cdots + \theta_n x_n^{(i)}$$

Así: $\frac{\partial J}{\partial \theta_1} = \frac{1}{m}\sum_{i=1}(h_\theta(x^{(i)}) - y^{(i)})\, x_1^{(i)}$ usa el valor de θ_0 dentro de $h_\theta(x^{(i)})$

Si se actualizaran en orden, por ejemplo, si se calcula

$\theta_0^{nuevo} = \theta_0 - \alpha \frac{\partial J}{\partial \theta_0}$ y antes de terminar la iteración se usa θ_0^{nuevo} para calcular $\frac{\partial J}{\partial \theta_1}$, se estaría calculando:

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_i \left(\theta_0^{\text{nuevo}} x_0^{(i)} + \theta_1 x_1^{(i)} + \dots - y^{(i)} \right) x_1^{(i)}$$

$h_\theta(x^{(i)})$ sería mezcla de valores nuevos y viejos de θ's

Ejemplo Numérico:

Ejemplo de calculo simultáneo

$$\frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2 = J(\theta)$$

i	$x_0^{(i)}$	$x_1^{(i)}$	$y^{(i)}$	con:
1	1	1	3	$\theta_0 = 0$
2	1	2	5	$\theta_1 = 0$
3	1	3	7	$\alpha = 0.1$

1. Calcular las predicciones con θ actual : $\theta = (0,0)$

$$h_\theta(x^{(i)}) = \theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} =$$

$$h_\theta(x^{(1)}) = \theta_0 x_0^{(1)} + \theta_1 x_1^{(1)} = 0$$
$$h_\theta(x^{(2)}) = \theta_0 x_0^{(2)} + \theta_1 x_1^{(2)} = 0$$
$$h_\theta(x^{(3)}) = \theta_0 x_0^{(3)} + \theta_1 x_1^{(3)} = 0$$

2. Calcular el error de cada predicción

$$h_\theta(x^{(1)}) - y^{(1)} = 0 - 3 = -3$$
$$h_\theta(x^{(2)}) - y^{(2)} = 0 - 5 = -5$$
$$h_\theta(x^{(3)}) - y^{(3)} = 0 - 7 = -7.$$

3. Calcular el gradiente : $\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$

- $\frac{\partial J}{\partial \theta_0} = \frac{1}{3}\left[(h_\theta(x^{(1)}) - y^{(1)})\, x_0^{(1)} + (h_\theta(x^{(2)}) - y^{(2)})\, x_0^{(2)} + (h_\theta(x^{(3)}) - y^{(3)})\, x_0^{(3)} \right]$

$= \frac{1}{3}[-3 - 5 - 7] = -5$ ★

- $\frac{\partial J}{\partial \theta_1} = \frac{1}{3}\left[(h_\theta(x^{(1)}) - y^{(1)})\, x_1^{(1)} + (h_\theta(x^{(2)}) - y^{(2)})\, x_1^{(2)} + (h_\theta(x^{(3)}) - y^{(3)})\, x_1^{(3)} \right]$

$= \frac{1}{3}[-3(1) + (-5)(2) + (-7)(3)] = -11.33$

4. Calcular los θ actualizados simultaneamente $\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$

$\theta_0 = \theta_0 - \alpha \frac{\partial J}{\partial \theta_0} = 0 - 0.1(-5) = 0.5$

$\theta = [0.5 \;,\; 1.33)$

$\theta_1 = \theta_1 - \alpha \frac{\partial J}{\partial \theta_1} = 0 - 0.1(-11.33) = 1.133$

Es decir, antes de la iteración, el modelo predecía siempre 0
Despues de un solo paso, θ se movió hacia valores que reducen el error.

5. Comparar los $J(\theta)$ $\quad J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2$

- Costo Inicial:

$J(\theta) = \frac{1}{2 \cdot 3}\left[(h_\theta(x^{(1)})^{0} - y^{(1)})^2 + (h_\theta(x^{(2)})^{0} - y^{(2)})^2 + (h_\theta(x^{(3)})^{0} - y^{(3)})^2 \right]$

$J(\theta) = \frac{1}{6}[3^2 + 5^2 + 7^2] = 13.83$

- Costo final: $\quad J(\theta) = \frac{1}{6}\left[(h_\theta(x^{(1)}) - y^{(1)})^2 + (h_\theta(x^{(2)}) - y^{(2)})^2 + (h_\theta(x^{(3)}) - y^{(3)})^2 \right]$

$h_\theta(x^{(1)}) = \theta_0 x_0^{(1)} + \theta_1 x_1^{(1)} = 0.5(1) + 1.33(1) = 1.63$

$h_\theta(x^{(2)}) = \theta_0 x_0^{(2)} + \theta_1 x_1^{(2)} = 0.5(1) + 1.33(2) = 2.76$

$h_\theta(x^{(3)}) = \theta_0 x_0^{(3)} + \theta_1 x_1^{(3)} = 0.5(1) + 1.33(3) = 3.89$

$$J(\theta) = \frac{1}{6}\left[\left(h_\theta(x^{(1)}) - y^{(1)}\right)^2 + \left(h_\theta(x^{(2)}) - y^{(2)}\right)^2 + \left(h_\theta(x^{(3)}) - y^{(3)}\right)^2\right]$$

$$= \frac{1}{6}\left[(1.63 - 3)^2 + (2.76 - 5)^2 + (3.89 - 7)^2\right] \approx 2.74$$

El costo final es mucho menor que el inicial

Ejemplo de calculo secuencial

1. Calcular el gradiente de θ_0. Tomamos (*)

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{3}\left[\left(h_\theta(x^{(1)}) - y^{(1)}\right)x_0^{(1)} + \left(h_\theta(x^{(2)}) - y^{(2)}\right)x_0^{(2)} + \left(h_\theta(x^{(3)}) - y^{(3)}\right)x_0^{(3)}\right]$$

$$= \frac{1}{3}\left[-3 - 5 - 7\right] = -5$$

2. Actualizar θ_0 $\qquad \theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$

$$\theta_0 := 0 - 0.1(-5) = 0.5$$

3. Calcular gradiente de θ_1

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{3}\left[\left(h_\theta(x^{(1)}) - y^{(1)}\right)x_1^{(1)} + \left(h_\theta(x^{(2)}) - y^{(2)}\right)x_1^{(2)} + \left(h_\theta(x^{(3)}) - y^{(3)}\right)x_1^{(3)}\right]$$

$$h_\theta(x^{(1)}) = \theta_0 x_0^{(1)} + \theta_1 x_1^{(1)} = 0.5(1) + 0(1) = 0.5$$
$$h_\theta(x^{(2)}) = \theta_0 x_0^{(2)} + \theta_1 x_1^{(2)} = 0.5(1) + 0(2) = 0.5$$
$$h_\theta(x^{(3)}) = \theta_0 x_0^{(3)} + \theta_1 x_1^{(3)} = 0.5(1) + 0(3) = 0.5$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{3}\left[(0.5 - 3)(1) + (0.5 - 5)(2) + (0.5 - 7)(3)\right] = -10.33$$

4. Actualizar θ_1

$$\theta_1 := 0 - 0.1(-10.33) = 1.03$$

5. Comparar los $J(\theta)$

Costo final: $J(\theta) = \frac{1}{6}\left[\left(h_\theta(x^{(1)}) - y^{(1)}\right)^2 + \left(h_\theta(x^{(2)}) - y^{(2)}\right)^2 + \left(h_\theta(x^{(3)}) - y^{(3)}\right)^2\right]$

$h_\theta(x^{(1)}) = \theta_0 x_0^{(1)} + \theta_1 x_1^{(1)} = 0.5\,(1) + 1.03\cdot(1) = 1.53$

$h_\theta(x^{(2)}) = \theta_0 x_0^{(2)} + \theta_1 x_1^{(2)} = 0.5\,(1) + 1.03\cdot(2) = 2.56$

$h_\theta(x^{(3)}) = \theta_0 x_0^{(3)} + \theta_1 x_1^{(3)} = 0.5\,(1) + 1.03\cdot(3) = 3.59$

$$J(\theta) = \frac{1}{6}\left[\left(h_\theta(x^{(1)}) - y^{(1)}\right)^2 + \left(h_\theta(x^{(2)}) - y^{(2)}\right)^2 + \left(h_\theta(x^{(3)}) - y^{(3)}\right)^2\right]$$

$$= \frac{1}{6}\left[(1.53-3)^2 + (2.56-5)^2 + (3.59-7)^2\right] \approx 3.27$$

Por tanto:

Método	θ_0	θ_1	$J(\theta)$
Simultáneo	0.5	1.133	2.74
Secuencial	0.5	1.033	3.27

El método simultáneo minimiza el costo.

3. Ecuación Normal

Para la regresión lineal también existe una solución analítica.
La idea es escribir el coste en forma matricial e imponer directamente la condición del mínimo.

Sea:

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix}; \quad Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}; \quad J(\theta) = \frac{1}{2m}(X\theta - y)^T(X\theta - y) \tag{13}$$

3.1 Expandir $(X\theta - y)^T(X\theta - y)$

$$\begin{aligned}(X\theta - y)^T(X\theta - y) &= [(X\theta)^T - y^T](X\theta - y) \\ &= (X\theta)^T X\theta - (X\theta)^T y - y^T X\theta + y^T y \\ &= \theta^T X^T X\theta - \theta^T X^T y - y^T X\theta + y^T y \end{aligned} \tag{14}$$

$$\theta^T X^T y = \theta^T X^T y^{TT} = (y^T X\theta)^T$$

Observar que: $[y^{(1)}\ y^{(2)} \cdots y^{(m)}]$ ($1 \times m$) $\begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix}$ ($m \times (n+1)$) $\begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ ($(n+1) \times 1$) = es escalar

Por tanto:

$$y^T X\theta = (y^T X\theta)^T = \theta^T X^T y$$

Así (14) queda como:

$$(X\theta - y)^T (X\theta - y) = \theta^T X^T X\theta - 2\theta^T X^T y + y^T y$$

3.2. Calcular $\nabla_\theta J(\theta) = 0$

Recordando que:

$$\nabla J(\theta) = \frac{1}{2m} \nabla \left[\theta^T X^T X\theta - 2\theta^T X^T y + y^T y \right]$$

$$= \frac{1}{2m} \left[\underbrace{\nabla(\theta^T X^T X\theta)}_{①} - 2\underbrace{\nabla(\theta^T X^T y)}_{②} + \underbrace{\nabla\, y^T y}_{③} \right] \quad (15)$$

Termino ①:

$$\nabla(\theta^T \underbrace{X^T X}_{A}\theta) = \nabla(\theta^T A\,\theta) = \nabla\left[\sum_{j=0}^{n} \sum_{k=0}^{n} \theta_j A_{jk} \theta_k \right]$$

(simétrica)

$$= \frac{\partial}{\partial \theta_l} \left[\sum_{j=0}^{n} \sum_{k=0}^{n} \theta_j A_{jk} \theta_k \right]$$

$$= \frac{\partial}{\partial \theta_l} (\theta_j A_{jk} \theta_k)$$

$$= A_{jk} \left[\frac{\partial \theta_j}{\partial \theta_l} \theta_k + \theta_j \frac{\partial \theta_k}{\partial \theta_l} \right]$$

$$= A_{jk} \left[\delta_{jl} \theta_k + \delta_{kl} \theta_j \right]$$

$$= A_{lk} \theta_k + A_{jl} \theta_j$$

$$= \sum_{k=0}^{n} A_{lk} \theta_k + \sum_{j=0}^{n} \theta_j A_{jl}$$

$$= (A\theta)_l + (A^T\theta)_l \qquad \text{Como } A \text{ es simétrica:}$$

$$= 2\,(A\theta)_l$$

Por tanto: $\nabla(\theta^T X^T X \theta) = 2A\theta = 2 X^T X \theta$

Termino ②:

$$\nabla(\theta^T \underbrace{X^T y}_{b}) = \nabla(\theta^T b) = \frac{\partial}{\partial \theta_l} \sum_{j=0}^{n} \theta_j b_j = \frac{\partial}{\partial \theta_l} \theta_j b_j = \delta_{lj} b_j = b_l$$

vector $(n+1) \times 1$

Por tanto: $\nabla(\theta^T X^T y) = b = X^T y$

Termino ③

$$\nabla y^T y = 0.$$

Sustituyendo ①, ②, ③ en (15)

$$\nabla J(\theta) = \frac{1}{2m}\left[2 X^T X \theta - 2 X^T y \right]$$

$$\nabla J(\theta) = \frac{1}{m}\left[X^T X \theta - X^T y \right]$$

3.3 Imponer $\nabla J(\theta) = 0$

$$\nabla J(\theta) = \frac{1}{m}\left[X^T X \theta - X^T y \right] = 0$$

3.4 $$\nabla J(\theta) = X^T X \theta - X^T y = 0 \longrightarrow X^T X \theta = X^T y$$

Ecuaciones Normales

3.5 Si X^TX es invertible, despejar θ.

$$X^TX\theta = X^Ty$$
$$(X^TX)^{-1}X^TX\theta = (X^TX)^{-1}X^Ty$$
$$I\theta = (X^TX)^{-1}X^Ty$$
$$\theta = (X^TX)^{-1}X^Ty$$

$(n+1)\times(n+1)$ $\quad$ $(n+1)\times 1$

Por tanto:

$$\theta = (X^TX)^{-1}X^Ty$$

Ecuación normal

3.6 Comparar esta solución con descenso por gradiente:

Cuál es iterativa? R// descenso por gradiente es iterativo. Se parte de un θ inicial y se corrige sucesivamente.

Cual es la analitica? R// La ecuación normal es la analitica dado que al ser evaluada una sola vez con los datos, devuelve el valor exacto sin aproximaciones

Cuándo puede fallar la inversión? R// poder despejar θ es posible solo si X^TX es invertible, lo cual ocurre cuando las $n+1$ columnas de X son linealmente independientes

Casos en los que puede fallar:

#1 Hay mas características que datos. $(n+1 > m)$

Si hay menos observaciones que parámetros a estimar, X tendrá mas columnas que filas. En este caso

si $\text{ran}(X) < n+1 \longmapsto X^T X$ no tiene rango completo y por tanto no es invertible

#2. Características linealmente dependientes

Como ejemplo, columnas de X que sean multiplos de otras

#3. Casos de colinealidad

Si las características están muy correlacionadas, sin ser necesariamente dependientes, entonces $X^T X$ queda mal condicionada.

4. Regresión logística de la familia exponencial

En clasificación binaria, Y toma dos valores posibles. Para esto se usa la distribución de Bernoulli. Al escribirla como miembro de la familia exponencial, se obtiene una relación entre su parámetro natural (η) y una función lineal de x.

Considerar: $$p(y;\eta) = b(y)\, e^{[\eta T(y) - a(\eta)]} \quad (16)$$

y para $Y \in \{0,1\}$ $$p(y;\phi) = \phi^{y}(1-\phi)^{1-y} \quad (17)$$

4.1 Reescribir Bernoulli usando una exponencial

Se dice que una clase de distribuciones está en la familia de exponenciales si se puede escribir de la forma:

$$p(y;\eta) = b(y)\, e^{[\eta T(y) - a(\eta)]}$$

η: parámetro natural / canónico
$T(y)$: suficiencia estadística.
$a(\eta)$: log función partición

$$a = e^{\log(a)}$$

Partiendo de (17):

$$p(y;\phi) = e^{\log(\phi^{y}(1-\phi)^{1-y})}$$

$$= e^{\log(\phi^{y}) + \log(1-\phi)^{1-y}}$$

$$= e^{y\log\phi + (1-y)\log(1-\phi)}$$

$$= e^{y\log\phi + \log(1-\phi) - y\log(1-\phi)}$$

$$= e$$

$$= e^{y[\log\phi - \log(1-\phi)] + \log(1-\phi)}$$

$$p(y;\phi) = e^{y \log\left(\frac{\phi}{1-\phi}\right) + \log(1-\phi)}$$

4.2. Identificar el parámetro natural η

RII: Comparando con (16):

- $T(y) = y$
- $\eta = \log\left(\frac{\phi}{1-\phi}\right)$
- $b(y) = 1$
- $a(\eta) = -\log(1-\phi)$

4.4 Despejar ϕ en función de η

$$\eta = \log\left(\frac{\phi}{1-\phi}\right)$$

$$e^{\eta} = e^{\log\left(\frac{\phi}{1-\phi}\right)} = \frac{\phi}{1-\phi}$$

$$e^{\eta}(1-\phi) = \phi$$

$$e^{\eta} - e^{\eta}\phi = \phi \rightarrow e^{\eta} = \phi(1+e^{\eta}) \rightarrow \phi = \frac{e^{\eta}}{1+e^{\eta}}$$

$$\phi = \frac{1}{\frac{1}{e^{\eta}} + 1} \rightarrow \boxed{\phi = \frac{1}{e^{-\eta}+1} = \sigma(\eta)}$$

4.5 Si $\eta = \theta^T x$ obtener : $P_\theta(Y=1 \mid X=x)$

R// De la distribución de Bernoulli, $p(y;\phi) = \phi^y (1-\phi)^{1-y}$

$$P(Y=1) = \phi \quad y \quad P(Y=0) = 1-\phi.$$

es decir, ϕ es la definición misma de la distribución

$$\phi = \frac{1}{e^{-\eta}+1} = P(Y=1) = \frac{1}{e^{-\theta^T x}+1} = P_\theta(Y=1 \mid X=x) \qquad (18)$$

4.6 Por tanto, definiendo

$$P_\theta(Y=1 \mid X=x) = \frac{1}{1+e^{-\theta^T x}} \equiv h_\theta(x) \qquad (19)$$

4.7 Obtener $P_\theta(Y=0 \mid X=x)$

R// De manera similar, usando (18) y (19)

$$P(Y=0) = 1-\phi = 1 - \frac{1}{1+e^{-\theta^T x}}$$

$$= \frac{1+e^{-\theta^T x} - 1}{1+e^{-\theta^T x}}$$

$$= \frac{e^{-\theta^T x}}{1+e^{-\theta^T x}} = P_\theta(Y=0 \mid X=x) = 1 - h_\theta(x)$$

(20)

5. Likelihood y función de coste logística

Una vez obtenida $h_\theta(x)$, cada observación puede interpretarse probabilísticamente.

Para $y=1$ el modelo asigna probabilidad $h_\theta(x)$
Para $y=0$ el modelo asigna probabilidad $1-h_\theta(x)$

A partir de ambas posibilidades se construye una única expresión para la verosimilitud.

5.1 Escriba una expresión única para: $p(y^{(i)} \mid x^{(i)}; \theta)$ válida para $y^{(i)}=0$ y $y^{(i)}=1$

R// De (19) y (20) se tiene que:

$$P_\theta(Y=1 \mid X=x) = h_\theta(x) = \phi$$

$$P_\theta(Y=0 \mid X=x) = 1-h_\theta(x) = 1-\phi$$

Sustituyendo estas expresiones en Bernoulli se tiene que:

$$p(y;\phi) = \phi^y (1-\phi)^{1-y}$$
$$= h_\theta(x)^y (1-h_\theta(x))^{1-y}$$

(21)
$$\boxed{p(y^{(i)} \mid x^{(i)}; \theta) = h_\theta(x^{(i)})^{y^{(i)}} \left(1-h_\theta(x^{(i)})\right)^{1-y^{(i)}}}$$

Para $y^{(i)}=0 \rightarrow p(0 \mid x^{(i)}, \theta) = 1-h_\theta(x^{(i)})$
Para $y^{(i)}=1 \rightarrow p(1 \mid x^{(i)}, \theta) = h_\theta(x^{(i)})$

5.2 Construir la verosimilitud para m observaciones

R// Recordando que la verosimilitud es la probabilidad conjunta de todos los datos observados, vista como función de θ es:

$$L(\theta) = p(y \mid X; \theta)$$

y que las observaciones son independientes. Bajo esta suposición y usando (21):

$$L(\theta) = \prod_{i=1}^{m} p(y^{(i)} \mid x^{(i)}; \theta)$$

$$\boxed{L(\theta) = \prod_{i=1}^{m} h_\theta(x^{(i)})^{y^{(i)}} \left(1 - h_\theta(x^{(i)})\right)^{1-y^{(i)}}}$$

5.3 Calcular la log-verosimilitud

$$l(\theta) = \ln L(\theta) = \sum_{i=1}^{m} \ln\left[h_\theta(x^{(i)})^{y^{(i)}} \left(1 - h_\theta(x^{(i)})\right)^{1-y^{(i)}} \right]$$

$$= \sum_{i=1}^{m} \left[\ln\left(h_\theta(x^{(i)})\right)^{y^{(i)}} + \ln\left(\left(1 - h_\theta(x^{(i)})\right)^{1-y^{(i)}}\right) \right]$$

$$l(\theta) = \sum_{i=1}^{m} \left[y^{(i)} \ln\left(h_\theta(x^{(i)})\right) + \left(1 - y^{(i)}\right) \ln\left(1 - h_\theta(x^{(i)})\right) \right]$$

5.4 Cambiar el signo y normalizar por m para obtener $J(\theta)$

Recordar que buscamos maximizar $l(\theta)$. Al igual que el procedimiento anterior para el algoritmo iterativo, el valor θ que maximiza $l(\theta)$ es el mismo valor de θ que minimiza $-l(\theta)$. Esto es independiente al multiplicar por una constante $\left(\frac{1}{m}\right)$. (Ver sección 1.8)

De esta manera se puede definir:

$$J(\theta) \equiv \frac{1}{m}\left[-l(\theta)\right] \qquad \text{con } \frac{1}{m} > 0$$

$$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[\, y^{(i)} \ln\left(h_\theta(x^{(i)})\right) + \left(1-y^{(i)}\right)\ln\left(1-h_\theta(x^{(i)})\right)\right]$$

$$\boxed{J(\theta) = \frac{1}{m}\sum_{i=1}^{m}\left[-y^{(i)} \ln\left(h_\theta(x^{(i)})\right) - \left(1-y^{(i)}\right)\ln\left(1-h_\theta(x^{(i)})\right)\right]}$$

Función de Coste (22)

5.5 Identificar la entropía cruzada binaria

RII Dadas dos distribuciones de probabilidad sobre las mismas categorías c. la entropía cruzada entre ellas es:

$$H(p,q) = -\sum_{c} p(c)\log q(c)$$

donde: p es la distribución real
q es la distribución predicha

En el caso binario, las categorías son $y=0$ y $y=1$, así:

$$H(p,q) = -\sum_{c} p(c)\log q(c) = -\left[p(1)\log q(1) + p(0)\log q(0)\right]$$

Identificando:

- $p(1)$: probabilidad real de que la categoría sea 1 $\rightarrow y^{(i)}$
- $p(0)$: probabilidad real de que la categoría sea 0 $\rightarrow 1-y^{(i)}$
- $q(1)$: probabilidad predicha de que la categoría sea 1 $\rightarrow h_\theta(x^{(i)})$
- $q(0)$: probabilidad predicha de que la categoría sea 0 $\rightarrow 1-h_\theta(x^{(i)})$

Luego, sustituyendo en $H(p,q)$:

$$H(p,q) = -[\,p(1)\log q(1) + p(0)\log q(0)\,]$$

$$H(p,q) = -[\,y^{(i)}\log h_\theta(x^{(i)}) + (1-y)\log(1-h_\theta(x^{(i)}))\,] \quad \text{comparando con (22)}$$

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m} H(p^{(i)}, q^{(i)}) \qquad (23)$$

5.6 Calcular $\frac{\partial J}{\partial \theta_j}$

R// Recordar que del desarrollo 4.5 y 4.6: $\eta = \theta^T x \rightarrow \phi = \frac{1}{e^{-\eta}+1} = \sigma(\eta) = \sigma(\theta^T x)$

Ahora, sea: $z^{(i)} = \theta^T x^{(i)} \longrightarrow h_\theta(x^{(i)}) = \sigma(z^{(i)}) = \frac{1}{1+e^{-z}}$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m}\sum_{i=1}^{m}\frac{\partial}{\partial \theta_j}\left[\,y^{(i)}\ln(h_\theta(x^{(i)})) + (1-y^{(i)})\ln(1-h_\theta(x^{(i)}))\,\right]$$

$$= -\frac{1}{m}\left[\,\underbrace{\frac{\partial}{\partial \theta_j}\{y^{(i)}\ln(h_\theta(x^{(i)}))\}}_{①} + \underbrace{\frac{\partial}{\partial \theta_j}\{(1-y^{(i)})\ln(1-h_\theta(x^{(i)}))\}}_{②}\,\right] \qquad (24)$$

Término ①:

$$\frac{\partial}{\partial \theta_j}\{y^{(i)}\ln(h_\theta(x^{(i)}))\} = y^{(i)}\frac{\partial}{\partial \theta_j}\ln(h_\theta(x^{(i)})) + \ln(h_\theta(x^{(i)}))\frac{\partial y^{(i)}}{\partial \theta_j}$$

$$= y^{(i)}\frac{1}{h_\theta(x^{(i)})}\frac{\partial h_\theta(x^{(i)})}{\partial \theta_j}$$

$$\frac{\partial h_\theta(x^{(i)})}{\partial \theta_j} = \frac{\partial}{\partial \theta_j}\sigma(z^{(i)}) = \sigma'(z^{(i)}) \cdot \frac{\partial z^{(i)}}{\partial \theta_j}$$

$$= -1\left(1+e^{-z}\right)^{-2}\left(-e^{-z}\right) \cdot \frac{\partial\left(\theta^T x^{(i)}\right)}{\partial \theta_j}$$

$$= \frac{e^{-z}}{\left(1+e^{-z}\right)^2} \cdot x_j^{(i)}$$

$$= \sigma(z)\left(1-\sigma(z)\right) \cdot x_j^{(i)}$$

$$= h_\theta(x^{(i)})\left(1-h_\theta(x^{(i)})\right) \cdot x_j^{(i)} \qquad (**)$$

$$\rightarrow \frac{\partial}{\partial \theta_j}\left\{y^{(i)} \ln\left(h_\theta(x^{(i)})\right)\right\} = y^{(i)} \frac{1}{h_\theta(x^{(i)})} h_\theta(x^{(i)})\left(1-h_\theta(x^{(i)})\right) \cdot x_j^{(i)}$$

$$= y^{(i)}\left(1-h_\theta(x^{(i)})\right) \cdot x_j^{(i)}$$

Termino ②

$$\frac{\partial}{\partial \theta_j}\left\{\left(1-y^{(i)}\right) \ln\left(1-h_\theta(x^{(i)})\right)\right\}$$

$$= \left(1-y^{(i)}\right)\frac{\partial}{\partial \theta_j} \ln\left(1-h_\theta(x^{(i)})\right) + \ln\left(1-h_\theta(x^{(i)})\right)\frac{\partial}{\partial \theta_j}\left(1-y^{(i)}\right)$$

$$= \left(1-y^{(i)}\right) \cdot \frac{1}{\left(1-h_\theta(x^{(i)})\right)} \frac{\partial}{\partial \theta_j}\left(1-h_\theta(x^{(i)})\right)$$

$$= \left(1-y^{(i)}\right) \cdot \frac{1}{\left(1-h_\theta(x^{(i)})\right)} \cdot (-1) \cdot \frac{\partial h_\theta(x^{(i)})}{\partial \theta_j}$$

$$= \left(1-y^{(i)}\right) \cdot \frac{1}{\left(1-h_\theta(x^{(i)})\right)} \cdot (-1)\, h_\theta(x^{(i)})\left(1-h_\theta(x^{(i)})\right) \cdot x_j^{(i)}$$

usando (**)

$$= -(1 - y^{(i)})\, h_\theta(x^{(i)})\, x_j^{(i)}$$

Sustituyendo ambos términos en (24):

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^{m} \left[y^{(i)} (1 - h_\theta(x^{(i)}))\, x_j^{(i)} - (1 - y^{(i)})\, h_\theta(x^{(i)})\, x_j^{(i)} \right]$$

$$\frac{\partial J}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^{m} \left[\left(y^{(i)} - \cancel{y^{(i)} h_\theta(x^{(i)})} - h_\theta(x^{(i)}) + \cancel{y^{(i)} h_\theta(x^{(i)})} \right) x_j^{(i)} \right]$$

$$\boxed{\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_j^{(i)}} \quad (25)$$

Lo cual es equivalente con la ecuación (11)

5.7 Escribir la regla de descenso por gradiente.

Al igual que en 2.4, dado que ∇J apunta hacia donde J crece más rápido, para reducir J hay que moverse en la dirección contraria:

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

Sustituyendo (25):

$$\boxed{\theta_j := \theta_j - \alpha \left\{ \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_j^{(i)} \right\}}$$

5.8 Comparar

Regresión lineal:

$$\theta_j := \theta_j - \alpha \left\{ \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_j^{(i)} \right\} \quad ; \quad h_\theta(x^{(i)}) = \theta^T x^{(i)}$$

Regresión logística

$$\theta_j := \theta_j - \alpha \left\{ \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_j^{(i)} \right\} \quad ; \quad h_\theta(x^{(i)}) = \sigma(\theta^T x^{(i)})$$

6. Regularización

Un buen ajuste de los datos de entrenamiento, no garantiza una buena generalización. Una forma de controlar modelos con parámetros grandes es añadir una penalización a la función de coste. Para regularización L2

$$\frac{\lambda}{2m} \sum_{j=1}^{n} \theta_j^2$$

λ: controla cuanto pesa esta penalización frente al ajuste de los datos

6.1 El coste regularizado para regresión lineal

De (9):

$$J(\theta) = \underbrace{\frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2}_{\text{Ajuste a los datos}} + \frac{\lambda}{2m} \sum_{j=1}^{n} \theta_j^2$$

$$J(\theta)_r = \frac{1}{2m} \sum_{i=1}^{m} (\theta^T x^{(i)} - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^{n} \theta_j^2$$

6.2 Calcular $\frac{\partial J}{\partial \theta_j}$; $j \geq 1$

$$\frac{\partial}{\partial \theta_j} J(\theta)_r = \underbrace{\frac{\partial}{\partial \theta_j}\left\{\frac{1}{2m}\sum_{i=1}^{m}\left(\theta^T x^{(i)} - y^{(i)}\right)^2\right\}}_{①} + \underbrace{\frac{\partial}{\partial \theta_j}\left\{\frac{\lambda}{2m}\sum_{j=1}^{n}\theta_j^2\right\}}_{②} \qquad (26)$$

Termino ①:

De (11) $$\frac{\partial}{\partial \theta_j} J = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right) x_j^{(i)}$$

Termino ②

$$\frac{\partial}{\partial \theta_j}\left\{\frac{\lambda}{m}\sum_{j=1}^{n}\theta_j^2\right\} = \frac{\lambda}{2m}\frac{\partial}{\partial \theta_j}\theta_j^2 = \frac{\lambda}{2m} 2\theta_j$$

Asi $$\boxed{\frac{\partial J_r}{\partial \theta_j} = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)^2 x_j^{(i)} + \frac{\lambda}{m}\theta_j} \qquad j \geq 1 \qquad (27)$$

6.3 Caso $j = 0$

De (26)

$\{\theta_1^2, \theta_2^2, \ldots\} - \theta_0^2$

$0 \rightarrow$

$$\frac{\partial}{\partial \theta_0} J(\theta)_r = \frac{\partial}{\partial \theta_0}\left\{\frac{1}{2m}\sum_{i=1}^{m}\left(\theta^T x^{(i)} - y^{(i)}\right)^2\right\} + \frac{\partial}{\partial \theta_0}\left\{\frac{\lambda}{2m}\sum_{K=1}^{n}\theta_K^2\right\}$$

$1 \rightarrow$

$$\boxed{\frac{\partial}{\partial \theta_0} J(\theta)_r = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right) x_0^{(i)}} \qquad j = 0 \qquad (28)$$

6.4. Construir la actualización para $j \geq 1$

$$\theta_j := \theta_j - \alpha \frac{\partial J_r(\theta)}{\partial \theta_j}$$

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

$$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

Regularizada

$j = 1, 2, \ldots n$

$$\theta_j := \theta_j - \frac{\alpha}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)} \quad (12)$$

Sin Regularizar

6.5 Reorganizar hasta obtener

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \text{termino de datos}$$

R11 $$\theta_j := \theta_j - \frac{\alpha \lambda}{m} \theta_j - \frac{\alpha}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

$$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \frac{\alpha}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

6.6 Interpretar el factor $\left(1 - \frac{\alpha \lambda}{m} \right)$

Sin Regularizar $$\theta_j := 1 \cdot \theta_j - \frac{\alpha}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

Regularizada: $$\theta_j := \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \frac{\alpha}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

$\alpha > 0$ Tasa de aprendizaje

$\lambda > 0$ Parámetro de Regularización

$m > 0$ # de observaciones

$$0 < \left(1 - \frac{\alpha\lambda}{m}\right) < 1$$

Multiplicar por este factor, el algoritmo reduce un poco el valor de θ_j. En cada iteración, el peso θ_j decae multiplicativamente antes de ajustarse según los datos

6.7 Escribir el coste regularizado para la regresión logística.

Recordando que el coste sin regularizar es:

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m}\left[-y^{(i)}\ln\left(h_\theta(x^{(i)})\right) - (1-y^{(i)})\ln\left(1-h_\theta(x^{(i)})\right)\right]$$

el regularizado es:

$$J(\theta)_r = \frac{1}{m}\sum_{i=1}^{m}\left[-y^{(i)}\ln\left(h_\theta(x^{(i)})\right) - (1-y^{(i)})\ln\left(1-h_\theta(x^{(i)})\right)\right] + \frac{\lambda}{2m}\sum_{j=1}^{n}\theta_j^2$$

6.8 Obtener el gradiente $\nabla J_r(\theta)$

$$\frac{\partial J(\theta)_r}{\partial \theta_j} = \frac{\partial}{\partial \theta_j}\left[\frac{1}{m}\sum_{i=1}^{m}\left[-y^{(i)}\ln\left(h_\theta(x^{(i)})\right) - (1-y^{(i)})\ln\left(1-h_\theta(x^{(i)})\right)\right]\right] = ①$$

$$+ \quad \frac{\partial}{\partial \theta_j}\left[\frac{\lambda}{2m}\sum_{j=1}^{n}\theta_j^2\right] \quad ②$$

La parte ① se obtiene de (25)

$$① = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_j^{(i)}$$

La parte ② se obtiene de 6.3

$$② = \frac{\partial}{\partial \theta_0} \frac{\lambda}{2m} \sum_{K=1}^{n} \theta_K^2 = \begin{cases} \frac{\lambda \theta_j}{m} & \text{si } j \geq 1 \\ 0 & \text{si } j = 0 \end{cases}$$

Por tanto: $\frac{\partial J_r}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_j^{(i)} + \frac{\lambda \theta_j}{m}$ $\quad j = 1, 2, \dots n$

Así: $\boxed{\frac{\partial J_r}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_0^{(i)}}$ $\quad h_\theta(x^{(i)}) = \sigma(\theta^T x^{(i)})$

Luego: $\theta_j := \theta_j \left(1 - \alpha \frac{\lambda}{m}\right) - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})\, x_j^{(i)}$ $\quad j \geq 1$

∴ La regla de actualización regularizada fue exactamente la misma forma en regresión lineal y logística

6.8. Por qué no se regulariza θ_0 normalmente?

θ_0 no está asociado a ninguna característica real de los datos, por defecto $x_0^{(i)} = 1$:

$$h_\theta(x^{(i)}) = \theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} + \dots \theta_n x_n^{(i)}$$

Dado que el objetivo de penalizar $\sum_j \theta_j^2$ es evitar que el modelo dependa fuertemente de alguna característica en particular