Laboratorio 10

Movimiento Browniano y Dinámica de Langevin con score model

Valentina Pérez Cadavid

2026

¿ Qué problema resuelve un score model?

Supongamos que queremos generar datos nuevos que se parezcan a los reales, pero que no sean copias de ellos.

Para esto, se necesita saber qué tan probable es cada foto $p(x)$:

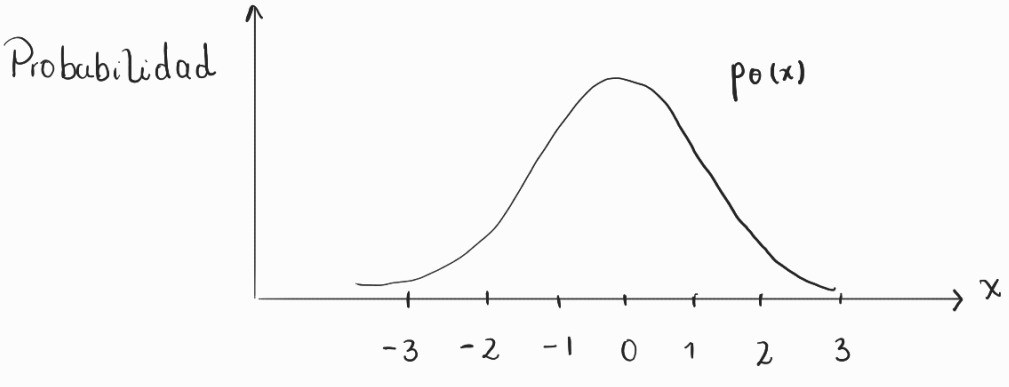
→ img parecida a la real → prob. alta

→ img con ruido aleatorio → prob baja

Sin embargo, aprender $p(x)$ se hace difícil en la práctica dado que se debe cumplir que la suma de las prob. de todas las img posibles deben ser 1

En lugar de averiguar qué tan probable es una img, nos podemos preguntar: ¿ Desde una foto dada, ¿hacia donde debo moverme para que se vea más real ?

La respuesta puede asociarse a una flecha. Esto es el score siempre apunta en la dirección de los datos mas probables



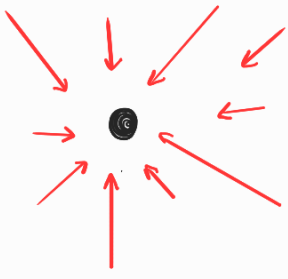
- Las flechas siempre apuntan hacia donde hay mas datos
- Cuanto mas lejos, mas grande la flecha



Score model = red neuronal que aprendió a dibujar las flechas a partir de los datos.

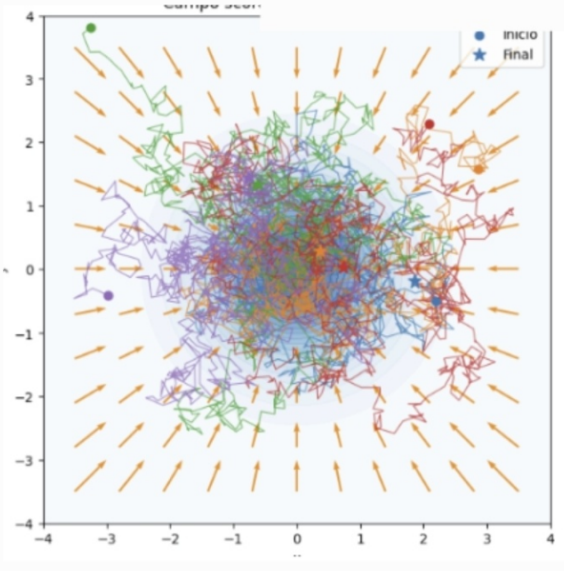
¿ Cómo se usan los scores para crear datos ?

1. Seguir las flechas: se sueltan partículas al azar y en cada paso se mueven en la dirección de la flecha.
   El problema está en que si se quieren nuevas img, todas saldrían iguales porque se van hacia la foto más probable



2. Añadir aleatoriedad: se sueltan partículas al azar y en cada paso se mueven en en la dirección de la flecha pero sometidas a un ruido aleatorio, es decir:

Mov. Browniano + flecha = Langevine



→ Movimiento Browniano: sin fuerza

→ Dinámica de Langevin: movimiento browniano + fuerza

Partícula sin fuerza

Para una partícula inmersa en un líquido que experimenta fricción y fluctuaciones, la fuerza total sobre la partícula es:

1. Con inercia:

$$m\frac{d^2x}{dt^2} = -\gamma\frac{dx}{dt} + \xi(t)$$

γ: coeficiente de fricción

$\xi(t)$: fuerza fluctuante

Cambia de valor de forma independiente en cada dt.

↓

En lugar de cambios en cada dt, se trabaja con sumas de cambios durante un intervalo $\Delta W \sim N(0, \Delta t)$:

$$\Delta W_n = \sqrt{\Delta t}\, Z_n \quad ; \quad Z_n \sim N(0,1)$$

$$dx_t = v_t\, dt$$

$$m\, dv_t = -\gamma\, v_t\, dt + \sqrt{2\gamma k_B T}\, dW_t$$

↓

$$v_{n+1} = v_n - \frac{\gamma}{m} v_n \Delta t + \frac{\sqrt{2\gamma k_B T}}{m}\Delta t\, Z_n$$

$$x_{n+1} = x_n + v_n \Delta t$$

2. Sin Inercia: Régimen Sobreamortiguado

$$m\frac{d^2x}{dt^2} = -\gamma\frac{dx}{dt} + \xi(t) \qquad \left(\frac{d^2x}{dt^2} \to 0\right)$$

↓

$$\frac{\gamma}{\gamma}\frac{dx}{dt}dt = \frac{\xi(t)}{\gamma}dt$$

↓

$$dx_t = \frac{\sqrt{2\gamma k_B T}}{\gamma}\, dW_t$$

↓

$$dx_t = \sqrt{\frac{2k_B T}{\gamma}}\, dW_t$$

↓

$$dx_t = \sqrt{2D}\, dW_t \quad ; \quad D = \frac{k_B T}{\gamma}$$

↓

$$x_{n+1} = x_n + \sqrt{2D\Delta t}\, Z_n$$

Partícula con Fuerza

1. Con inercia:

fricción + resorte + fuerzas

$$m\frac{d^2x}{dt^2} = -\gamma\frac{dx}{dt} - \kappa x + \xi(t)$$

$$dx_t = v_t\,dt$$

$$m\,dv_t = -\gamma v_t\,dt - \kappa x_t\,dt + \sqrt{2\gamma k_B T}\,dW_t$$

$$v_{n+1} = v_n - \frac{\gamma}{m}v_n\,\Delta t - \frac{\kappa}{m}x_n\Delta t + \sqrt{\frac{2\gamma k_B T}{m}}\sqrt{\Delta t}\,z_n$$

$$x_{n+1} = x_n + v_n\,\Delta t$$

2. Sin Inercia: Régimen Sobreamortiguado

$$m\frac{d^2x}{dt^2} = -\gamma\frac{dx}{dt} - \kappa x + \xi(t)$$

($m\frac{d^2x}{dt^2} \to 0$)

$$\frac{\gamma}{\gamma}\frac{dx}{dt}dt = \left(-\frac{\kappa x}{\gamma} + \frac{\xi(t)}{\gamma}\right)dt$$

$$dx_t = -\frac{\kappa}{\gamma}x_t\,dt + \frac{\xi(t)}{\gamma}\,dt$$

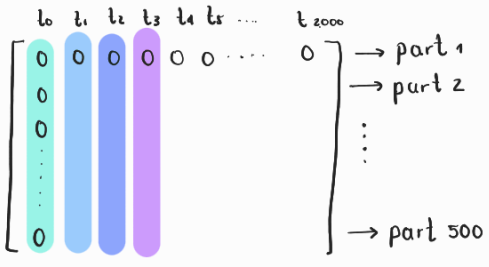
$$dx_t = -\frac{\kappa}{\gamma}x_t\,dt + \frac{\sqrt{2\gamma k_B T}\,dW_t}{\gamma}$$

$$dx_t = -\frac{\kappa}{\gamma}x_t\,dt + \sqrt{\frac{2k_BT}{\gamma}}\,dW_t$$

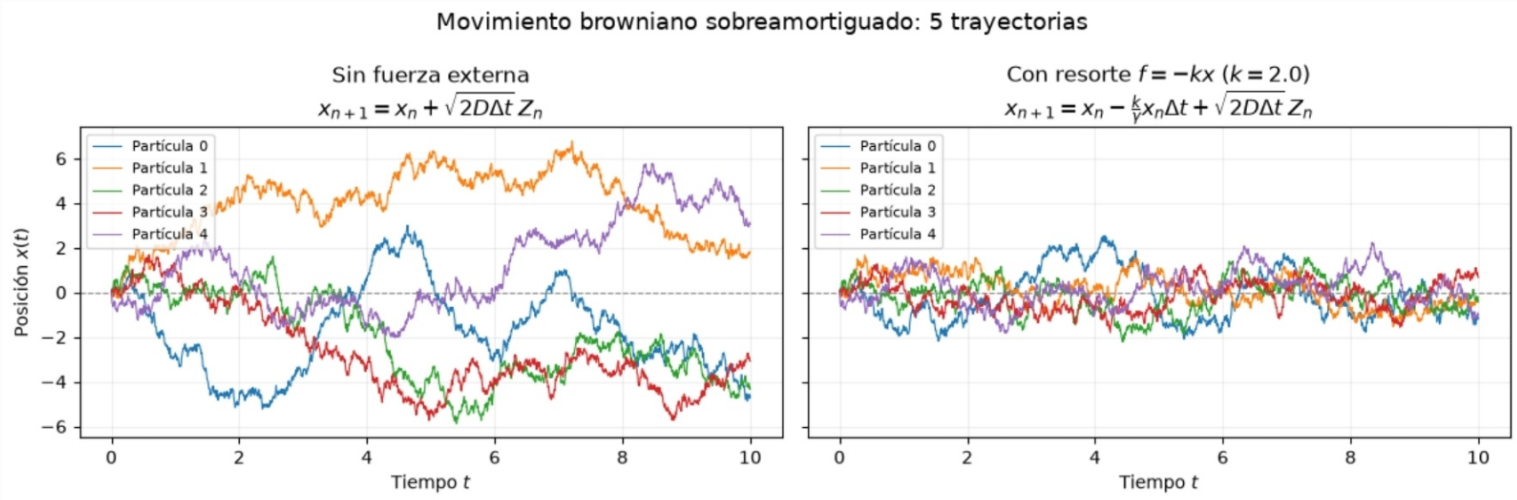
$$dx_t = -\frac{\kappa}{\gamma}x_t\,dt + \sqrt{2D}\,dW_t\,,\quad D = \frac{k_BT}{\gamma}$$

$$x_{n+1} = x_n - \frac{\kappa}{\gamma}x_n\,\Delta t + \sqrt{2D\,\Delta t}\,z_n$$

$x_libre =$



↳ aplicar ruidos aleatorios a cada partícula en cada t_i



Hasta aquí: mov. browniano libre

Dinámica de Langvin con una fuerza $f = -kx$

Dinámica con modelo tipo Score

Ahora, se reemplazará el resorte por un score:

$$x_{n+1} = x_n - \frac{k}{\gamma} x_n \Delta t + \sqrt{2D\Delta t}\, z_n \longrightarrow x_{n+1} = x_n + s(x_n)\Delta t + \sqrt{2D\Delta t}\, z_n$$

$$s_\theta(x) = \nabla_x \log p_\theta(x)$$

$p_{data}(x)$: Distribución real de los datos (es desconocida)

$p_\theta(x)$: Distribución que depende de los parámetros θ que son ajustables

por ejm: para la Gaussiana los parámetros son: $(\mu, \sigma) = \theta$

$$p_\theta(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

OJO: Conocer ejemplos de P_{data} no es lo mismo que conocer P_{data}

Lo que sé	Lo que no sé
Los 10.000 fotos son reales	Qué tan probable sea esta otra foto que no vi
Un conjunto de puntos	La función $p_{data}(x)$ para cualquier x

Conocer p_{data} significa poder responder, para cualquier imágen posible, qué tan probable es. Con el dataset solo se que imágenes existen y cuales no.

```
p_data:      la montaña real (oculta)
empírica:    solo picos donde hay muestras
p_θ:         la montaña reconstruida (suave)
```



Para una distribución de Boltzmann:

$$p_\theta(x) = \frac{1}{Z_\theta} e^{\left(-\frac{U_\theta}{K_B T}\right)}$$

$$\log p_\theta(x) = -\frac{1}{K_B T} U_\theta - \log Z_\theta$$

$$S_\theta(x) \equiv \nabla \log P_\theta(x) = -\frac{1}{K_B T} \nabla_x U_\theta \quad ; \quad F_\theta = -\nabla U_\theta$$

$$S_\theta(x) \equiv \frac{1}{K_B T} F_\theta \longrightarrow \boxed{F_\theta(x) = K_B T \, S_\theta(x)}$$

Así:

$$x_{n+1} = x_n + S(x_n)\Delta t + \sqrt{2\Delta t}\, z_n \qquad D=1.$$

Ejmplo: Para una distribución Gaussiana con μ, σ:

La densidad es: $p(\vec{x}) = \frac{1}{2\pi\sigma} e^{-\frac{\|\vec{x}-\vec{\mu}\|^2}{2\sigma}}$

Sacar log: $\log p(\vec{x}) = \frac{-\|\vec{x}-\vec{\mu}\|^2}{2\sigma} - \log(2\pi\sigma)$

Derivar con $\vec{x}$: $\boxed{S_\theta(x) \equiv \nabla_x \log p(\vec{x}) = -\frac{\vec{x}-\vec{\mu}}{\sigma}}$ $\quad \vec{\mu}=0$, $\sigma=1$

EJERCICIO COMPUTACIONAL

Enunciado: Simular dinámica de Langevin de partículas distribuidas al azar en el plano usando el score de una gaussiana con $\mu = (0,0)$ y $\sigma = \mathbb{1}$

R11. $\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$ $\qquad \sigma\mathbb{1} = \begin{pmatrix} \sigma & 0 \\ 0 & \sigma \end{pmatrix}$

$$p(\vec{x}) = \frac{1}{2\pi\sigma} e^{-\frac{\|\vec{x}-\vec{\mu}\|^2}{2\sigma}} = \frac{1}{2\pi\sigma} e^{-\frac{(x_1-\mu_1)^2+(x_2-\mu_2)^2}{2\sigma}}$$

$$\log p(\vec{x}) = -\frac{(x_1-\mu_1)^2+(x_2-\mu_2)^2}{2\sigma} - \log(2\pi\sigma)$$

$$S_\theta(\vec{x}) = \nabla \log p(\vec{x}) = \begin{bmatrix} \partial_{x_1} \log p(\vec{x}) \\ \partial_{x_2} \log p(\vec{x}) \end{bmatrix} = \begin{bmatrix} -\frac{2(x_1-\mu_1)}{2\sigma} \\ -\frac{(x_2-\mu_2)}{\sigma} \end{bmatrix} = \begin{bmatrix} -x_1 \\ -x_2 \end{bmatrix} \longrightarrow \boxed{S(\vec{x}) = -\vec{x}}$$

Luego: $$x_{n+1} = x_n + s(x_n)\,\Delta t + \sqrt{2\,\Delta t}\; z_n$$

↳ $$x_{1,n+1} = x_{1n} - x_{1,n}\,\Delta t + \sqrt{2\Delta t}\; z_{1,n}$$

↳ $$x_{2,n+2} = x_{2n} - x_{2,n}\,\Delta t + \sqrt{2\Delta t}\; z_{1,n}$$