UNIVERSIDAD
DE ANTIOQUIA
1803

Universidad de Antioquia
Facultad de Ciencias Exactas y Naturales
Instituto de Física
Examen, 30 Octubre, CCA

Nombre: Santiago Ramirez puentes
Cédula: 1035440236.

1. (20%)Considere un detector que registra el número de partículas que llegan a su superficie durante intervalos de tiempo fijos. Se asume que las detecciones ocurren de manera independiente y que la tasa esperada de llegada depende de una condición experimental x_i, por ejemplo la intensidad de la fuente, la distancia al detector o el tiempo de exposición. Bajo estas hipótesis, el número de eventos observados y_i se modela como una variable aleatoria de Poisson:

$$p(y_i \mid x_i; \theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}, \quad y_i = 0, 1, 2, \dots \tag{1}$$

donde $h_\theta(x_i)$ representa la tasa esperada de detecciones. En este primer modelo, suponga que la tasa depende linealmente de x_i:

$$h_\theta(x_i) = \theta_0 + \theta_1 x_i. \tag{2}$$

Como $h_\theta(x_i)$ representa una tasa física, se debe cumplir que

$$h_\theta(x_i) > 0 \tag{3}$$

para todos los datos observados.

(a) Construya la función de verosimilitud $L(\theta)$ para un conjunto de datos independientes $\{(x_i, y_i)\}_{i=1}^n$.

(b) Determine la log-verosimilitud $\ell(\theta)$ y obtenga la función de coste asociada al principio de máxima verosimilitud.

(c) Muestre que, salvo constantes independientes de θ, la función de coste puede escribirse como

$$J(\theta) = \sum_{i=1}^{n} \left[h_\theta(x_i) - y_i \log h_\theta(x_i) \right]. \tag{4}$$

(d) Usando $h_\theta(x_i) = \theta_0 + \theta_1 x_i$, calcule el gradiente de $J(\theta)$ respecto a θ_0 y θ_1.

(e) Interprete físicamente $h_\theta(x)$, θ_0 y θ_1 en el contexto del detector.

Punto

1

Solución primer punto:

1) Estimación por máxima verosimilitud para una distribución de poisson

$$p(y_i | x_i; \theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}$$

donde:

$h_\theta(x_i)$ representa la tasa de detecciones.

$h_\theta(x_i) = \theta_0 + \theta_1 x_i$

$h_\theta(x_i) > 0$

a) Construya la función de verosimilitud $L(\theta)$ para un conjunto de datos independientes $\{(x_i, y_i)\}_{i=1}^{n}$

$$L(\theta) = \prod_{i=1}^{n} p(y_i | x_i; \theta)$$

$$L(\theta) = \prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}$$ Para $h_\theta(x_i) = \theta_0 + \theta_1 x_i$ sustituyendo:

$$L(\theta_0, \theta_1) = \prod_{i=1}^{n} \frac{(\theta_0 + \theta_1 x_i)^{y_i} e^{-(\theta_0 + \theta_1 x_i)}}{y_i!}$$

interpretación: la verosimilitud mide que tan compatibles son los conteos observados con unos valores determinados θ_0 y θ_1

②

b) Determine la log - verosimilitud $\ell(\theta)$ y obtenga la función de coste asociada al principio de máxima verosimilitud

*) Aplicamos el logaritmo natural

Definimos la log-verosimilitud como:

$$\ell(\theta) = \ln(L(\theta))$$

Sustituyendo tenemos que:

$$\ell(\theta) = \ln\left[\prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right]$$

Usando:

$$\ln\left(\prod_{i=1}^{n} a_i\right) = \sum_{i=1}^{n} \ln(a_i) \text{ se tiene que:}$$

$$\ell(\theta) = \sum_{i=1}^{n} \ln\left[\frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right]$$

$$\ell(\theta) = \sum_{i=1}^{n}\left[\ln(h_\theta(x_i))^{y_i} + \ln(e^{-h_\theta(x_i)}) - \ln(y_i!)\right]$$

$$\ell(\theta) = \sum_{i=1}^{n} y_i \ln(h_\theta(x_i)) - h_\theta(x_i) - \ln(y_i!)$$

Sustituimos el modelo lineal

$$\ell(\theta_0, \theta_1) = \sum_{i=1}^{n}\left[y_i \ln(\theta_0 + \theta_1 x_i) - (\theta_0 + \theta_1 x_i) - \ln(y_i!)\right]$$

Ahora vamos a construir la función de costo.

Construyendo la función de costo:

El metodo de Máxima Verosimilitud busca:

$$\hat{\theta} = \arg\max_{\theta} L(\theta)$$

Como el logaritmo es estrictamente creciente:

$$\hat{\theta} = \arg\max_{\theta} \ell(\theta)$$

pero los logaritmos de optimización suelen formularse como problemas de minimización.

por eso definimos

$$J_{completa}(\theta) = -\ell(\theta)$$

por lo tanto

$$J_{completa}(\theta) = -\ell(\theta) = -\sum_{i=1}^{n} [y_i \ln h_\theta(x_i) - h_\theta(x_i) - \ln(y_i!))$$

$$J_{completa}(\theta) = \sum_{i=1}^{n} h_\theta(x_i) - y_i \ln(h_\theta(x_i)) + \ln(y_i!)$$

c) Muestre que salvo constantes independientes de θ, la función de costo puede escribirse como:

$$J(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \log h_\theta(x_i)]$$

*) Sabemos que: $J_{completa}(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \ln h_\theta(x_i) + \ln(y_i!)]$

④

Separamos la suma:

$$J_{completa}(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \ln h_\theta(x_i)] + \sum_{i=1}^{n} \ln(y_i!)$$

$C = \sum_{i=1}^{n} \ln(y_i!)$ este termino no depende de θ, es conocido.

$$\frac{\partial C}{\partial \theta} = 0, \quad \frac{\partial C}{\partial \theta_1} = 0$$

por lo tanto,

$$\underset{\theta}{\arg\min} [J(\theta) + C] = \underset{\theta}{\arg\min} J(\theta)$$

por lo tanto definimos

$$\boxed{J(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \ln h_\theta(x_i)]}$$

Sustituyendo el modelo lineal:

$$\boxed{J(\theta_0, \theta_1) = \sum_{i=1}^{n} [(\theta_0 + \theta_1 x_i) - y_i \ln(\theta_0 + \theta_1 x_i)]}$$

f)

Usando $h_\theta(x_i) = \theta_0 + \theta_1 x_i$, calcule el gradiente $J(\theta)$ respecto a θ_0 y θ_1

partimos de:

$$J(\theta_0, \theta_1) = \sum_{i=1}^{n} [(\theta_0 + \theta_1 x_i) - y_i \ln(\theta_0 + \theta_1 x_i)]$$

$$\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n} \frac{\partial}{\partial \theta_0}\left[(\theta_0+\theta_1 x_i) - y_i \ln(\theta_0+\theta_1 x_i)\right]$$

$$\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n}\left[1 - \frac{y_i}{\theta_0+\theta_1 x_i}(1)\right]$$

$$\boxed{\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n}\left(1 - \frac{y_i}{\theta_0+\theta_1 x_i}\right)}$$

Ahora derivamos con respecto a θ_1

$$\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} \frac{\partial}{\partial \theta_1}\left[(\theta_0+\theta_1 x_i) - y_i \ln(\theta_0+\theta_1 x_i)\right]$$

$$\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} x_i - \frac{y_i}{\theta_0+\theta_1 x_i} x_i$$

$$\boxed{\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} x_i\left(1 - \frac{y_i}{\theta_0+\theta_1 x_i}\right)}$$

El gradiente es el vector formada por ambas derivadas:

$$\nabla_\theta J = \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^{n}\left(1 - \frac{y_i}{\theta_0+\theta_1 x_i}\right) \\ \sum_{i=1}^{n} x_i\left(1 - \frac{y_i}{\theta_0+\theta_1 x_i}\right) \end{pmatrix}$$

e) Interprete Fisicamente $h_\theta(x), \theta_0, \theta_1$ en el contexto del detector

Recordemos

$$h_\theta(x) = \theta_0 + \theta_1 x$$

interpretación $h_\theta(x)$

Representa el número esperado de partículas detectadas durante un intervalo de observación, para una condición experimental determinada.

En particular

$$E[Y|X]=h_\theta(X)$$

Ejemplo si $h_\theta(x)=5$

el detector registra en promedio, cinco partículas por intervalo bajo esa condición experimental

interpretación θ_0

Es el término independiente del modelo lineal

Si hacemos $X=0$

$h_\theta(0)=\theta_0$

θ_0: = número esperado de detecciones cuando $X=0$.

Si X representa la intensidad de una fuente y $X=0$ corresponde a una fuente apagada θ_0 podría interpretarse como una contribución de fondo del detector, siempre que el modelo experimental lo justifique.

interpretación θ_1

*) Es la pendiente de la relación entre la tasa esperada y la condición experimental

$$\frac{d h_\theta(x)}{dx}=\theta_1 \quad \boxed{\theta_1\text{: cambio de la tasa esperada por unidad de cambio de } x}$$