4. (30%) Considere una red de memoria asociativa formada por N neuronas que almacena P patrones binarios. Cada patrón se representa mediante un vector de N componentes, cuyos valores son $+1$ o -1. Los patrones almacenados se organizan en una matriz X de tamaño $P \times N$, cuyos elementos son

$$x_{\mu i} \in \{-1, +1\},$$

donde $\mu = 1, \ldots, P$ identifica el patrón almacenado e $i = 1, \ldots, N$ identifica la neurona.

El estado de la red se describe mediante un vector $\mathbf{q} = (q_1, \ldots, q_N)$, donde $q_i \in \mathbb{R}$ representa el estado de la neurona i. Inicialmente, la red recibe un patrón binario $\mathbf{q}^{(0)}$, que puede contener errores respecto a uno de los patrones almacenados.

La recuperación de la memoria se realiza mediante la minimización de la función de energía

$$E(\mathbf{q}) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln \left(\sum_{\mu=1}^{P} \exp \left[\beta \sum_{i=1}^{N} x_{\mu i} q_i \right] \right)$$

donde $\beta > 0$ es un parámetro que controla la selectividad de la recuperación. Durante la evolución de la red, los valores q_i pueden ser continuos, aunque los patrones almacenados sean binarios.

Parte analítica

- Calcular las derivadas parciales de la energía respecto a cada componente q_i y obtener la expresión del gradiente.
- A partir del descenso de gradiente, deducir la regla de actualización:

$$q_i^{(t+1)} = q_i^{(t)} - \alpha \left. \frac{\partial E}{\partial q_i} \right|_{\mathbf{q}=\mathbf{q}^{(t)}},$$

  donde $\alpha > 0$ es el tamaño del paso de actualización y $t = 0, 1, 2, \ldots$ representa el número de iteración.
- Considerar el caso $\alpha = 1$ y simplificar la regla de actualización. Analizar cómo influye el parámetro β en la contribución de los diferentes patrones almacenados, considerando valores pequeños y grandes.

Parte computacional

- Implementar en Python una red de memoria asociativa que almacene dos patrones binarios correspondientes a las letras J y H, representados mediante imágenes de 8×8 píxeles. Cada patrón contiene $N = 64$ componentes, donde $+1$ representa un píxel activo y -1 uno inactivo. Organizar los patrones en una matriz X de tamaño 2×64.
- Seleccionar uno de los patrones almacenados y generar un estado inicial perturbado mediante la inversión aleatoria de un porcentaje de sus píxeles. Implementar iterativamente la regla de actualización obtenida en la parte analítica, utilizando $\alpha = 1$, hasta alcanzar la convergencia o un número máximo de iteraciones.
- Desarrollar experimentos computacionales que permitan:
  (a) Visualizar el patrón original, el patrón perturbado y el estado final de la red, tanto en su representación continua como binaria.
  (b) Estudiar cómo cambia la recuperación al modificar el porcentaje de píxeles perturbados. Realizar varias perturbaciones aleatorias para cada porcentaje y evaluar la calidad de la recuperación.
  (c) Analizar cómo influye el parámetro β en la evolución de la energía y en los estados finales de la red. Interpretar los resultados obtenidos.

Ayuda: Para evaluar la recuperación, convertir el estado final en un patrón binario según el signo de cada componente y calcular el porcentaje de píxeles que coinciden con el patrón original.


Cuarto
Punto

*) punto 4

1) planteamiento del problema:

El enunciado considera una red de memoria asociativa formada por N neuronas.

que almacena p patrones binarios

Cada patron se representa

$$X^M = (X_{M1}, X_{M2}, \dots X_{MN})$$

dado: $X_{Mi} \in \{-1, +1\}$

El estado de la red es:

$$q = (q_1, q_2, \dots, q_N)$$

la función de energía propuesta es:

$$E(q) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln \left[\sum_{M=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j \right) \right]$$

El objetivo es encontrar como debe evolucionar q para disminuir esta energía y recuperar una de los patrones almacenados

2) calcular las derivadas parciales y el gradiente

$$\frac{\partial E}{\partial q_i}$$

$$E(q) = E_1(q) + E_2(q)$$

$$E(q) = E_1(q) + E_2(q)$$

donde:

$$E_1(q) = \frac{1}{2}\sum_{j=1}^{N} q_j^2$$

y $$E_2(q) = -\frac{1}{\beta} \ln\left[\sum_{\mu=1}^{p} e^{\beta \sum_{j=1}^{N} \chi_{\mu j} q_j}\right]$$

paso 1)

Derivar el termino cuadratico:

$$\frac{\partial E_1}{\partial q_i} = \frac{\partial}{\partial q_i}\left(\frac{1}{2}\sum_{j=1}^{N} q_j^2\right) = \frac{1}{2}\sum_{j=1}^{N} \frac{\partial q_j^2}{\partial q_i}$$

$$\frac{\partial q_j}{\partial q_i} = \delta_{ij}$$

por la regla de la cadena

$$\frac{\partial^2 q_j}{\partial q_i} = 2 q_j \delta_{ij}$$

Entonces:

$$\frac{\partial E_1}{\partial q_i} = \frac{1}{2}\sum_{j=1}^{N} 2 q_j \delta_{ij}$$

$$\frac{\partial E_1}{\partial q_i} = q_i$$

Pasos Derivar el termino logaritmo

Definamos:

$$Z(q) = \sum_{M=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

De esta manera

$$F_2(q) = \frac{-1}{\beta} \ln Z(q)$$

Aplicamos la regla de la cadena:

$$\frac{\partial F_2}{\partial q_i} = \frac{-1}{\beta} \frac{1}{Z(q)} \frac{\partial Z}{\partial q_i}$$

Ahora calculemos: $\frac{\partial Z}{\partial q_i}$

$$\frac{\partial Z}{\partial q_i} = \sum_{M=1}^{P} \frac{\partial}{\partial q_i} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

$$\frac{\partial Z}{\partial q_i} = \sum_{M=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right) \frac{\partial}{\partial q_i} \left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

Derivamos el exponente:

$$\frac{\partial}{\partial q_i} \left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right) = \beta \sum_{j=1}^{N} X_{Mj} \frac{\partial q_j}{\partial q_i} = \beta \sum_{j=1}^{N} X_{Mj} \delta_{ij} = \beta X_{Mi}$$

Sustituimos:

$$\frac{\partial Z}{\partial q_i} = \beta \sum_{M=1}^{P} X_{Mi} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

Regresamos a la derivada de E_1:

$$\frac{\partial E_1}{\partial q_i} = \frac{-1}{\beta} \frac{\beta \sum_{M=1}^{P} X_{Mi} e^{\beta \sum_j X_{Mi} q_i}}{\sum_{n=1}^{P} e^{\beta \sum_j X_{ni} q_i}}$$

$$\frac{\partial E_2}{\partial q_i} = - \frac{\sum_{M=1}^{P} X_{Mi} e^{\beta \sum_j X_{Mi} q_i}}{\sum_{n=1}^{P} e^{\beta \sum_j X_{ni} q_i}}$$

Paso 3:
Sumar ambas derivadas:

$$\frac{\partial E}{\partial q_i} = \frac{\partial E_1}{\partial q_i} + \frac{\partial E_2}{\partial q_i}$$

Obtenemos:

$$\frac{\partial E}{\partial q_i} = q_i - \frac{\sum_{M=1}^{P} X_{Mi} \exp\left(\beta \sum_{j=1}^{N} X_{Mi} q_i\right)}{\sum_{n=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{ni} q_i\right)}$$

Paso 4:
Escribir el gradiente vectorial.
Definimos el producto interno entre el patrón X^M y el estado q

$$X^M \cdot q = \sum_{j=1}^{N} X_{Mi} q_i$$

introducimos los pesos:

$$p_M(g) = \frac{e^{\beta x^M \cdot g}}{\sum_{h=1}^{P} e^{\beta x^h \cdot g}}$$

$$\sum_{M=1}^{P} p_M(g) = 1$$

Así la derivada se simplifica

$$\frac{\partial E}{\partial g_i} = g_i - \sum_{M=1}^{P} p_M(g) x_{Mi}$$

Agrupando todas las componentes:

$$\nabla_g E(g) = g - \sum_{M=1}^{P} p_M(g) x^M$$

.) A partir del descenso de gradiente, deducir la regla de actualización

$$g_i^{(t+1)} = g_i^{(t)} - \alpha \frac{\partial E}{\partial g_i}$$

*) El descenso de gradiente actualiza cada componente mediante.

$$g_i^{(t+1)} = g_i^{(t)} - \alpha \frac{\partial E}{\partial g_i}\Big|_{g=g(t)}$$

Sustituimos la derivada obtenida.

$$g_i^{(t+1)} = g_i^{(t)} - \alpha \left[g_i^{(t)} - \sum_{M=1}^{P} p_M(g(t)) x_{Mi} \right]$$

Distribuimos $-\alpha$

$$q_i^{(t+1)} = q_i^{(t)} - \alpha q_i^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Agrupamos los términos de $q_i^{(t)}$

$$q_i^{(t+1)} = (1-\alpha) q_i^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Esta es la regla de actualización explícita.

En forma vectorial:

$$q^{(t+1)} = (1-\alpha) q^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x^\mu$$

Si X es la matriz $P \times N$ podemos escribir

$$q^{(t+1)} = (1-\alpha) q^{(t)} + \alpha X^T p^{(t)}$$

donde $p^{(t)}$ es el vector de los pesos de los P patrones

4) Tercer numeral $\alpha = 1$

partimos de:

$$q_i^{(t+1)} = (1-\alpha) q_i^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Sustituimos $\alpha = 1$

$$q_i^{(t+1)} = (1-1) q_i^{(t)} + \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Obtenemos:

$$q_i^{(t+1)} = \sum_{M=1}^{P} p_M(q(t)) X_{Mi}$$

En forma Vectorial:

$$q^{(t+1)} = \sum_{M=1}^{P} p_M(q(t)) X^M$$

Sustituyendo explícitamente los pesos:

$$q^{(t+1)} = \frac{\sum_{M=1}^{P} X^M \, e^{\beta X^M \cdot q(t)}}{\sum_{M=1}^{P} e^{\beta X^M \cdot q(t)}}$$

Resultado Fundamental Cuando $\alpha = 1$ el nuevo estado es directamente un promedio ponderado de las memorias almacenadas

esto explica por qué los valores de q_i pueden ser continuos durante la recuperación, aun que cada patrón original tenga componentes ± 1

De hecho, al ser un promedio ponderado de valores ± 1

$$-1 \leq q_i^{(t+1)} \leq 1$$

5) Cuarta Numerical Analiza la influencia de β.

El parametro β aparece en los pesos

$$p_M(g) = \frac{e^{\beta S_M}}{\sum_{\nu=1}^{P} e^{\beta S_\nu}}, \quad S_M = X^M \cdot g$$

Caso A: β pequeño

Cuando $\beta \to 0^+$ usamos la expansión de taylor

$$e^{\beta S_M} = 1 + \beta S_M + O(\beta^2)$$

en el denominador:

$$\sum_{\nu=1}^{P} e^{\beta S_\nu} = P + \beta \sum_{\nu=1}^{P} S_\nu + O(\beta^2)$$

por tanto en el limite

$$\lim_{\beta \to 0^+} p_M(g) = \frac{1}{P}$$

Todos los patrones reciben aproximadamente el mismo peso.

Con $\alpha = 1$

$$g(t+1) \approx \frac{1}{P} \sum_{M=1}^{P} X^M$$

interpretación: La red discrimina poco entre memorias y tiende a producir una mezcla de los patrones almacenados.

Caso B: β grande:

Supongamos que el patrón m representa la mayor similitud.

$$S_m = \max_M S_M$$

Dividimos numerador y denominador de p_m por $e^{\beta S_m}$

$$p_m = \frac{1}{1 + \sum_{n \neq m} e^{\beta(S_n - S_m)}}$$

Si el máximo es único, entonces para todo $n \neq m$

$$S_n - S_m < 0$$

Cuando $\beta \to \infty$ $e^{\beta(S_n - S_m)} \to 0$

por consiguiente, $p_m \to 1$, $p_{n \neq m} \to 0$

la actualización se convierte aproximadamente en.

$$y^{(t+1)} \approx x^m$$

la red favorece fuertemente el patrón con mayor similitud y puede recuperarlo de forma más selectiva.

Resultados analíticos finales

Gradiente de energía.

$$\nabla E(q) = q - X^T p(q)$$

Actualización general

$$q^{(t+1)} = (1-\alpha) q^{(t)} + \alpha X^T p(q^{(t)})$$

Actualización para $\alpha = 1$

$$q^{(t+1)} = X^T p(q^{(t)})$$

Pesos de verosimilitud

$$p_m(q) = \frac{e^{\beta X^m \cdot q}}{\sum_{h=1}^{p} e^{\beta X^h \cdot q}}$$