UNIVERSIDAD DE ANTIOQUIA
1803

**Universidad de Antioquia**
Facultad de Ciencias Exactas y Naturales
Instituto de Física
Examen, 30 Octubre, CCA

Nombre: Santiago Ramirez puentes Cédula: 1035944236

1. (20%)Considere un detector que registra el número de partículas que llegan a su superficie durante intervalos de tiempo fijos. Se asume que las detecciones ocurren de manera independiente y que la tasa esperada de llegada depende de una condición experimental $x_i$, por ejemplo la intensidad de la fuente, la distancia al detector o el tiempo de exposición.

   Bajo estas hipótesis, el número de eventos observados $y_i$ se modela como una variable aleatoria de Poisson:

$$p(y_i \mid x_i; \theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}, \quad y_i = 0, 1, 2, \ldots \tag{1}$$

   donde $h_\theta(x_i)$ representa la tasa esperada de detecciones. En este primer modelo, suponga que la tasa depende linealmente de $x_i$:

$$h_\theta(x_i) = \theta_0 + \theta_1 x_i. \tag{2}$$

   Como $h_\theta(x_i)$ representa una tasa física, se debe cumplir que

$$h_\theta(x_i) > 0 \tag{3}$$

   para todos los datos observados.

   (a) Construya la función de verosimilitud $L(\theta)$ para un conjunto de datos independientes $\{(x_i, y_i)\}_{i=1}^n$.

   (b) Determine la log-verosimilitud $\ell(\theta)$ y obtenga la función de coste asociada al principio de máxima verosimilitud.

   (c) Muestre que, salvo constantes independientes de $\theta$, la función de coste puede escribirse como

$$J(\theta) = \sum_{i=1}^{n} \left[ h_\theta(x_i) - y_i \log h_\theta(x_i) \right]. \tag{4}$$

   (d) Usando $h_\theta(x_i) = \theta_0 + \theta_1 x_i$, calcule el gradiente de $J(\theta)$ respecto a $\theta_0$ y $\theta_1$.

   (e) Interprete físicamente $h_\theta(x)$, $\theta_0$ y $\theta_1$ en el contexto del detector.

J



Solución primer punto:

1) Estimación por máxima Verosimilitud para una distribución de poisson

$$P(y_i | x_i, \theta) = \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}$$

donde:

$h_\theta(x_i)$ representa la tasa de detecciones.

$h_\theta(x_i) = \theta_0 + \theta_1 x_i$

$h_\theta(x_i) > 0$

a) Construya la función de Verosimilitud $L(\theta)$ para un conjunto de datos independientes $\{(x_i, y_i)\}_{i=1}^{n}$

$$L(\theta) = \prod_{i=1}^{n} P(y_i | x_i; \theta)$$

$$L(\theta) = \prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}$$ Para $h_\theta(x_i) = \theta_0 + \theta_1 x_i$ sustituyendo:

$$L(\theta_0, \theta_1) = \prod_{i=1}^{n} \frac{(\theta_0 + \theta_1 x_i)^{y_i} e^{-(\theta_0 + \theta_1 x_i)}}{y_i!}$$

Interpretación: La Verosimilitud mide que tan compatibles son los conteos observados con unos valores determinados $\theta_0$ y $\theta_1$.

b) Determine la log - Verosimilitud $\ell(\theta)$ y obtenga la función de costo asociada al principio de máxima Verosimilitud

*) Aplicamos el logaritmo natural

Definimos la log-Verosimilitud como:

$$\ell(\theta) = \ln(L(\theta))$$

Sustituyendo tenemos que:

$$\ell(\theta) = \ln\left[\prod_{i=1}^{n} \frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right]$$

Usando:

$$\ln\left(\prod_{i=1}^{n} a_i\right) = \sum_{i=1}^{n} \ln(a_i) \quad \text{se tiene que:}$$

$$\ell(\theta) = \sum_{i=1}^{n} \ln\left[\frac{h_\theta(x_i)^{y_i} e^{-h_\theta(x_i)}}{y_i!}\right]$$

$$\ell(\theta) = \sum_{i=1}^{n} [\ln(h_\theta(x_i)^{y_i}) + \ln(e^{-h_\theta(x_i)}) - \ln(y_i!)]$$

$$\ell(\theta) = \sum_{i=1}^{n} y_i \ln(h_\theta(x_i)) - h_\theta(x_i) - \ln(y_i!)$$

Sustituimos el modelo lineal

$$\ell(\theta_0, \theta_1) = \sum_{i=1}^{n} [y_i \ln(\theta_0 + \theta_1 x_i) - (\theta_0 + \theta_1 x_i) - \ln(y_i!)]$$

Ahora vamos a construir la función de costo.

Construyendo la función de costo:

El método de máxima Verosimilitud busca:

$$\hat{\theta} = \arg\max_{\theta} L(\theta)$$

Como el logaritmo es estrictamente creciente:

$$\hat{\theta} = \arg\max_{\theta} \ell(\theta)$$

Pero los logaritmos de optimización suelen formularse como problemas de Minimización.

Por eso definimos

$$J_{completa}(\theta) = -\ell(\theta)$$

por lo tanto

$$J_{completa}(\theta) = -\ell(\theta) = -\sum_{i=1}^{n} [y_i \ln h_\theta(x_i) - h_\theta(x_i) - \ln(y_i!)]$$

$$J_{completa}(\theta) = \sum_{i=1}^{n} h_\theta(x_i) - y_i \ln(h_\theta(x_i)) + \ln(y_i!)$$

c) Muestre que si los términos independientes de $\theta$, la función de costo puede escribirse como:

$$J(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \log h_\theta(x_i)]$$

*) Sabemos que: $J_{completa}(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \ln h_\theta(x_i) + \ln(y_i!)]$

Separando la suma:

$$J_{completa}(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \ln h_\theta(x_i)] + \sum_{i=1}^{n} \ln(y_i!)$$

$C = \sum_{i=1}^{n} \ln(y_i!)$ este termino no depende de $\theta$, lo conocido.

$$\frac{\partial C}{\partial \theta} = 0, \quad \frac{\partial C}{\partial \theta_1} = 0$$

por lo tanto:

$$\arg\min_{\theta} [J(\theta) + C] = \arg\min_{\theta} J(\theta)$$

por lo tanto definimos

$$J(\theta) = \sum_{i=1}^{n} [h_\theta(x_i) - y_i \ln h_\theta(x_i)]$$

Sustituyendo el modelo lineal:

$$J(\theta_0, \theta_1) = \sum_{i=1}^{n} [(\theta_0 + \theta_1 x_i) - y_i \ln(\theta_0 + \theta_1 x_i)]$$

d):

Usando

$h_\theta(x_i) = \theta_0 + \theta_1 x_i$, calculo el gradiente $J(\theta)$ respecto a $\theta_0$ y $\theta_1$

partimos de:

$$J(\theta_0, \theta_1) = \sum_{i=1}^{n} [(\theta_0 + \theta_1 x_i) - y_i \ln(\theta_0 + \theta_1 x_i)]$$

$$\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n} \frac{\partial}{\partial \theta_0} \left[ (\theta_0 + \theta_1 x_i) - y_i \ln(\theta_0 + \theta_1 x_i) \right]$$

$$\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n} \left[ 1 - \frac{y_i}{\theta_0 + \theta_1 x_i} (1) \right]$$

$$\boxed{\frac{\partial J}{\partial \theta_0} = \sum_{i=1}^{n} \left( 1 - \frac{y_i}{\theta_0 + \theta_1 x_i} \right)}$$

Ahora derivamos con respecto a $\theta_1$

$$\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} \frac{\partial}{\partial \theta_1} \left[ (\theta_0 + \theta_1 x_i) - y_i \ln(\theta_0 + \theta_1 x_i) \right]$$

$$\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} x_i - \frac{y_i}{\theta_0 + \theta_1 x_i} x_i$$

$$\boxed{\frac{\partial J}{\partial \theta_1} = \sum_{i=1}^{n} x_i \left( 1 - \frac{y_i}{\theta_0 + \theta_1 x_i} \right)}$$

El gradiente es el vector formado por ambas derivadas:

$$\nabla_\theta J = \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^{n} \left( 1 - \frac{y_i}{\theta_0 + \theta_1 x_i} \right) \\ \sum_{i=1}^{n} x_i \left( 1 - \frac{y_i}{\theta_0 + \theta_1 x_i} \right) \end{pmatrix}$$

¿Interpreta físicamente $h_\theta(x)$, $\theta_0$, $\theta_1$ en el contexto del detector

Recordemos

$$h_\theta(x) = \theta_0 + \theta_1 x$$

interpretación $h_\theta(x)$

Representa el número esperado de partículas detectadas durante un intervalo de observación, para una condición experimental determinada.

En particular

$$E[Y|X] = h_\theta(x)$$

Ejemplo si $h_\theta(x) = 5$

el detector registra en promedio, cinco partículas por intervalo bajo esa condición experimental.

interpretación $\theta_0$

Es el término independiente del modelo lineal

Si hacemos $X = 0$

$h_\theta(0) = \theta_0$

$\theta_0$: = número esperado de detecciones cuando $X = 0$.

Si X representa la intensidad de una fuente y $X = 0$ corresponde a una fuente apagada $\theta_0$ podría interpretarse como una contribución de fondo del detector, siempre que el modelo experimental se justifique.

interpretación $\theta_1$

*) Es la pendiente de la relación entre la tasa esperada y la condición experimental

$$\frac{\partial h_\theta(x)}{\partial x} = \theta_1$$

$\theta_1$: cambio de la tasa esperada por unidad de cambio de x

2. (20%) Backward pass. Considere una red neuronal de una capa oculta que recibe una entrada escalar $x_i$ y produce una tasa esperada de conteos mediante una salida positiva:

$$h_\theta(x_i) = \exp(f_\theta(x_i)). \tag{5}$$

La red está definida por:

$$Z_{i,1}^{[1]} = \theta_{1,1}^{[1]} x_i + b_1^{[1]}, \tag{6}$$

$$A_{i,1}^{[1]} = \sigma\left(Z_{i,1}^{[1]}\right), \tag{7}$$

$$Z_{i,1}^{[2]} = \theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}, \tag{8}$$

$$h_\theta(x_i) = \exp\left(Z_{i,1}^{[2]}\right). \tag{9}$$

donde $\sigma$ es una función de activación diferenciable. Para un dato $(x_i, y_i)$, la función de coste de Poisson, salvo constantes independientes de $\theta$, es

$$J_i(\theta) = h_\theta(x_i) - y_i \log h_\theta(x_i). \tag{10}$$

Como $h_\theta(x_i) = \exp\left(Z_{i,1}^{[2]}\right)$, esta función puede escribirse como

$$J_i(\theta) = \exp\left(Z_{i,1}^{[2]}\right) - y_i Z_{i,1}^{[2]}. \tag{11}$$

(a) Calcule el error en la capa de salida:

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}}. \tag{12}$$

(b) Calcule los gradientes respecto a los parámetros de la capa de salida:

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}}, \qquad \frac{\partial J_i}{\partial b_1^{[2]}}. \tag{13}$$

(c) Calcule el error que se propaga hacia la capa oculta:

$$\delta_{i,1}^{[1]} = \frac{\partial J_i}{\partial Z_{i,1}^{[1]}} = \frac{\partial J_i}{\partial Z_{i,1}^{[2]}} \frac{\partial Z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} \frac{\partial A_{i,1}^{[1]}}{\partial Z_{i,1}^{[1]}}. \tag{14}$$

(d) Calcule los gradientes respecto a los parámetros de la primera capa:

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}}, \qquad \frac{\partial J_i}{\partial b_1^{[1]}}. \tag{15}$$

# Segundo Punto

2

*) Punto Numero 2.

Las ecuaciones de la red son:

Se tiene una red con una entrada escalar, una neurona oculta y una neurona de salida

primera capa:

$$z_{i,1}^{[1]} = \theta_{1,1}^{[1]} x_i + b_1^{[1]}$$

$$A_{i,1}^{[1]} = \sigma(z_{i,1}^{[1]})$$

Segunda capa:

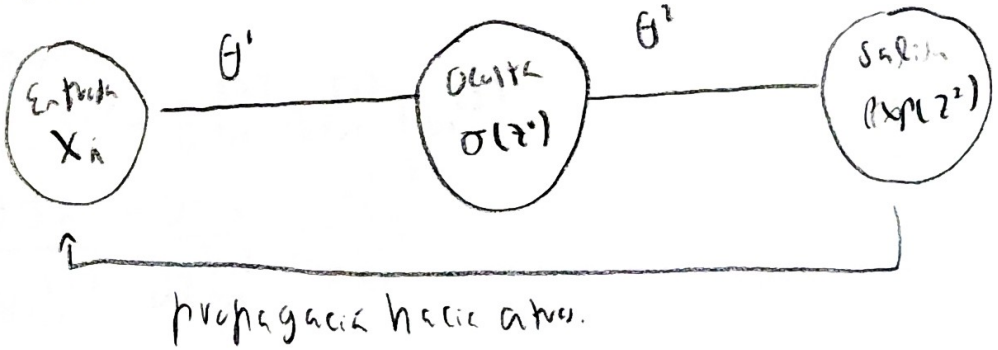
$$z_{i,1}^{[2]} = \theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}$$

$$h_\theta(x_i) = \exp(z_{i,1}^{[2]})$$

La función de costo para una observación es:

$$J_i(\theta) = \exp(z_{i,1}^{[2]}) - y_i z_{i,1}^{[2]}$$

La estructura es:




a) Calcule el error de la capa de salida

El ejercicio pide:

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}}$$

$$\delta_{i,1}^{[2]} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}}$$

$$J_i(\theta) = e^{z_{i,1}^{[2]}} - y_i z_{i,1}^{[2]}$$

$$\frac{\partial J_i(\theta)}{\partial z_{i,1}^{[2]}} = \frac{\partial}{\partial z_{i,1}^{[2]}} e^{z_{i,1}^{[2]}} - y_i \frac{\partial z_{i,1}^{[2]}}{\partial z_{i,1}^{[2]}}$$

$$\frac{\partial J_i(\theta)}{\partial z_{i,1}^{[2]}} = e^{z_{i,1}^{[2]}} - y_i$$

Como $h_\theta(x) = e^{z_{i,1}^{[2]}}$, obtenemos:

$$\delta_{i,1}^{[2]} = h_\theta(x_i) - y_i$$

b) Calcule los gradientes respecto a los parámetros de la capa de salida

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}}, \frac{\partial J_i}{\partial b_1^{[2]}}$$

tenemos:

$$z_{i,1}^{[2]} = \theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}$$

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}} \cdot \frac{\partial z_{i,1}^{[2]}}{\partial \theta_{1,1}^{[2]}}$$

Ej primer factor

$$\frac{\partial J_i}{\partial z_{i,1}^{[2]}} = \delta_{i,1}^{[2]}$$

$$\frac{\partial z_{i,1}^{[2]}}{\partial \theta_{1,1}^{[2]}} = \frac{\partial}{\partial \theta_{1,1}^{[2]}} (\theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}) = A_{i,1}^{[1]}$$ por la tata

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[2]}} = (h_\theta(x) - y_i) A_{i,1}^{[1]}$$

Derivada respecto a $b_1^{[2]}$

$$\frac{\partial J_i}{\partial b_1^{[2]}} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}} \frac{\partial z_{i,1}^{[2]}}{\partial b_1^{[2]}}$$

$$\frac{\partial z_{i,1}^{[2]}}{\partial b_1^{[2]}} = 1$$

Entonces:

$$\frac{\partial J_i}{\partial b_1^{[2]}} = \frac{\partial J_i}{\partial z_{i,1}} (1) = h_\theta(x_i) - y_i$$

C) Calcular el error que se propaga hacia la capa oculta

$$\delta_{i,1}^{[1]} = \frac{\partial J_i}{\partial z_{i,1}^{[1]}} = \frac{\partial J_i}{\partial z_{i,1}^{[2]}} \cdot \frac{\partial z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} \cdot \frac{\partial A_{i,1}^{[1]}}{\partial z_{i,1}^{[1]}}$$

Calculamos el primer factor.

$$\frac{\partial J_i}{\partial z_{i,1}^{[2]}} = \delta_{i,1}^{[2]} = h_\theta(x_i) - y_i$$

Segundo factor:

$$z_{i,1}^{[2]} = \theta_{1,1}^{[2]} A_{i,1}^{[1]} + b_1^{[2]}$$

$$\frac{\partial z_{i,1}^{[2]}}{\partial A_{i,1}^{[1]}} = \theta_{1,1}^{[2]}$$

tercer factor:

la Activación oculta:

$$A_{i,1}^{[1]} = \sigma(z_{i,1}^{[1]})$$

$$A_{i,0}^{[1]} = \sigma(z_{i,1}^{[1]})$$

$$\frac{\partial A_{i,0}^{[1]}}{\partial z_{i,1}^{[1]}} = \sigma'(z_{i,1}^{[1]})$$

Multiplicamos por los factores:

$$\delta_{i,1}^{[1]} = (h_\theta(x_i) - y_i)\,\theta_{1,1}^{[2]}\,\sigma'(z_{i,1}^{[2]})$$

por lo tanto:

$$\delta_{i,1}^{[1]} = \delta_{i,1}^{[1]}\,\theta_{1,1}^{[2]}\,\sigma'(z_{i,1}^{[1]})$$

**1)** Gradientes respecto a los parametros de la primera capa:

La primera capa esta definida por

$$z_{i,1}^{[1]} = \theta_{1,1}^{[1]} x_i + b_1^{[1]}$$

$$\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = \frac{\partial J_i}{\partial z_{i,1}^{[1]}} \times \frac{\partial z_{i,1}^{[1]}}{\partial \theta_{1,1}^{[1]}}$$

$$\frac{\partial J_i}{\partial z_{i,1}^{[1]}} = \delta_{i,1}^{[1]} \qquad \frac{\partial z_{i,1}^{[1]}}{\partial \theta_{1,1}^{[1]}} = \frac{\partial}{\partial \theta_{1,1}^{[1]}}\left(\theta_{1,1}^{[1]} x_i + b_1^{[1]}\right) = x_i$$

$$\frac{\partial J_i}{\partial z_{i,1}^{[1]}} = \delta_{i,1}^{[1]}\, x_i$$

$$\boxed{\frac{\partial J_i}{\partial \theta_{1,1}^{[1]}} = (h_\theta(x_i) - y_i)\,\theta_{1,1}^{[2]}\,\sigma'(z_{i,1}^{[1]})\, x_i}$$

Derivada respecto al sesgo $b_1^{[1]}$

$$\frac{\partial J_i}{\partial b_1^{[1]}} = \frac{\partial J_i}{\partial z_{i,1}^{[1]}} \cdot \frac{\partial z_{i,1}^{[1]}}{\partial b_1^{[1]}}$$

$$\frac{\partial z_{i,1}^{[1]}}{\partial b_1^{[1]}} = 1$$

$$\frac{\partial J_i}{\partial z_{i,1}^{[1]}} = \delta_{i,1}^{[1]}$$

por lo tanto:

$$\frac{\partial J_i}{\partial b_1^{[1]}} = (h_\theta(x_i) - y_i)\,\theta_{1,1}^{[2]}\,\sigma'(z_{i,1}^{[1]})$$

3. (30%) Considere una membrana cuadrada de lado unitario, con bordes fijos, cuyos desplazamientos transversales (U(x,y,t)), respecto a su posición de equilibrio, están descritos, en el régimen de pequeñas oscilaciones, por la ecuación de ondas adimensional:

$$\frac{\partial^2 U}{\partial t^2} = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2}$$

con $U = 0$ en los bordes y condiciones iniciales

$$U(x, y, 0) = \sin(\pi x)\sin(\pi y),$$

$$U_t(x, y, 0) = \sqrt{2}\pi \sin(\pi x)\sin(\pi y).$$

Aproxime el desplazamiento $U(x, y, t)$ mediante una PINN de la forma

$$U_\theta(x, y, t) = \sin(\pi x)\sin(\pi y)a_\theta(t).$$

donde $a_\theta(t)$ se representa mediante las siguientes arquitecturas:

**Modelo A.** Una capa con dos neuronas de activación sinusoidal:

$$a_\theta(t) = \sum_{j=1}^{2} A_j \sin(w_j t + b_j).$$

**Modelo B.** Dos capas consecutivas, con una neurona por capa:

$$h_1(t) = \sin(w_1 t + b_1),$$

$$a_\theta(t) = A \sin(w_2 h_1(t) + b_2).$$

**Parte analítica**. Para ambas arquitecturas, reducir la ecuación de ondas a una ecuación diferencial ordinaria, calcular analíticamente las derivadas de las neuronas y construir el residuo físico y la función de pérdida, incorporando las condiciones iniciales.

**Parte computacional**. Implementar en Python ambas arquitecturas y minimizar sus funciones de pérdida mediante un método de optimización. Comparar gráficamente las soluciones obtenidas con la solución analítica, cuantificar los errores de aproximación y analizar la conservación de la energía mecánica de la membrana. Analice todos los resultados.

**Ayuda:** La energía mecánica total se conserva:

$$E(t) = \frac{1}{2}\int_0^1 \int_0^1 \left[\left(\frac{\partial U}{\partial t}\right)^2 + \left(\frac{\partial U}{\partial x}\right)^2 + \left(\frac{\partial U}{\partial y}\right)^2\right] dx\, dy.$$

$$\frac{dE}{dt} = 0.$$

Punto 3

Punto 3

Planteamiento del problema

tenemos una membrana de lado unitario

$0 \le x \le 1, \quad 0 \le y \le 1$

su desplazamiento transversal satisface la ecuación de ondas.

$$\frac{\partial^2 U}{\partial t^2} = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2}$$

las condiciones de frontera son:

$$U(0,y,t) = U(1,y,t) = 0$$

las condiciones iniciales son:

$$U(x,y,0) = \sin(\pi x)\sin(\pi y)$$

$$U_t(x,y,0) = \sqrt{2}\,\pi \sin(\pi x)\sin(\pi y)$$

la Aproximación propuesta es:

$$U_\theta(x,y,t) = \sin(\pi x)\sin(\pi y)\,a_\theta(t)$$

2) Reducción de la ecuación de ondas a una EDO

$$U_\theta(x,y,t) = \sin(\pi x)\sin(\pi y)\,a_\theta(t)$$

$$\frac{\partial U_\theta}{\partial t} = \sin(\pi x)\sin(\pi y)\,a'_\theta(t)$$

$$\frac{\partial^2 U_\theta}{\partial t^2} = \sin(\pi x)\sin(\pi y)\,a''_\theta(t)$$

paso 2

Calcular la segunda derivada espacial respecto a X

$$\frac{\partial U_\theta}{\partial X} = \pi \cos(\pi x)\sin(\pi y)a_\theta(t)$$

$$\frac{\partial^2 U_\theta}{\partial x^2} = -\pi^2 \sin(\pi x)\sin(\pi y)a_\theta(t)$$

paso 3: Calcular la segunda derivada espacial respecto a y

$$\frac{\partial U_\theta}{\partial y} = \pi \sin(\pi x)\cos(\pi y)a_\theta(t)$$

Por lo tanto:

$$\frac{\partial^2 U_\theta}{\partial y^2} = -\pi^2 \sin(\pi x)\sin(\pi y)a_\theta(t)$$

paso 4

Sustituir en la ecuación de ondas:

la ecuación original es:

$$U_{tt} = U_{xx} + U_{yy}$$

Sustituimos

$$\sin(\pi x)\sin(\pi y)a_\theta''(t) = -\pi^2\sin(\pi x)\sin(\pi y)a_\theta(t) - \pi^2\sin(\pi x)\sin(\pi y)a_\theta(t)$$

Agrupamos:

$$\sin(\pi x)\sin(\pi y)a_\theta''(t) = -2\pi^2\sin(\pi x)\sin(\pi y)a_\theta(t)$$

para los puntos interiores donde el vector espacial es distinto de cero podemos dividir por $\sin(\pi x)\sin(\pi y)$ Entonces:

$$a_\theta''(t) = -2\pi^2 a_\theta(t)$$

$$\boxed{a_\theta''(t) + 2\pi^2 a_\theta(t) = 0}$$ Esta es la ecuación que deben satisfacer ambas arquitecturas

Podemos escribirla como:

$$a\theta''(t) + \omega^2 a_\theta(t) = 0$$

donde $\omega = \sqrt{2}\pi$

Esta es la ecuación de un oscilador armonico simple.

Reducción de las condiciones iniciales.

$$U(x,y,0) = \sin(\pi x)\sin(\pi y)$$

$$U_\theta(x,y,0) = \sin(\pi x)\sin(\pi y)\, a_\theta(0)$$

Al comparar ambas expresiones:

$$a_\theta(0) = 1$$

La segunda condición:

$$U_t(x,y,0) = \sqrt{2}\pi \sin(\pi x)\sin(\pi y)$$

$$U_{\theta,t}(x,y,0) = \sin(\pi x)\sin(\pi y)\, a'_\theta(0)$$

$$a'_\theta(0) = \sqrt{2}\pi$$

Por tanto el problema reducido es:

$$\begin{cases} a''(t) + 2\pi^2 a(t) = 0 \\ a(0) = 1 \\ a'(0) = \sqrt{2}\pi \end{cases}$$

4) Solución analítica exacta

La ecuación es:

$$a'' + \omega^2 a = 0 \quad \omega = \sqrt{2}\pi$$

La ecuación es:

$a'' + w^2 a = 0 \quad w = \sqrt{2}\pi$

La solución general:

$a(t) = C_1 \cos(wt) + C_2 \sin(wt)$

Aplicamos la primera condición inicial

$a(0) = C_1 \cos(0) + C_2 \sin(0) = C_1$

$a(0) = 1 \quad C_1 = 1$

Ahora derivamos:

$a'(t) = -C_1 w \sin(wt) + C_2 w \cos(wt)$

Evaluamos en $t = 0$

$a'(0) = C_2 w$

pero:

$a'(0) = \sqrt{2}\pi = w$

por lo tanto $C_2 = 1$

La solución temporal exacta es:

$$a(t) = \cos(\sqrt{2}\pi t) + \sin(\sqrt{2}\pi t)$$

y la solución exacta de la membrana es:

$$V(x, y, t) = \sin(\pi x)\sin(\pi y)\left[\cos(\sqrt{2}\pi t) + \sin(\sqrt{2}\pi t)\right]$$

5) Modelo A: una capa oculta con funciones sinusoidales

$$a_{\theta}(t) = \sum_{j=1}^{2} A_j \sin(w_j t + b_j)$$

$a_{\theta}(t) = A_1 \sin(w_1 t + b_1) + A_2 \sin(w_2 t + b_2)$

Los parametros entrenables son:

$\theta_A = [A_1, A_2, w_1, w_2, b_1, b_2]$

primera derivada temporal:

$\frac{d}{dt}[A_1 \sin(w_1 t + b_1)] = A_1 w_1 \cos(w_1 t + b_1)$

$\frac{d}{dt}[A_2 \sin(w_2 t + b_2)] = A_2 w_2 \cos(w_2 t + b_2)$

$a'_{\theta}(t) = A_1 w_1 \cos(w_1 t + b_1) + A_2 w_2 \cos(w_2 t + b_2)$

Segunda derivada temporal

$\frac{d}{dt}[A_1 w_1 \cos(w_1 t + b_1) + A_2 w_2 \cos(w_2 t + b_2)]$

$= -A_1 w_1^2 \sin(w_1 t + b_1) - A_2 w_2^2 \sin(w_2 t + b_2)$

$a''_{\theta}(t) = -A_1 w_1^2 \sin(w_1 t + b_1) - A_2 w_2^2 \sin(w_2 t + b_2)$

Residuo del modelo A:

$a''_{\theta}(t) + 2\pi^2 a_{\theta}(t) = 0$

$V_A(t) = a''_{\theta}(t) + 2\pi^2 a_{\theta}(t)$

Sustituimos las expresiones

$V_A(t) = -A_1 w_1^2 \sin(w_1 t + b_1) - A_2 w_2^2 \sin(w_2 t + b_2) + 2\pi^2 A_1 \sin(w_1 t + b_1) +$

$2\pi^2 A_2 \sin(w_2 t + b_2)$

$V_A(t) = A_1(2\pi^2 - w_1^2) \sin(w_1 t + b_1) + A_2(2\pi^2 - w_2^2) \sin(w_2 t + b_2)$

Si el modelo satisface exactamente la ecuación diferencial, entonces:

$$r_A(t) = 0$$

Condiciones iniciales del modelo:

$$a_\theta(0) = 1$$

Sustituimos $t = 0$

$$A_1 \sin b_1 + A_2 \sin b_2 = 1$$

$$a\dot{\theta}(0) = \sqrt{2}\,\pi$$

Sustituimos:

$$A_1 w_1 \cos b_1 + A_2 w_2 \cos b_2 = \sqrt{2}\,\pi$$

*) Función de pérdida del modelo A

Elegimos $N_V$ puntos temporales de colocación

$$\{t_k\}_{k=1}^{N_V}$$

La pérdida física es:

$$\mathcal{L}_{Fis,A} = \frac{1}{N_V} \sum_{k=1}^{N_V} r_A(t_k)^2$$

La pérdida por condiciones iniciales es:

$$\mathcal{L}_{CI,A} = [a_\theta(0) - 1]^2 + [a\dot{\theta}(0) - \sqrt{2}\,\pi]^2$$

Por lo tanto la función de pérdida total puede escribirse:

$$\mathcal{L}_A = \lambda_V \mathcal{L}_{Fis,A} + \lambda_0 [a_\theta(0) - 1]^2 + \lambda_1 [a\dot{\theta}(0) - \sqrt{2}\,\pi]^2$$

Dado $\lambda_V, \lambda_0, \lambda_1 > 0$ son pesos que controlan la importancia de cada contribución.

En forma explícita:

$$\mathcal{L}_A = \frac{\lambda_v}{N_V} \sum_{k=1}^{N_V} \left[ \sum_{j=1}^{2} A_j(2\pi^2 - w_j^2) \sin(w_j t_k + b_j) \right]^2$$

$$+ \lambda_0 \left[ A_1 \sin b_1 + A_2 \sin b_2 - 1 \right]^2$$

$$+ \lambda_1 \left[ A_1 w_1 \cos b_1 + A_2 w_2 \cos b_2 - \sqrt{2}\pi \right]^2$$

*) El modelo A puede representar exactamente la solución analítica.

Modelo B: Dos capas consecutivas:

El enunciado define:

$h_1(t) = \sin(w_1 t + b_1)$

$a_\theta(t) = A \sin(w_2 h_1(t) + b_2)$

Los parámetros entrenables son:

$\theta_B = (A, w_1, w_2, b_1, b_2)$

Para facilitar las derivadas definimos

$z_1(t) = w_1 t + b_1$

$h_1(t) = \sin z_1(t)$

$z_2(t) = w_2 h_1(t) + b_2$

Entonces: $a_\theta(t) = A \sin z_2(t)$

Primeira derivada temporal

$a\theta'(t) = A\cos z_2(t)\, z_2'(t)$

$z_2'(t) = w_2 h_1'(t)$

$h_1'(t) = w_1 \cos(w_1 t + b_1)$

temos:

$z_1'(t) = w_1 w_2 \cos(w_1 t + b_1)$

Por fe tanto:

$a\theta'(t) = A w_1 w_2 \cos(w_1 t + b_1) \cos[w_2 \sin(w_1 t + b_1) + b_2]$

Segunda derivada temporal:

$a\theta'(t) = A w_1 w_2 \cos z_1(t) \cos z_2(t)$

$a\theta''(t) = A w_1 w_2 [-w_1 \sin z_1(t) \cos z_2(t) + \cos z_1(t)(-\sin z_1(t) z_2'(t))]$

$z_2'(t) = w_1 w_2 \cos z_1(t)$

$a\theta''(t) = -A w_1^2 w_2 \sin z_1(t) \cos z_1(t) - A w_1^2 w_1^2 \cos^2 z_1(t) \sin z_2(t)$

Resíduo físico do modelo B.

Definimos:

$V_B(t) = a\theta''(t) + 2\Pi^2 a\theta(t)$

Substituindo as expressões:

$V_B(t) = -A w_1^2 w_2 \sin z_1(t) \cos z_2(t) - A w_1^2 w_2^2 \cos^2 z_1(t) \sin z_1(t) + 2\Pi^2 A \sin z_1(t)$

Dado $z_1(t) = w_1 t + b_1$, $z_2(t) = w_2 \sin z_1(t) + b_2$

(20)

Condiciones iniciales para el modelo B.

para $t=0$

$z_1(0) = b_1$

$z_2(0) = w_2 \sin b_1 + b_2$

primera condición

$A\theta(0) = 1$

$A \sin(w_2 \sin b_1 + b_2) = 1$

Segunda condición

$A\theta'(0) = \sqrt{2}\pi$

sustituyendo

$A w_1 w_2 \cos b_1 \cos(w_2 \sin b_1 + b_2) = \sqrt{2}\pi$

*) Función de pérdida del modelo B:

La pérdida física es:

$$\mathcal{L}_{Fis,B} = \frac{1}{Nv} \sum_{k=1}^{Nv} v_B(tk)^2$$

La pérdida total queda:

$$\mathcal{L}_B = \frac{\lambda v}{Nv} \sum_{k=1}^{Nv} v_B(tk)^2 + \lambda_c [A\sin(w_2 \sin b_1 + b_2) - 1]^2 + \lambda_1 [A w_1 w_2 \cos b_1 \cos(w_2 \sin b_1 + b_2) - \sqrt{2}\pi]^2$$

#) Energía mecánica: resultado Análisis dimensional

Enunciado proporciona:

$$E(t) = \frac{1}{2} \int_0^1 \int_0^1 [v_t^2 + v_x^2 + v_y^2] \, dx \, dy$$

Sustituimos:

$$U = \sin(\pi x)\sin(\pi y)\, a(t)$$

Las derivadas son:

$$U_t = \sin(\pi x)\sin(\pi y)\, a'(t)$$

$$U_x = \pi \cos(\pi x)\sin(\pi y)\, a(t)$$

$$U_y = \pi \sin(\pi x)\cos(\pi y)\, a(t)$$

Usamos las integrales:

$$\int_0^1 \sin^2(\pi x)\, dx = \frac{1}{2}, \quad \int_0^1 \cos^2(\pi x)\, dx = \frac{1}{2}$$

Por lo tanto la contribución temporal es:

$$\int_0^1 \int_0^1 U_t^2\, dx\, dy = \frac{1}{4}[a'(t)]^2$$

Cada contribución espacial es:

$$\int_0^1 \int_0^1 U_x^2\, dx\, dy = \frac{\pi^2}{4} a(t)^2$$

$$\int_0^1 \int_0^1 U_y^2\, dx\, dy = \frac{\pi^2}{4} a(t)^2$$

Sumamos y multiplicamos por $\frac{1}{2}$

$$E(t) = \frac{1}{2}[a'(t)]^2 + \frac{\pi^2}{4} a(t)^2$$

Podemos verificar la conservación derivando.

$$\frac{dE}{dt} = \frac{1}{4} a'(t) a''(t) + \frac{\pi^2}{2} a(t) a'(t)$$

$$\frac{dE}{dt} = \frac{1}{4} a'(t) [a''(t) + 2\pi^2 a(t)]$$

Como la solución exacta satisface

$$a''(t) + 2\pi^2 a(t) = 0$$

Resulta

$$\frac{dE}{dt} = 0$$

Finalmente evaluamos la Energía inicial

$$a(0) = 1, \quad a'(0) = \sqrt{2}\pi$$

Entonces

$$E(0) = \frac{1}{2}(2\pi^2) + \frac{\pi^2}{4} = \frac{\pi^2}{2}$$

por lo tanto la Energía exacta permanece constante.

4. (30%) Considere una red de memoria asociativa formada por $N$ neuronas que almacena $P$ patrones binarios. Cada patrón se representa mediante un vector de $N$ componentes, cuyos valores son $+1$ o $-1$. Los patrones almacenados se organizan en una matriz $X$ de tamaño $P \times N$, cuyos elementos son

$$x_{\mu i} \in \{-1, +1\},$$

donde $\mu = 1, \ldots, P$ identifica el patrón almacenado e $i = 1, \ldots, N$ identifica la neurona.

El estado de la red se describe mediante un vector $\mathbf{q} = (q_1, \ldots, q_N)$, donde $q_i \in \mathbb{R}$ representa el estado de la neurona $i$. Inicialmente, la red recibe un patrón binario $\mathbf{q}^{(0)}$, que puede contener errores respecto a uno de los patrones almacenados.

La recuperación de la memoria se realiza mediante la minimización de la función de energía

$$E(\mathbf{q}) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln \left( \sum_{\mu=1}^{P} \exp \left[ \beta \sum_{i=1}^{N} x_{\mu i} q_i \right] \right)$$

donde $\beta > 0$ es un parámetro que controla la selectividad de la recuperación. Durante la evolución de la red, los valores $q_i$ pueden ser continuos, aunque los patrones almacenados sean binarios.

**Parte analítica**

- Calcular las derivadas parciales de la energía respecto a cada componente $q_i$ y obtener la expresión del gradiente.
- A partir del descenso de gradiente, deducir la regla de actualización:

$$q_i^{(t+1)} = q_i^{(t)} - \alpha \left. \frac{\partial E}{\partial q_i} \right|_{\mathbf{q}=\mathbf{q}^{(t)}},$$

  donde $\alpha > 0$ es el tamaño del paso de actualización y $t = 0, 1, 2, \ldots$ representa el número de iteración.
- Considerar el caso $\alpha = 1$ y simplificar la regla de actualización. Analizar cómo influye el parámetro $\beta$ en la contribución de los diferentes patrones almacenados, considerando valores pequeños y grandes.

**Parte computacional**

- Implementar en Python una red de memoria asociativa que almacene dos patrones binarios correspondientes a las letras J y H, representados mediante imágenes de $8 \times 8$ píxeles. Cada patrón contiene $N = 64$ componentes, donde $+1$ representa un píxel activo y $-1$ uno inactivo. Organizar los patrones en una matriz $X$ de tamaño $2 \times 64$.
- Seleccionar uno de los patrones almacenados y generar un estado inicial perturbado mediante la inversión aleatoria de un porcentaje de sus píxeles. Implementar iterativamente la regla de actualización obtenida en la parte analítica, utilizando $\alpha = 1$, hasta alcanzar la convergencia o un número máximo de iteraciones.
- Desarrollar experimentos computacionales que permitan:
  (a) Visualizar el patrón original, el patrón perturbado y el estado final de la red, tanto en su representación continua como binaria.
  (b) Estudiar cómo cambia la recuperación al modificar el porcentaje de píxeles perturbados. Realizar varias perturbaciones aleatorias para cada porcentaje y evaluar la calidad de la recuperación.
  (c) Analizar cómo influye el parámetro $\beta$ en la evolución de la energía y en los estados finales de la red. Interpretar los resultados obtenidos.

**Ayuda:** Para evaluar la recuperación, convertir el estado final en un patrón binario según el signo de cada componente y calcular el porcentaje de píxeles que coinciden con el patrón original.


Cuarto
Punto

## *) punto 4

1) planteamiento del problema:

El enunciado considera una red de memoria asociativa formada por N neuronas.

que almacena p patrones binarios

Cada patron se representa

$$X^M = (X_{M1}, X_{M2}, \dots X_{MN})$$

dado: $X_{Mi} \in \{-1, +1\}$

El estado de la red es:

$$q = (q_1, q_2, \dots, q_N)$$

la función de energía propuesta es:

$$E(q) = \frac{1}{2} \sum_{i=1}^{N} q_i^2 - \frac{1}{\beta} \ln \left[ \sum_{M=1}^{P} \exp\left( \beta \sum_{j=1}^{N} X_{Mj} q_j \right) \right]$$

El objetivo es encontrar como debe evolucionar $q$ para disminuir esta energía y recuperar una de los patrones almacenados

2) calcular las derivadas parciales y el gradiente

$$\frac{\partial E}{\partial q_i}$$

$$E(q) = E_1(q) + E_2(q)$$

$$E(q) = E_1(q) + E_2(q)$$

donde:

$$E_1(q) = \frac{1}{2}\sum_{j=1}^{N} q_j^2$$

y $$E_2(q) = -\frac{1}{\beta} \ln\left[\sum_{\mu=1}^{p} e^{\beta \sum_{j=1}^{N} \chi_{\mu j} q_j}\right]$$

paso 1)

Derivar el termino cuadratico:

$$\frac{\partial E_1}{\partial q_i} = \frac{\partial}{\partial q_i}\left(\frac{1}{2}\sum_{j=1}^{N} q_j^2\right) = \frac{1}{2}\sum_{j=1}^{N} \frac{\partial q_j^2}{\partial q_i}$$

$$\frac{\partial q_j}{\partial q_i} = \delta_{ij}$$

por la regla de la cadena

$$\frac{\partial^2 q_j}{\partial q_i} = 2 q_j \delta_{ij}$$

Entonces:

$$\frac{\partial E_1}{\partial q_i} = \frac{1}{2}\sum_{j=1}^{N} 2 q_j \delta_{ij}$$

$$\frac{\partial E_1}{\partial q_i} = q_i$$

Pasos Derivar el termino logaritmo

Definamos:

$$Z(q) = \sum_{M=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

De esta manera

$$F_2(q) = \frac{-1}{\beta} \ln Z(q)$$

Aplicamos la regla de la cadena:

$$\frac{\partial F_2}{\partial q_i} = \frac{-1}{\beta} \frac{1}{Z(q)} \frac{\partial Z}{\partial q_i}$$

Ahora calculemos: $\frac{\partial Z}{\partial q_i}$

$$\frac{\partial Z}{\partial q_i} = \sum_{M=1}^{P} \frac{\partial}{\partial q_i} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

$$\frac{\partial Z}{\partial q_i} = \sum_{M=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right) \frac{\partial}{\partial q_i} \left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

Derivamos el exponente:

$$\frac{\partial}{\partial q_i} \left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right) = \beta \sum_{j=1}^{N} X_{Mj} \frac{\partial q_j}{\partial q_i} = \beta \sum_{j=1}^{N} X_{Mj} \delta_{ij} = \beta X_{Mi}$$

Sustituimos:

$$\frac{\partial Z}{\partial q_i} = \beta \sum_{M=1}^{P} X_{Mi} \exp\left(\beta \sum_{j=1}^{N} X_{Mj} q_j\right)$$

Regresamos a la derivada de $E_1$:

$$\frac{\partial E_1}{\partial q_i} = \frac{-1}{\beta} \frac{\beta \sum_{M=1}^{P} X_{Mi} e^{\beta \sum_j X_{Mi} q_i}}{\sum_{n=1}^{P} e^{\beta \sum_j X_{ni} q_i}}$$

$$\frac{\partial E_2}{\partial q_i} = - \frac{\sum_{M=1}^{P} X_{Mi} e^{\beta \sum_j X_{Mi} q_i}}{\sum_{n=1}^{P} e^{\beta \sum_j X_{ni} q_i}}$$

Paso 3:
Sumar ambas derivadas:

$$\frac{\partial E}{\partial q_i} = \frac{\partial E_1}{\partial q_i} + \frac{\partial E_2}{\partial q_i}$$

Obtenemos:

$$\frac{\partial E}{\partial q_i} = q_i - \frac{\sum_{M=1}^{P} X_{Mi} \exp\left(\beta \sum_{j=1}^{N} X_{Mi} q_i\right)}{\sum_{n=1}^{P} \exp\left(\beta \sum_{j=1}^{N} X_{ni} q_i\right)}$$

Paso 4:
Escribir el gradiente vectorial.
Definimos el producto interno entre el patrón $X^M$ y el estado $q$

$$X^M \cdot q = \sum_{j=1}^{N} X_{Mi} q_i$$

introducimos los pesos:

$$p_M(g) = \frac{e^{\beta x^M \cdot g}}{\sum_{h=1}^{P} e^{\beta x^h \cdot g}}$$

$$\sum_{M=1}^{P} p_M(g) = 1$$

Así la derivada se simplifica

$$\frac{\partial E}{\partial g_i} = g_i - \sum_{M=1}^{P} p_M(g) x_{Mi}$$

Agrupando todas las componentes:

$$\nabla_g E(g) = g - \sum_{M=1}^{P} p_M(g) x^M$$

.) A partir del descenso de gradiente, deducir la regla de actualización

$$g_i^{(t+1)} = g_i^{(t)} - \alpha \frac{\partial E}{\partial g_i}$$

*) El descenso de gradiente actualiza cada componente mediante.

$$g_i^{(t+1)} = g_i^{(t)} - \alpha \frac{\partial E}{\partial g_i}\Big|_{g=g(t)}$$

Sustituimos la derivada obtenida.

$$g_i^{(t+1)} = g_i^{(t)} - \alpha \left[ g_i^{(t)} - \sum_{M=1}^{P} p_M(g(t)) x_{Mi} \right]$$

Distribuimos $-\alpha$

$$q_i^{(t+1)} = q_i^{(t)} - \alpha q_i^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Agrupamos los términos de $q_i^{(t)}$

$$q_i^{(t+1)} = (1-\alpha) q_i^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Esta es la regla de actualización explícita.

En forma vectorial:

$$q^{(t+1)} = (1-\alpha) q^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x^\mu$$

Si $X$ es la matriz $P \times N$ podemos escribir

$$q^{(t+1)} = (1-\alpha) q^{(t)} + \alpha X^T p^{(t)}$$

donde $p^{(t)}$ es el vector de los pesos de los $P$ patrones

4) Tercer numeral $\alpha = 1$

partimos de:

$$q_i^{(t+1)} = (1-\alpha) q_i^{(t)} + \alpha \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Sustituimos $\alpha = 1$

$$q_i^{(t+1)} = (1-1) q_i^{(t)} + \sum_{\mu=1}^{P} p_\mu(q^{(t)}) x_{\mu i}$$

Obtenemos:

$$q_i^{(t+1)} = \sum_{M=1}^{P} p_M(q(t)) X_{Mi}$$

En forma Vectorial:

$$q^{(t+1)} = \sum_{M=1}^{P} p_M(q(t)) X^M$$

Sustituyendo explícitamente los pesos:

$$q^{(t+1)} = \frac{\sum_{M=1}^{P} X^M \, e^{\beta X^M \cdot q(t)}}{\sum_{M=1}^{P} e^{\beta X^M \cdot q(t)}}$$

Resultado Fundamental Cuando $\alpha = 1$ el nuevo estado es directamente un promedio ponderado de las memorias almacenadas

esto explica por qué los valores de $q_i$ pueden ser continuos durante la recuperación, aun que cada patrón original tenga componentes $\pm 1$

De hecho, al ser un promedio ponderado de valores $\pm 1$

$$-1 \leq q_i^{(t+1)} \leq 1$$

5) Cuarta Numerical Analiza la influencia de $\beta$.

El parametro $\beta$ aparece en los pesos

$$p_M(g) = \frac{e^{\beta S_M}}{\sum_{\nu=1}^{P} e^{\beta S_\nu}}, \quad S_M = X^M \cdot g$$

Caso A: $\beta$ pequeño

Cuando $\beta \to 0^+$ usamos la expansión de taylor

$$e^{\beta S_M} = 1 + \beta S_M + O(\beta^2)$$

en el denominador:

$$\sum_{\nu=1}^{P} e^{\beta S_\nu} = P + \beta \sum_{\nu=1}^{P} S_\nu + O(\beta^2)$$

por tanto en el limite

$$\lim_{\beta \to 0^+} p_M(g) = \frac{1}{P}$$

Todos los patrones reciben aproximadamente el mismo peso.

Con $\alpha = 1$

$$g(t+1) \approx \frac{1}{P} \sum_{M=1}^{P} X^M$$

interpretación: La red discrimina poco entre memorias y tiende a producir una mezcla de los patrones almacenados.

Caso B: $\beta$ grande:

Supongamos que el patrón m representa la mayor similitud.

$$S_m = \max_M S_M$$

Dividimos numerador y denominador de $p_m$ por $e^{\beta S_m}$

$$p_m = \frac{1}{1 + \sum_{n \neq m} e^{\beta(S_n - S_m)}}$$

Si el máximo es único, entonces para todo $n \neq m$

$$S_n - S_m < 0$$

Cuando $\beta \to \infty$ $e^{\beta(S_n - S_m)} \to 0$

por consiguiente, $p_m \to 1$, $p_{n \neq m} \to 0$

la actualización se convierte aproximadamente en.

$$y^{(t+1)} \approx x^m$$

la red favorece fuertemente el patrón con mayor similitud y puede recuperarlo de forma más selectiva.

Resultados analíticos finales

Gradiente de energía.

$$\nabla E(q) = q - X^T p(q)$$

Actualización general

$$q^{(t+1)} = (1-\alpha) q^{(t)} + \alpha X^T p(q^{(t)})$$

Actualización para $\alpha = 1$

$$q^{(t+1)} = X^T p(q^{(t)})$$

Pesos de verosimilitud

$$p_m(q) = \frac{e^{\beta X^m \cdot q}}{\sum_{h=1}^{p} e^{\beta X^h \cdot q}}$$